

杭州电子科技大学

硕士学位论文

题目 面向变电站运维的搬运机器人导
航系统设计与实现

姓 名 任佳乐

专 业 控制工程

指导教师 黄娜

完成日期 二〇二七年五月

杭州电子科技大学硕士学位论文

面向变电站运维的搬运机器人导航系统设计与实现

姓 名 任佳乐

指导教师 黄娜

二〇二七年五月

**A Thesis Submitted to
Hangzhou Dianzi University for the Degree of
Master**

**Design and Implementation of a
Navigation System for Substation
Operation and Maintenance Robots**

Author **Jiale Ren**

Supervisor **Na Huang**

May, 2027

原创性声明

申请学位论文与资料若有不实之处，本人承担一切相关责任。

论文作者签名: _____ 日期: _____ 年 _____ 月 _____ 日

学位论文使用授权说明

论文作者签名: _____ 日期: _____ 年 _____ 月 _____ 日

指导教师签名: _____ 日期: _____ 年 _____ 月 _____ 日

摘 要

变电站是电力系统运行维护中的关键节点，其内部存在高电压、强电磁干扰、设备密集、通道狭窄以及动态障碍物等复杂因素。传统人工巡检和辅助作业方式在安全性、实时性和作业效率方面存在一定局限，引入具备自主感知、定位建图和路径规划能力的移动机器人，是提升变电站运维智能化水平的重要途径。围绕变电站运维场景下机器人自主导航的实际需求，本文开展面向变电站运维的搬运机器人导航系统设计与实现研究。

首先，本文分析了变电站运维机器人的功能需求，设计了由传感器模块、中央控制模块、底层运动控制模块和电源模块组成的机器人硬件平台，并结合激光雷达、双目相机等传感器构建环境感知与导航系统框架。在此基础上，介绍了机器人导航所需的坐标系变换、点云聚类等基本理论，为后续环境感知、地图构建和路径规划提供统一的数据表达基础。

其次，针对机器人在复杂动态环境中对障碍物实时感知的需求，本文设计了基于深度图像和点云数据融合的轻量级障碍物检测与跟踪方法。该方法结合 U 深度图检测器和 DBSCAN 点云检测器的检测结果，通过包围盒匹配与融合提升障碍物检测的鲁棒性；同时引入基于特征的数据关联、恒加速度运动模型和点云投票策略，对动态障碍物进行状态估计与识别。在地图构建方面，本文采用局部占用栅格更新为规划器提供可更新的环境约束。

最后，面向变电站场景中的复杂障碍分布和实时避障需求，本文设计了全局参考引导与局部滚动优化相结合的分层路径规划方法。全局层采用目标偏向 RRT 生成二维拓扑可行参考路径，并结合直连检查、线段碰撞检测、超时处理和路径平滑后验校验提高工程可用性；局部层构建学习增强 MPC 规划器，在承接障碍物边界和动态状态估计结果的基础上，引入点级障碍表示、动态预测点流和学习型距离特征，生成满足运动约束、平滑约束和避障要求的局部轨迹。同时，本文设计 MPC 直接速度输出接口，将滚动优化得到的首个最优控制量转换为全向底盘可执行的速度指令。

关键词：变电站运维，移动机器人，自主导航，环境感知，路径规划

ABSTRACT

Substations are key nodes in the operation and maintenance of power systems. Their operating environments usually involve high voltage, strong electromagnetic interference, dense equipment layout, narrow passages, and dynamic obstacles. Traditional manual inspection and auxiliary operation methods have limitations in safety, real-time response, and operational efficiency. Introducing mobile robots with autonomous perception, localization, mapping, and path planning capabilities is therefore an important approach to improving the intelligence level of substation operation and maintenance. Focusing on the autonomous navigation requirements of robots in substation operation and maintenance scenarios, this thesis studies the design and implementation of a navigation system for a substation operation and maintenance robot.

First, this thesis analyzes the functional requirements of the robot and designs a hardware platform composed of a sensing module, a central control module, a low-level motion control module, and a power supply module. A navigation framework is then constructed using sensors such as LiDAR and binocular cameras. On this basis, coordinate transformation and point cloud clustering methods required for robot navigation are introduced, providing a unified data representation foundation for subsequent environment perception, mapping, and path planning.

Second, to meet the need for real-time obstacle perception in complex dynamic environments, this thesis designs a lightweight obstacle detection and tracking method based on the fusion of depth images and point cloud data. The method combines the results of a U-depth image detector and a DBSCAN point cloud detector, and improves detection robustness through bounding box matching and fusion. Feature-based data association, a constant-acceleration motion model, and a point cloud voting strategy are further introduced to estimate and identify dynamic obstacle states. For mapping, local occupancy grid updating is adopted to provide updatable environmental constraints for the planner.

Finally, for complex obstacle distributions and real-time collision avoidance in substations, this thesis develops a hierarchical planning method combining global reference guidance with local receding-horizon optimization. A goal-biased RRT is used at the global level to generate a topologically feasible two-dimensional reference path, together with direct-connection checking, segment collision detection, timeout handling, and post-

smoothing collision validation. At the local level, a learning-enhanced MPC planner incorporates point-level obstacle representations, predicted dynamic point flows, and learned distance features derived from obstacle boundaries and dynamic state estimates. The resulting trajectories account for motion, smoothness, and collision-avoidance requirements. The first optimal control action is mapped directly to executable omnidirectional chassis velocity commands through an MPC velocity-output interface.

Keywords: substation operation and maintenance, mobile robot, autonomous navigation, environment perception, path planning

目 录

摘 要.....	I
ABSTRACT.....	II
第 1 章 绪论	1
1.1 研究背景及意义	1
1.2 国内外研究现状	3
1.2.1 移动机器人环境感知研究现状	3
1.2.2 移动机器人路径规划研究现状	6
1.3 本文主要研究内容.....	8
第 2 章 机器人系统框架总体设计	9
2.1 机器人功能需求分析	9
2.2 机器人系统方案设计	9
2.3 机器人硬件平台架构	10
2.3.1 硬件选型	10
2.3.2 硬件结构连接	13
2.4 机器人软件系统架构	16
2.5 本章小结.....	17
第 3 章 多传感器标定与坐标变换基础	18
3.1 坐标系与空间变换基础	18
3.1.1 世界坐标系.....	18
3.1.2 雷达坐标系转换	19
3.1.3 相机坐标系转换	20
3.2 双目视觉成像模型与内参标定	20
3.2.1 针孔相机成像模型.....	21
3.2.2 镜头畸变模型	22
3.2.3 张正友标定法原理.....	23
3.2.4 双目深度相机内参标定实现.....	24
3.3 多传感器外参与静态坐标变换	25
3.3.1 外参标定问题概述.....	25
3.3.2 本文坐标系配置方案.....	26
3.3.3 TF 坐标变换树	27

3.4 深度图像到三维点云的转换	27
3.4.1 深度图像数据格式	28
3.4.2 深度图像反投影算法	28
3.4.3 点云的坐标系变换与发布	29
3.5 多传感器点云融合与局部体素地图	29
3.5.1 占据体素地图表示	29
3.5.2 分传感器差异化融合策略	30
3.5.3 时间衰减与地图更新	30
第 4 章 基于 FAST_LIO2 的激光里程计定位算法研究	32
4.1 引言	32
4.2 SLAM 方法架构及技术分类	33
4.2.1 基于滤波器的 SLAM	33
4.2.2 基于图优化的 SLAM	34
4.2.3 紧耦合激光-惯性 SLAM	34
4.3 FAST_LIO2 激光惯性里程计原理	34
4.3.1 状态变量与 IMU 传播模型	35
4.3.2 直接点到地图量测模型	36
4.3.3 基于 ikd-Tree 的增量地图维护	37
4.4 面向预建地图的 FAST_LIO2 定位与重定位方法	38
4.4.1 预建地图定位框架	38
4.4.2 预建地图加载与初始位姿对齐	39
4.4.3 地图约束下的在线定位更新	40
4.4.4 纯定位模式与混合建图模式	41
4.5 仿真实验与结果分析	41
4.5.1 仿真平台与实验设置	41
4.5.2 定位精度评估	43
4.5.3 初始对齐 (ICP) 有效性	45
4.5.4 实时性与计算开销	47
4.5.5 实验结果讨论	48
4.6 本章小结	49
第 5 章 运维机器人障碍检测与环境感知算法设计	50
5.1 引言	50
5.2 点云聚类算法基础	51

5.2.1 K-Means 聚类.....	51
5.2.2 DBSCAN 聚类	53
5.3 障碍物检测跟踪系统	54
5.3.1 三维障碍物检测器	55
5.3.2 障碍物关联跟踪	57
5.3.3 动态障碍物识别	60
5.4 局部地图构建策略.....	63
5.5 仿真实验验证	64
第 6 章 分层路径规划与学习增强局部避障方法	65
6.1 引言	65
6.2 全局参考路径生成与分层规划接口	66
6.2.1 二维 RRT 参考路径生成	66
6.2.2 目标偏向采样、碰撞检测与超时处理.....	66
6.2.3 路径后处理与局部规划接口	68
6.3 面向局部避障的学习增强 MPC 规划器	68
6.3.1 滚动优化框架与底盘运动模型	68
6.3.2 包络约束 MPC 的保守性分析.....	70
6.3.3 点级障碍表示与动态预测点流	72
6.3.4 神经网络编码器结构与点级特征生成.....	73
6.3.5 距离-分离方向编码器及离线训练.....	75
6.3.6 带误差补偿的优化模型与在线求解流程	77
6.3.7 在线求解与全向底盘速度输出	80
6.4 Gazebo 仿真实验.....	81
6.4.1 仿真平台与统一实验协议	81
6.4.2 静态障碍实验	82
6.4.3 混合动静态障碍实验.....	83
6.4.4 实时性与仿真结果分析规范.....	84
6.5 实物实验.....	84
6.5.1 实验平台与场景	84
6.5.2 L 型非凸障碍运行验证	85
6.5.3 复杂障碍环境运行展示与讨论	85
6.6 本章小结.....	86
第 7 章 总结与展望.....	87

7.1 工作总结	87
7.2 工作展望	88
致 谢	89
攻读硕士学位期间取得的成果	90

第 1 章 绪论

1.1 研究背景及意义

电力系统的安全稳定运行是国家经济发展与能源安全的基石。伴随着“碳达峰、碳中和”目标向纵深推进以及新型电力系统建设全面提速，电网结构与运行模式发生深刻变革，对作为电能转换与分配核心节点的变电站的智能化运维水平提出了前所未有的要求。然而，变电站内部环境充斥着高电压、强电磁场、密集金属构架、狭窄通道以及有害气体（六氟化硫）泄漏等固有风险因素，构成了一个作业难度大、安全风险高的典型工业场景。传统的、高度依赖人工完成的设备巡检^[2]、状态核查、开关操作、仪表记录及应急处置等核心运维任务，不仅效率面临瓶颈，更使运维人员长期暴露于触电、机械伤害、高空坠落等严重职业安全风险之中。这种高风险人工模式与国家不断提升的安全生产标准（国家能源局与原安监总局 2014 年联合发布并不断强化的《防止电力生产事故的二十五项重点要求》）形成了尖锐矛盾，亟需通过技术革新实现“机器换人、人机协同”，从本质上提升作业安全水平。

国家宏观战略层面对于解决上述难题、推动能源行业智能化升级的决心清晰而坚定。2022 年 3 月由国家发展改革委、国家能源局联合印发的《“十四五”现代能源体系规划》，将能源基础设施的智能化改造与数字化转型列为重点任务，明确要求“提升电网智能化水平，构建智慧能源系统”。更直接的指引来自于 2023 年 3 月国家能源局发布的《关于加快推进能源数字化智能化发展的若干意见》，该文件特别强调要“推动机器人^[2]、无人机等智能装备在电力巡检^[2]、设备操作、带电作业、应急救援^[2]等场景的规模化应用”，将智能作业装备的部署上升至行业发展的战略高度。同时，以 2015 年《中国制造 2025》为起点、后续《智能制造发展规划》《“十四五”机器人产业发展规划》以及 2023 年 1 月工业和信息化部等十七部门联合印发的《“机器人+”应用行动实施方案》共同构成的制造业升级政策体系，都将智能机器人定位为突破复杂环境应用的关键抓手，尤其强调在能源、电力等高安全要求领域深化“机器人+”应用，提升劳动生产率和作业安全性。政策红利的直接效应体现在电网企业的实际行动上：国家电网“数字赋能，提质增效”战略、南方电网公司 2020 年启动的“数字南网”蓝图，均斥巨资推进智能变电站建设，并将自主移动作业机器人视为实现“无人值守”目标不可或缺的技术支撑，为辅助作业机器人的研发与落地提供了强大的内在驱动力。

尽管固定式在线监测设备与无人机巡视^[2]已在变电站得到推广，为宏观状态

监控提供了有效补充，但它们对需要深度介入的精细作业任务表现出明显的局限性。例如，开关柜内部触头的烧蚀状况排查、设备连接点毫米级的松动检测、保护屏柜内密集指示灯的精确识别、高压设备的安全操作指令执行、复杂空间内的接地线辅助挂拆、故障设备现场状态的近场取证等核心环节，都要求作业主体具备在复杂物理环境与强电磁干扰下可靠感知、自主移动与精准执行的能力。当下部署的巡检机器人虽能执行既定路线的巡检任务，但在面对变电站这一独特“考场”时，其核心能力——特别是高鲁棒性的环境感知、复杂受限空间下的可靠导航定位^[2]、以及适应非结构化场景的动态规划与精细目标识别能力^[2]——仍显不足。技术瓶颈具体表现在：传感器系统（如激光雷达在强反射金属环境中、可见光相机在暗光/强光/视觉纹理缺失场景下）易受强电磁干扰和环境复杂性影响，导致感知数据失真、不稳定，难以构建对环境动态变化的可靠理解；在卫星定位信号缺失（室内或受遮挡区）且结构极其复杂（金属多径反射严重）的环境中，同时定位与地图构建（SLAM）^[2]的精度和鲁棒性面临严峻挑战，易出现定位漂移甚至失效；对变电站内大量存在的外观相似度高、排列密集、目标微小、易被部分遮挡的关键设备元件（如绝缘子串、线夹类型、特定仪表状态指示器）的检测与识别准确性，直接制约着后续操作的精度与安全性；而这些感知与定位的不确定性，进一步制约了机器人在狭窄、障碍物多变的通道内实现高效、安全自主通行的能力。

因此，聚焦于研发能够有效克服变电站严苛环境挑战、具备自主作业能力的智能辅助作业机器人，并将研究重心置于其核心使能技术——包括多源异构传感器（激光雷达、多光谱视觉、IMU、UWB 等）在强干扰环境下的深度融合^[2]与抗干扰处理方法、针对复杂结构化/半结构化室内外场景的无 GNSS 鲁棒导航与地图构建策略、融合环境语义信息^[2]的动态路径规划^[2]与精确避障机制、以及面向高相似度电力设备的高精度、高实时性目标检测与语义理解模型——不仅是对国家政策导向的积极响应，更是破解行业瓶颈、引领技术升级的必然选择。其价值首先体现在对电力安全生产本质性提升的贡献上，通过替代或辅助人工进入高风险区域执行任务，大幅降低甚至消除触电、机械伤害等事故风险，彻底落实“生命至上、本质安全”的法规要求。其次，在提升运行效率与经济效益方面，机器人的引入能够实现近乎全天候的自主监控^[2]与部分程序化操作，显著提高巡检覆盖面和频次，缩短设备停运窗口，提升响应速度，降低人力成本。尤其重要的是，基于其强大的感知能力提供的更精确、更丰富的实时数据，可为设备状态的精准评估和预测性维护提供坚实支撑，有效规避重大设备故障造成的直接经济损失与间接社会成本，推动变电站运维模式向智能化、无人化高级形态演进。再者，攻克变电站这一极具挑战性的应用场景，本身就是推动相关技术领域创新的催化剂。在

强干扰环境下实现多模态感知^[2]的有效融合、开发适应非结构化空间的鲁棒导航定位算法、构建适用于特定复杂工业目标的智能识别模型^[2]等突破，其技术外溢效应显著，可广泛应用于电厂、换流站、乃至石化、轨交等其他高危复杂工业环境的自动化作业中，助力国产高端智能装备自主创新能力的提升。最终，从支撑国家能源转型与发展战略的角度审视，变电站辅助作业机器人的成熟应用，是构建新型电力系统智能化、自动化运维体系的关键环节，为保障国家能源安全、推动能源生产消费革命、最终实现“双碳”宏伟目标提供了基础性的技术保障。

目前在国家政策的强效驱动下，结合电网企业智能化升级的现实需求与当前技术瓶颈的清晰认知，深入研究并系统解决变电站辅助作业机器人在环境感知^[2]、自主决策、安全运行方面的关键科学问题与技术难点，具有明确的应用紧迫性、显著的经济社会价值、重要的技术创新意义以及服务国家战略的深层内涵。

1.2 国内外研究现状

移动机器人感知与规划技术已发展成为现代智能系统的核心驱动力，其本质是构建一套从环境认知到行为决策的闭合智能环路。当前技术前沿正经历从分立模块化设计向多模态协同智能的系统性跃迁，其核心驱动力在于传感器硬件的颠覆性革新、跨域数据融合范式的重构，以及安全约束下自主决策能力的质变。对于变电站运维机器人来说，其工作的主要目的是在特定环境中，通过机器人搭载的传感器获取复杂环境信息，并基于环境信息进行环境感知与自主定位，最终实现自主导航并确保能够有效避开障碍物区域^[2]。由此可见，移动机器人控制的研究重点主要集中在环境感知和路径规划两个关键环节。在环境感知方面，主要依赖于传感器对周围环境进行探测和数据采集，随后采用特定的数据表示方法构建环境地图。这一过程不仅要求环境模型能够精确反映实际环境的空间特征，还需要具备对动态环境变化的实时更新能力。环境感知的有效性直接决定了机器人对环境信息的感知质量，而路径规划则是在此基础上，通过对环境模型的分析处理，确定需要访问的目标点位置，并实时规划避障策略，最终实现控制机器人安全平稳地到达目标点进行作业。基于上述分析，本节将从环境感知方法与路径规划方法两个维度，系统阐述当前相关领域的研究进展与现状。

1.2.1 移动机器人环境感知研究现状

随着自动驾驶与智能制造的发展，移动机器人环境感知技术正经历从单一传感器依赖向多模态智能融合的范式转换。国际研究核心聚焦于解决三大共性难题：动态复杂场景的实时建模、极端环境下的感知鲁棒性，以及海量数据的高效智能

处理。激光雷达作为三维空间感知的核心传感器，其技术演进呈现多线束与固态化并行路线。美国 Velodyne 公司 2025 年推出的 HDL-3600 固态激光雷达^[2]通过 MEMS 微振镜阵列将通道数提升至 360 线，角度分辨率达 0.05° ，并在强降雨条件下保持 80% 的有效点云捕获率，但成本高达 8000 美元，限制大规模商业化应用。与之对比，速腾聚创研发的 M3 平台采用转镜式方案，在保持 128 线性能的同时将价格压缩至 2000 美元级，已装配于菜鸟物流 AGV 集群，但其抗震性能较差，难以适应工程机械等高振动场景。毫米波雷达^[2]领域，德州仪器的 AWR2944 芯片集成 4 发 4 收 MIMO 架构，通过多普勒-角度联合估计^[2]技术将运动物体轨迹预测精度提升至 0.1m/s ，不过金属密集环境中的多径反射问题仍导致很高的虚警率。

可见光视觉感知在近年取得颠覆性突破。以色列 Mobileye 的 EyeQ6 芯片搭载神经拟态计算架构，利用事件相机^[2]毫秒级动态响应特性，在强逆光场景下仍能保持很高的车道线检测率，特斯拉 FSD V12 系统则采用纯视觉方案构建时空记忆网络^[2]，不再依赖于传统的高精地图和导航数据，而是完全依靠车载摄像头和神经网络来识别道路和交通情况，通过隐式神经表征实现无高精地图的厘米级定位并做出相应的决策，但这依赖超 2000 万公里真实路况训练的万亿参数模型，初创企业难以复制。国内旷视科技研发的软硬一体化方案“慧影”在低照度场景表现突出，联合优化 ISP 图像处理器与 Transformer^[2]网络，在低光照度下大幅提高了传统方法的行人检测召回率，该技术已用于美团无人配送车系列，然而在雨雾天气下识别性能仍会有巨大衰减。

环境感知数据处理创新呈算法与硬件协同演进态势。多传感器时空配准领域，为了在同步定位与地图构建（SLAM）任务中实现精确且鲁棒的位姿估计，Zhang^[2]等人提出了一种名为 FAST-LIVO 的快速激光雷达-惯性-视觉里程计系统，该系统基于两个紧密耦合且直接里程计子系统：一个视觉里程计子系统和一个激光雷达-惯性子系统。激光雷达-惯性子系统将新扫描的原始点注册到逐步构建的点云地图中，地图点附加了图像块，在视觉里程计子系统通过最小化直接光度误差来对齐新图像，而无需提取任何视觉特征。Nguyen 等人对于 VSLAM 框架提出了一种基于多个邻近姿态的“加权平均”的新型方法，在保持其定位精度的同时，计算从当前图像帧到先前邻近帧的相机姿态后，提供定位估计。利用相机运动引入了两种立体模式^[2]：“静态立体”模式（通过左右相机的固定基线设置）以及“时间多视图立体”模式。同时在尺度估计步骤中，将视差图限制为时间多视图立体模式内的内点，大大降低了计算成本。Cheng^[2]等提出了一用于实现高精度和鲁棒的车辆定位，在前端使用激光雷达点云获取视觉特征的深度信息，同步的惯性测量单元测量值以松散耦合的方式输入到姿态估计模块中。在后端提

出了两种关键策略来减少算法的计算量，平衡选择策略基于关键帧和滑动窗口算法^[2]，而分类优化策略基于特征点和姿态估计辅助。与 Fast-LIVO 算法相比，其算法在精度和鲁棒性方面均表现更优，且具有最佳实时性能。环境精确重建也是 SLAM 系统的核心目标。然而，智能体的轨迹会显著影响估计精度。阿根廷学者 Gimenez 提出了一种使用不确定性地图（UM）对主动 SLAM 系统中的地图不确定性进行建模的新方法。UM 利用概率分布来捕捉地图不确定性的空间分布，从而将不确定性前沿（UF）转化为关键勘探-开发目标和潜在停止的标准^[2]。与依赖于特定 SLAM 系统设置的方法不同，该方法可兼容不同类型的传感器，同时还解决了探索规划和停止条件中的常见问题，使智能体能够自主探索开阔空间。

针对动态目标处理，Li^[2] 等人使用具有丰富环境信息和深度信息的密集点云映射取代了传统的激光映射和稀疏点云映射，为了解决动态环境中运动物体的鬼影问题，引入 Mask R-CNN 来提取输入帧中的运动物体掩码。在定位精度满足要求后，提出了一种鲁棒的掩码截断符号距离函数模型，用于在动态室内环境中构建密集地图，通过体素的截断距离识别重置动态体素，然后更新密集点云映射。Andrey^[2] 等提出了一种提高动态环境下地面移动机器人视觉惯性里程计鲁棒性的新方法，通过交替因子图优化扩展了标准视觉惯性导航系统，并使用加权最小二乘^[2] 状态估计问题。同时，基于场景的语义先验知识建立了视觉地标的可靠性模型，在高动态环境下实现了稳定和准确的状态估计。为了解决动态场景中视觉同步定位与地图构建算法在相机位姿计算过程中常错误地包含动态点，导致精度和鲁棒性下降的问题，Yin^[2] 等提出了一种基于目标检测和区域动态概率的动态 SLAM 算法。采用 YOLOX 目标检测模型获取二维语义信息并补偿漏检。接着通过聚类算法自适应地确定提取动态对象轮廓作为动态点的阈值，将图像划分为低动态、可疑动态和高动态区域。在跟踪线程中，动态点移除模块为这些区域中的特征点分配动态概率权重。结合几何方法，检测并移除动态点。该动态 SLAM 算法超越了大多数现有 SLAM 算法，在动态环境中提供了更好的位姿估计精度和鲁棒性。在动态环境视觉同步定位与地图构建方面，Liu^[2] 等人提出了 RDMO-SLAM 方法，通过添加使用密集光流进行语义标签预测，能够在确保实时性的同时利用更多语义信息。同时估计每个地标的速度，使用其作为约束来减少动态物体在跟踪中的影响，该方法在保持动态场景中稳健跟踪的同时，将实时性能从 15Hz 提升至 30Hz。还有学者提出了一种通用的动态驾驶环境的参数化表示方法^[2]，该方法基于常见的占用栅格地图环境表示，通过交互式多模型无迹卡尔曼概率数据关联（IMM-UK-PDA）滤波器以基于对象的方式同时提取、分类和跟踪属于动态对象的单元，并将其从栅格中清除。剩余的静态环境栅格随后通过图像分析领域的方法

进行处理，然后通过基于信息滤波的自由空间边界轮廓跟踪创建时空平滑的紧凑参数化自由空间（PFS）地图，该方法具备紧凑性、静态与动态实体之间固有的协调性、无关细节的抑制，以及其传感器实时生成能力。

极端环境感知是近年攻关焦点。针对浓雾场景，卡耐基梅隆大学开发的 FogNet 网络融合透射率物理模型与深度学习，在能见度低于 10m 条件下将障碍物检出率提升至 84%。Paloma 等人提出了一种基于特征的 3D 映射方法，用于获取半结构化环境（如部分损毁的建筑）的紧凑模型，以便移动机器人在救援活动中使用。为了收集 3D 数据，采用安装在真实和模拟机器人上的摆动数据采集系统^[21]。采用的分割算法源于计算机视觉技术的集成，能够快速分离对应于不同表面的点，通过对每个区域内的点进行最小二乘拟合并提取几何特征，基于扩展卡尔曼滤波器^[21]的增量概率最大算法提供 6D 定位，并生成具有凸包表示的平面块地图。Xing^[21]等设计了一款配备尖端导航系统（激光雷达和雷达）以及新型气体探测能力（FireNose）的探索机器人，专为消防员定制，将传感器数据与实时二维地图相结合，通过传感器和数据处理方法的融合，提供清晰且用户友好的危险指示，形成全面的救援机器人，在消防领域具有不错的应用前景。对于只依靠视觉感知的移动机器人来说，在经典的视觉伺服范式中，非完整移动机器人的视觉控制变得具有挑战性，这主要是由于运动和能见度限制，这使得机器人无法在不丢失相机视野中的基本视觉信息的条件下，达到指定位姿。Crombez^[21]等提出一种新的深度强化学习框架来解决非完整移动机器人的视觉伺服问题，该框架集成了深度递归策略、内在动机和一种新的辅助任务，利用经典视觉伺服方法的核心交互矩阵来解决非完整机器人系统的基于视觉的控制问题。

随着相关产业技术的发展，移动机器人环境感知技术已从“单一器件性能提升”转入“系统级智能融合”阶段。这一变革的核心在于感知系统正逐步演化为具备自主协同决策能力的有机整体，当前前沿研究不再局限于传感器个体的抗扰性增强或分辨率突破，而是转向构建跨模态感知^[21]—边缘计算—场景认知闭环的综合技术生态。

1.2.2 移动机器人路径规划研究现状

移动机器人路径规划技术已从早期单一的静态环境避障，发展至当今动态复杂场景下的智能决策系统，其演进过程深刻反映了人工智能、控制理论及高性能计算的跨学科融合。在技术发展初期（2000-2010 年），基于图搜索的传统算法如 A*^[21]、Dijkstra^[21]主导了结构化环境中的路径求解，这些方法通过栅格化地图将连续空间离散化，虽能保证最优路径却受限于计算复杂度，难以应对实时性要求。随后采样式规划算法掀起革新浪潮：快速随机扩展树（RRT）及其优化版本 RRT*

通过概率采样突破维度灾难，将高维空间求解时间压缩一半以上。同期出现的人工势场法能实现毫秒级响应，却因局部极小点问题造成较高的规划失败率，凸显早期技术对环境动态性的适应不足。

环境复杂度的提升倒逼规划技术向多层级架构演进。2015年后出现的分层规划框架将任务解耦为全局路径生成与局部轨迹优化：全局层采用改进A*算法融合地形代价，结合运动学约束生成可达性路径；局部层则依赖模型预测控制（MPC）实现动态避障。研究人员提出利用模型预测控制在局部偏离规定的全局路径以响应动态环境^[71]，为了确保局部路径和全局路径之间的一致性，对于不同起点和终点的路径引入了本地同位路径的概念，通过制定一个硬约束来确保局部路径与给定的全局路径一致。真正推动质变的是安全约束理论的工程化应用——控制屏障函数^{[71][72]}（CBF）的提出，通过微分不等式构建安全空间，确保机器人轨迹始终满足速度、加速度等物理约束，该技术已成为当前安全标准的理论基石。

受自然界生物行为启发，诸如蚁群算法^[71]、遗传算法^[71]等智能进化算法也逐渐运用到路径规划中。Zhong^[71]等从果蝇行为中得到灵感，引入了一种新的采样器，该机制通过选择最佳采样候选策略或虚拟子目标点来优化双树采样过程。最优采样候选策略在三维空间进行全局采样，有效减少采样时间，虚拟子目标点加速了双树连接过程，增强了方向引导。使用果蝇机制重建了路径，从而降低了无人机路径成本。同时还提出利用Halton序列代替伪随机序列，从根本上解决了RRT方法中的欠采样和过采样问题。受蛇类捕食行为启发，研究人员提出了蛇优化算法。原始SO在种群多样性和搜索精度方面仍存在不足，容易陷入局部最优。为此，研究人员又提出了改进蛇优化算法^[71]（ISO），通过引入三种全新的增强策略，显著提升算法性能。ISO模拟了蛇类在自然环境中应对捕食与生存压力的多样化行为：初始化阶段采用多策略混沌系统，增强个体初始分布的随机性与均匀性；探索阶段融合反捕食者策略，拓展搜索范围，提高收敛速度与精度；开发阶段引入双向种群进化动态，保持种群多样性，强化全局搜索能力与局部开发能力的平衡。

与此同时，深度学习驱动的方法开辟了新路径：端到端强化学习在仿真环境中训练策略网络。Lai等为解决移动机器人轨迹规划的问题提出了一种强化学习范式，将隐式策略与Lyapunov理论相结合^[71]，开发了一个加权不对称的Lyapunov奖励函数，并提供了一个以适度动力学作为隐含策略的解析解，提出了事件触发的多目标策略优化。这是一种根据事件触发条件动态调整优化目标的方法，缩小了探索空间，实现了RL策略的迭代改进。Fu等提出了一种危险感知机器人导航算法^[71]，通过定义行人的危险并引入有关参考路径的虚拟机器人。该算法的主要新颖之处在于，利用虚拟机器人来获得额外的动作和更多的采样航点，以追求机

机器人运动的平滑性和前瞻性。并且建立优先机制并将其纳入深度强化学习导航,以提高机器人导航的安全性。Ho^[2]等提出了一种强化学习路径规划方法用于智能仓库或智能工厂内自动导引车的实时路径规划。与难以适应动态运营变化的传统路径规划方法不同,该算法集成了实时信息,以实现响应迅速且灵活的路径决策。通过将移动机器人路径规划和强化学习集成到动态环境中,例如包含各种工作站、充电站和存储位置的智能仓库。在处理复杂的物流和运营环境方面展现出了高效性。

当前路径规划技术瓶颈主要体现在两个方面:1、复杂动态环境中的长程规划容易陷入计算泥沼;2、多目标优化存在根本性矛盾。为了逐步解决上述问题,研究人员在过去几年做出了不懈努力。针对复杂和狭窄的工作空间,Yin^[2]等对协作路径规划问题提出了一种改进的多任务约束多目标优化。采用具有动态约束松弛和混合差分进化算子的多任务协同进化框架。同时优化主辅任务,平衡全局勘探和本地开发。采用多涡叠加模型量化环境干扰,构建无人驾驶车辆路径规划模型,结合任务协作效率、威胁风险成本和能耗目标。Jihoon等提出了一种用于室内搜救作业的多级路径规划系统^[2],对路径规划系统的要求是基于集成室内导航系统的作业概念得出的。提出了一个五步路径规划系统,该系统由地图预处理、路段路径规划、图形处理、路线优化和路径后处理组成,通过采用基于图的方法,以计算高效的方式解决了多层建筑中的多目标路径规划问题,同时满足预处理和后处理步骤中的间隙条件等要求。

综上所述,移动机器人路径规划是一个涉及多方面优化技术的问题,针对不同的任务需求需进行特定优化。随着技术不断的发展,越来越多的跨学科知识被广泛应用于路径规划的研究当中,并取得了一定的研究进展。以上研究在实际的应用中仍存在计算量大、规划效率低或部署成本过高等问题。未来的研究应着重于提高路径的搜索效率和路径质量,降低算法部署成本。同时提高算法的鲁棒性,特别是在动态复杂环境中的应用。

1.3 本文主要研究内容

第 2 章 机器人系统框架总体设计

2.1 机器人功能需求分析

对于面向变电站辅助作业的运维机器人，为满足其特殊应用场景对可靠性、高性能的综合要求结合其工作内容，要求机器人具备以下功能：（1）具备环境感知模块，可通过传感器与周围环境进行信息交互，感知自身作业环境；（2）具备实时处理复杂空间信息的能力，实现高精度环境地图构建，以及在动态环境中的厘米级自我定位。（3）具备基于先验地图自主导航模块，导航过程中能够自主规划出从当前位置到目标点的最优全局路径。（4）具备任务执行过程中的未知障碍物规避能力，即在遵循全局路径的同时，实时感知并绕开未预见的障碍，并在必要时触发路径重规划机制以应对复杂的突发状况。

2.2 机器人系统方案设计

针对第 2.1 节提出的环境感知、定位建图、自主导航与动态避障四项功能需求，本文采用“感知-决策-执行”的分层模块化方案设计运维机器人系统。整体方案在逻辑上划分为感知层、决策层和执行层三个层次，在物理上对应传感器模块、中央控制模块、底层运动控制模块和电源模块四类硬件，并以中央控制模块为核心实现各层之间的数据流转与指令下发。系统总体方案如图 2-1 所示。

感知层位于系统底端，负责将物理环境转化为可计算的数字信息。该层由 3D 激光雷达、双目相机及雷达内置惯性测量单元（IMU）构成：激光雷达提供周围环境的三维点云，用于定位建图与障碍物几何提取；双目相机提供 RGB 图像与深度图像，用于工作目标识别与近场障碍感知；IMU 提供高频角速度和加速度测量，为激光惯性里程计提供运动预测。各传感器以统一时间基准采集数据，经标准接口上传至中央控制模块。

决策层是系统的运算核心，由搭载高性能嵌入式计算平台的中央控制模块承担。该层订阅感知层上传的多源数据，依次完成激光惯性定位与地图构建、动态障碍物检测与跟踪、全局路径规划与局部滚动优化等任务，最终解算出满足运动学约束与避障要求的速度指令。考虑到激光点云配准、障碍物检测和模型预测控制等算法对算力的较高要求，决策层选用具备 GPU 并行加速能力的边缘计算平台，以保证导航算法的实时性。

执行层位于系统顶端，负责将决策层输出的速度指令转化为机器人的实际运动。该层由伺服驱动器、驱动电机和转向电机组成，通过 CAN 总线接收速度或位




图 2-1 机器人系统总体方案

姿指令，驱动底盘按期望线速度和角速度运动，并将编码器反馈的实时转速、转角回传至中央控制模块，形成闭环控制。电源模块为上述各层提供稳定的多路供电，是系统持续可靠运行的能量基础。

上述分层方案使各模块职责清晰、接口规范，便于功能扩展与故障定位。下文将分别从硬件平台架构和软件系统架构两方面，对该方案的具体实现进行详细说明。

2.3 机器人硬件平台架构

2.3.1 硬件选型

机器人硬件结构包括传感器模块、中央控制模块、底层运动控制模块以及移动电源。传感器模块负责采集环境信息发送给中央控制器；中央控制器处理传感器数据，计算出机器人运动控制指令并发送给底层运动控制模块；底层电机和舵机接受控制指令驱动机器人一定速度运动或变换到指定位姿。

2.3.1.1 传感器模块

传感器模块包括两部分：激光雷达和双目摄像头。3D 激光雷达选用大疆览沃的 MID-360，该激光雷达是 4 线束非重复扫描固态激光雷达，由于体积小、重量

轻、视场较大、分辨率较高，因此被广泛部署使用在机器人、割草机、无人车、工业和教育等智能产品中。内部集成了 IMU 芯片（3 轴加速度计和 3 轴陀螺仪），可结合点云数据构建高精地图并实现自主定位过程中的雷达坐标系、机器人坐标系、世界坐标系三者之间的转换关系。激光雷达具体尺寸图如图 2-2 所示，其性能参数如表 2-1 所示。




图 2-2 激光雷达具体尺寸

图像采集模块包含两个双目摄像头，选用奥比中光公司的 Gemini335L 型号的摄像头，输出深度图像和 RGB 图像。可用于目标检测、距离检测以及 3D 环境构建，本课题中双目摄像头主要用于移动机器人移动过程中对工作目标的识别。双目摄像头参数见表 2-2 所示。

2.3.1.2 中央控制模块

中央控制模块是机器人系统的运算核心，需在有限的体积和功耗下同时承担激光惯性定位、点云处理、障碍物检测跟踪以及模型预测控制等计算密集型任务。综合考虑算力、接口丰富度、工业级可靠性和嵌入式部署要求，本文选用研华（Advantech）公司的 MIC-733 边缘 AI 推理计算机作为中央控制模块。该计算机以 NVIDIA Jetson AGX Orin 微型计算机为核心，集成 Arm 架构 CPU 与 Ampere 架构 GPU，具备强大的并行计算与深度学习推理能力，可满足点云配准和滚动优化的实时性需求。同时，其工业级设计支持宽温、宽压工作，适应变电站等复杂工业环境。MIC-733 的主要性能参数如表 2-3 所示。

MIC-733 提供 4 个千兆以太网口，其中一个用于连接 MID-360 激光雷达并支持 PTP 时间同步，保证点云与 IMU 数据的时间一致性；USB 3.2 接口用于连接

表 2-1 MID360 激光雷达性能参数

项目	最小值	典型值	最大值	单位	备注
测距范围	0.1	10	40	m	100klux 照度
测距精度	-	± 5	-	cm	90% 反射率
水平视场角	-	360	-	°	全向扫描
垂直视场角	-7.0	-	52.0	°	-
扫描模式	-	非重复扫描	-	-	-
虚警率	-	<0.01%	-	-	100klux 照度
工作温度	-20	-	55	°C	-
工作电压	9	-	27	V DC	-
功耗	-	11	-	W	典型功耗
网络接口	-	千兆以太网	-	-	支持 PTP、PPS

双目相机，传输 RGB 与深度图像。由于底层伺服驱动器采用 CAN 总线通信，而 Jetson 平台默认不提供工业级 CAN 接口，本文通过其 Mini PCIe 扩展槽加装研华 PCM-26D2CA 双口隔离 CAN 扩展卡，该卡提供 2 路隔离 CAN 总线接口（DB9 接插件），支持总线终端电阻跳线配置，从而实现中央控制模块与伺服驱动器之间的可靠通信。

2.3.1.3 底层运动控制模块

底层运动控制模块负责将中央控制模块输出的速度指令转化为底盘的实际运动。为满足运维机器人在变电站狭窄通道、设备密集区域灵活移动以及负载搬运的需求，底盘采用全向移动方案，选用凤凰动力（Phoenix Power）公司的 PH210DS-A3-008-15 卧式舵轮作为驱动与转向一体化执行单元。该舵轮将行走电机与转向电机集成于同一模块，行走部分负责提供前进驱动力，转向部分负责调整轮系朝向，二者协同实现底盘的全向运动。舵轮的主要参数如表 2-4 所示。

舵轮的行走电机与转向电机均为交流伺服电机，需配套伺服驱动器进行闭环控制。行走电机额定功率 1100W、额定电流 25A，转向电机额定功率 400W、额定电流 10A，二者功率与电流等级差异较大。为此，本文针对不同电机分别选配伺服驱动器：行走电机选用凤凰动力 PLD2L-CAN 系列驱动器，转向电机选用步科（Kinco）FD1X5 系列驱动器。两类驱动器均支持 CANopen（CiA DSP402）总线协议，可与中央控制模块的 CAN 扩展卡组网通信，并支持位置、速度、转矩多种控

表 2-2 双目摄像头 Gemini335L 性能参数

规格参数	数值
最大工作范围	0.17-20m
推荐工作范围	0.25-6m
基线	95mm
视场角	90°×65° @ 2m (1280×800)
分辨率	1280×800 @ 60fps
供电建议	DC 5V & $\geq 1.5A$
平均功耗	< 3W
工作温度	-10-50°C

制模式。两款伺服驱动器的主要参数对比如表 2-5 所示。

工作时，中央控制模块将解算得到的底盘速度指令分解为各舵轮的行走速度和转向角度，经 CAN 总线下发至对应伺服驱动器；驱动器驱动电机运动，并将编码器测得的实时转速、转角通过 CAN 总线回传，实现速度与位置的闭环控制。转向部分采用 17bit 绝对值编码器，可在上电时直接获取绝对转角，无需回零操作，提高了系统启动效率与定位精度。

2.3.1.4 电源模块

电源模块为机器人各功能单元提供稳定可靠的电能。系统内不同部件的供电需求各异：舵轮行走与转向电机需 48V 直流供电，制动器与驱动器逻辑电路需 24V 直流供电，中央控制模块支持 9~36V 宽压输入，激光雷达需 9~27V 直流供电，双目相机需 5V 直流供电。为统一管理上述多路供电，本文采用以 48V 锂电池组为主电源、配合多路 DC-DC 变换的供电架构：48V 母线直接为舵轮电机供电，并经 DC-DC 降压模块分别转换为 24V、12V 和 5V，为驱动器逻辑、工控机、激光雷达和相机等部件供电。各供电支路独立布线并设置过流、过压保护，避免电机启停时的电流冲击影响控制与感知系统的稳定运行。

2.3.2 硬件结构连接

在完成各功能模块选型的基础上，本节阐述机器人硬件各部件之间的物理连接与信号交互关系，整体硬件连接拓扑如图 2-3 所示。系统以 MIC-733 中央控制模块为核心，向上通过标准数据接口连接感知设备，向下通过 CAN 总线连接执行设

表 2-3 MIC-733 中央控制器主要性能参数

规格参数	数值
核心模块	NVIDIA Jetson AGX Orin
内存	32GB / 64GB LPDDR5
存储	64GB eMMC 5.1，支持 M.2 2280 NVMe 扩展
网络接口	4 × 10/100/1000 Mbps 千兆以太网
USB 接口	2 × USB 2.0，4 × USB 3.2 Gen 2
串口	2 × RS-232/RS-422/RS-485
扩展接口	2 × Mini PCIe，1 × iDoor
供电类型	AT/ATX，DC 9~36V
工作温度	0 ~ +60℃
尺寸 / 重量	192 × 230 × 87 mm / 4.5 kg

备，形成”传感器—控制器—驱动器—电机”的完整信号链路。




图 2-3 机器人硬件连接拓扑

在感知数据链路上，MID-360 激光雷达通过千兆以太网接入 MIC-733 的 LAN 口，利用 PTP/PPS 实现与系统时钟的硬件同步；双目相机通过 USB 3.2 接口连接工控机，传输 RGB 与深度图像数据。在控制指令链路上，工控机经 Mini PCIe 扩

表 2-4 PH210DS 卧式舵轮主要参数

部件	参数	数值	单位
行走部分	额定电压	48	V DC
	额定功率	1100	W
	额定扭矩 / 峰值扭矩	4.2 / 12.6	N·m
	额定转速 / 额定电流	2500 / 25	rpm / A
	驱动轮径 / 速比	210 / 24.685	mm / —
	编码器	增量式 2500ppr	—
转向部分	额定电压	48	V DC
	额定功率	400	W
	额定扭矩 / 峰值扭矩	1.27 / 3.81	N·m
	最大转向速度	81.82	°/s
	编码器	17bit 绝对值	—
整机	驱动轮载荷	800	kg
	机械限位 / 电子限位	±135 / ±125	°
	制动器电压 / 扭矩	24 / 6	V DC / N·m
	防护等级	IP65	—

表 2-5 伺服驱动器主要参数对比

参数	凤凰 PLD2L-CAN	步科 FD1X5
适配电机	行走电机（1100W）	转向电机（400W）
主电源电压	24 ~ 70V DC	24 ~ 60V DC
额定输出电流	5 ~ 30 Arms（分档）	15 / 30 / 50 Arms（分档）
控制方式	SVPWM 正弦波控制	矢量控制
总线协议	CANopen (DSP402)	CAN / Modbus / EtherCAT
控制模式	位置 / 速度 / 转矩	位置 / 速度 / 转矩
反馈信号	多摩川协议编码器	多摩川协议编码器
抱闸输出	支持（直接驱动）	支持（24V 直接驱动）

展的 PCM-26D2CA 双口 CAN 卡引出两路隔离 CAN 总线，分别连接行走电机驱动器（凤凰 PLD2L-CAN）和转向电机驱动器（步科 FD1X5）。CAN 总线采用主从结构，工控机作为主站周期性下发速度与位置指令，驱动器作为从站执行指令并反馈电机状态，总线终端按规范配置 120Ω 终端电阻以保证通信质量。在能量供给链路上，48V 锂电池组经配电单元和 DC-DC 变换为各部件分配相应电压等级的电源。通过上述连接方式，各模块在统一的硬件框架下协同工作，为软件系统的运行提供物理基础。

2.4 机器人软件系统架构

机器人软件系统基于机器人操作系统（Robot Operating System, ROS）构建，运行于 Ubuntu 20.04 操作系统与 ROS Noetic 发行版之上。ROS 采用分布式节点架构，各功能模块以独立节点（Node）形式运行，节点之间通过话题（Topic）、服务（Service）和动作（Action）等机制进行消息通信，并借助参数服务器和坐标变换（TF）工具统一管理系统参数与多坐标系关系。这种松耦合的设计使感知、定位、规划和控制等模块能够独立开发、测试与替换，便于系统的迭代与维护。机器人软件系统总体架构如图 2-4 所示，自下而上可划分为传感器驱动层、感知与定位层、规划决策层和运动控制层四个层次。




图 2-4 机器人软件系统架构

传感器驱动层负责采集并发布原始传感器数据。激光雷达驱动节点发布三维点云与 IMU 数据，相机驱动节点发布 RGB 图像与深度图像，各驱动节点将

数据封装为标准 ROS 消息（如 `sensor_msgs/PointCloud2`、`sensor_msgs/Image`、`sensor_msgs/Imu`）并以话题形式向上层发布，为后续处理提供统一的数据输入。

感知与定位层是环境理解的核心。该层包含激光惯性定位建图节点和障碍物检测跟踪节点：前者基于 FAST_LIO2 算法融合点云与 IMU 数据，在预建地图坐标系下输出机器人的全局位姿与里程计信息；后者融合深度图像与点云数据，检测并跟踪环境中的静态与动态障碍物，输出障碍物包围盒与状态估计结果，同时维护局部占用栅格地图。该层输出的位姿、地图和障碍信息为规划决策提供环境约束。

规划决策层根据导航任务和环境信息生成运动轨迹。全局规划节点基于预建地图和目标点，采用 RRT 算法生成全局参考路径；局部规划节点以全局路径为参考，融合实时障碍信息，通过学习增强 MPC 在滚动时域内求解满足运动学约束、平滑约束和避障要求的局部轨迹，并输出底盘速度指令。

运动控制层负责将速度指令转化为电机执行动作。运动控制节点将规划层输出的底盘速度指令分解为各舵轮的行走速度与转向角度，通过 CAN 总线接口节点按 CANopen 协议下发至伺服驱动器，并接收编码器反馈，实现底盘运动的闭环控制。

上述四层结构与硬件平台一一对应，数据自下而上逐层抽象、指令自上而下逐层细化，共同构成功能完整、层次清晰的机器人导航软件系统。

2.5 本章小结

本章面向变电站运维机器人的应用需求，完成了机器人系统框架的总体设计。首先，结合变电站高安全性、高可靠性和复杂空间约束的特点，分析了机器人在环境感知、定位建图、自主导航和动态避障四个方面的功能需求。其次，提出了“感知-决策-执行”的分层模块化系统方案，明确了传感器模块、中央控制模块、底层运动控制模块和电源模块的职责划分与协作关系。在此基础上，完成了硬件平台选型：感知模块选用 MID-360 激光雷达和 Gemini335L 双目相机，中央控制模块选用基于 NVIDIA Jetson AGX Orin 的研华 MIC-733 计算机并扩展 CAN 接口，底层运动控制模块选用凤凰动力 PH210DS 卧式舵轮，并分别为行走电机和转向电机配套凤凰 PLD2L-CAN 和步科 FD1X5 伺服驱动器，电源模块采用 48V 锂电池配合多路 DC-DC 变换的供电架构。随后，阐述了各部件之间的硬件连接拓扑与信号交互关系。最后，基于 ROS 设计了由传感器驱动层、感知与定位层、规划决策层和运动控制层构成的软件系统架构。本章设计的软硬件框架为后续各章的定位、感知与路径规划算法研究提供了统一的实现平台。

第3章 多传感器标定与坐标变换基础

变电站运维机器人搭载激光雷达、双目深度相机和惯性测量单元等多类传感器，各传感器安装位置不同、成像原理各异，其原始数据分布在互不相同的坐标系中。要将这些异构观测融合到统一的空间基准下，供后续定位建图、障碍物检测和路径规划使用，必须先解决两个基础问题：一是明确各坐标系的定义及其相互变换关系，二是通过标定确定传感器的成像参数与安装位姿。本章围绕这两个问题展开：首先介绍机器人导航涉及的坐标系及其齐次变换关系，为多源数据的空间统一提供数学工具；随后以双目深度相机为对象，阐述针孔成像模型、镜头畸变模型与张正友标定法原理，并给出本文相机平台的内参标定实现，为深度图像转点云等后续处理奠定基础。

3.1 坐标系与空间变换基础

在机器人设备上需要根据实际需求在不同位置安装不同类型的传感器。在机器人导航过程中，需要快速将不同传感器采集的数据在相同的坐标系统下进行处理，在机器人导航控制中，需将机器人在本地坐标系中的位置映射到世界坐标系，将雷达采集到的点云映射到世界坐标系，方便进行机器人运动轨迹的规划；在视觉目标检测中，需要将相机坐标系中的位置转换到世界坐标系中。为了实现不同设备及系统之间数据交互、协同工作，本节使用 $\mathcal{F}_w$ 、 $\mathcal{F}_b$ 、 $\mathcal{F}_l$ 、 $\mathcal{F}_c$ 分别表示世界坐标系、机器人基坐标系、雷达坐标系和相机坐标系，以下详细说明了世界坐标系、雷达坐标系、相机坐标系之间的转换关系。

3.1.1 世界坐标系

世界坐标系又称全局坐标系，是整个机器人系统的参考坐标系。在 ROS 机器人操作系统中采用右手坐标系，如图 3-1：

右手坐标系遵循右手定则，当右手食指、中指和大拇指相互垂直时，规定食指指向 X 轴正方向，中指则指向 Y 轴正方向，大拇指指向 Z 轴正方向。在机器人二维平面导航中，X 轴通常表示机器人前进的方向，Y 轴表示机器人的左侧方向，Z 轴垂直向上。若在三维场景中，这三个轴则用于描述机器人在空间中的位置和姿态。世界坐标系的规定为机器人提供了全局的定位与导航基础，它是一个全局固定的坐标系，在机器人整个运动过程中其原点和坐标轴方向保持不变，为机器人在环境中的位置和姿态提供了统一的参考标准，为后续机器人能够在全局范围




图 3-1 右手坐标系

内进行定位、导航和地图构建提供基础。

3.1.2 雷达坐标系转换

在机器人导航过程中，需要将雷达坐标系下的数据转换为世界坐标系下的数据，具体转换过程为：

$$\tilde{P}_w = T_w^b \cdot T_b^l \cdot \tilde{P}_l \quad (3-1)$$

上式中， $\tilde{P}_l = [x, y, z, 1]^T$ 表示雷达坐标系下的点的齐次坐标， $\tilde{P}_w$ 表示世界坐标系下的雷达点的齐次坐标。 $T_w^b \in SE(3)$ 为动态刚体变换，表征机器人基坐标系 $\mathcal{F}_b$ 在世界坐标系 $\mathcal{F}_w$ 下的实时位姿， $T_b^l \in SE(3)$ 为静态刚体变换，描述雷达相对于机器人基坐标系 $\mathcal{F}_b$ 的固定安装位姿，其形式为：

$$T_b^l = \begin{bmatrix} R_b^l & t_b^l \\ 0_{1 \times 3} & 1 \end{bmatrix} \quad (3-2)$$

这里， $R_b^l \in SE(3)$ 是旋转矩阵， $t_b^l \in R^3$ 是平移向量，二者描述雷达相对机器人地盘的安装位姿。雷达传感器坐标系 $\mathcal{F}_l$ 的坐标轴定义通常与机器人机体坐标系和世界坐标系保持一致，均遵循右手法则：X 轴指向前方，Y 轴指向左方，Z 轴指向上方。因此，其静态变换主要包含安装位置偏移，旋转部分通常近似为单位矩

阵 $\mathbf{I}$ ，则上式可改写为：

$$T_b^s = \begin{bmatrix} \mathbf{I} & t_b^l \\ 0_{1 \times 3} & 1 \end{bmatrix} \quad (3-3)$$

3.1.3 相机坐标系转换

相机模型涉及两个关键坐标系：物理安装坐标系 $\mathcal{F}_c$ 和 光学坐标系 $\mathcal{F}_o$ 。原始图像数据及深度信息定义在光学坐标系 $\mathcal{F}_c$ 下，其遵循计算机视觉惯例：Z 轴沿光轴指向相机前方，X 轴指向图像右侧，Y 轴指向图像下方。该定义与相机坐标系和世界坐标系均不同。因此，转换过程包含一个额外的、固定的旋转变换矩阵来对齐坐标轴定义。一个在光学坐标系下的点 P_o 的完整转换公式为：

$$\tilde{P}_w = T_w^b \cdot T_b^c \cdot \begin{bmatrix} R_c^o & 0 \\ 0 & 1 \end{bmatrix} \cdot \tilde{P}_o \quad (3-4)$$

其中， $\tilde{P}_o$ 和 $\tilde{P}_w$ 分别表示光学坐标系下和世界坐标系下点的其次坐标。与雷达坐标变换类似， T_b^c 是相机物理本体相对于机器人基座的安装变换；与雷达变换不同的是，多了一个旋转变换 R_c^o 将点从光学坐标系 $\mathcal{F}_o$ 旋转至相机物理坐标系 $\mathcal{F}_c$ ，其值固定为：

$$R_c^o = \begin{bmatrix} 0 & 0 & 1 \\ -1 & 0 & 0 \\ 0 & -1 & 0 \end{bmatrix} \quad (3-5)$$

等价于先绕原 X 轴旋转 -90° ，再绕新 Y 轴旋转 90° 的复合旋转。

3.2 双目视觉成像模型与内参标定

上一节给出了相机坐标系与世界坐标系之间的刚体变换关系，但要将相机采集的二维图像与三维空间点建立联系，还需引入相机的成像模型，并通过标定确定模型中的内部参数。本文选用的 Gemini335L 双目深度相机由左右两个红外相机和一个 RGB 相机组成，其深度图像在左红外相机坐标系下生成。深度图像转点云、视觉目标测距等处理均依赖准确的相机内参。本节首先介绍针孔相机成像模型和镜头畸变模型，随后阐述张正友标定法的基本原理，最后给出本文双目深度相机的内参标定实现与结果。

3.2.1 针孔相机成像模型

针孔相机模型是描述三维空间点如何投影到二维图像平面的经典几何模型，它将复杂的透镜成像过程简化为光线经过单一光心的理想投影。如图 3-2 所示，设相机坐标系 $\mathcal{F}_c$ 的原点位于光心 O_c ， Z_c 轴沿光轴指向相机前方， X_c 、 Y_c 轴分别与图像的行、列方向对齐。空间中任意一点 P 在相机坐标系下的坐标为 (X_c, Y_c, Z_c) ，其与光心的连线交成像平面于像点 p 。




图 3-2 针孔相机成像模型

根据相似三角形关系，空间点 P 在归一化成像平面 ($Z_c = 1$) 上的投影坐标为 $(X_c/Z_c, Y_c/Z_c)$ 。考虑焦距 f 与像素物理尺寸后，投影点在像素坐标系下的坐标 (u, v) 可由下式给出：

$$Z_c \begin{bmatrix} u \\ v \\ 1 \end{bmatrix} = \begin{bmatrix} f_x & 0 & c_x \\ 0 & f_y & c_y \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} X_c \\ Y_c \\ Z_c \end{bmatrix} = K \begin{bmatrix} X_c \\ Y_c \\ Z_c \end{bmatrix}, \quad (3-6)$$

其中 K 称为相机内参矩阵， f_x 、 f_y 为以像素为单位的等效焦距（等于物理焦距与像素在 u 、 v 方向物理尺寸之比）， c_x 、 c_y 为主点坐标，即光轴与成像平面交点在像素坐标系下的位置。内参矩阵 K 仅由相机自身光学结构决定，与相机在空间中的位姿无关，因此可以通过离线标定一次性确定。

式 (3-6) 描述的是理想针孔投影，其逆过程即由像素坐标和深度值反求空间点：给定像点 (u, v) 及其对应深度 Z_c ，可由内参矩阵反投影得到该点在相机坐标系下

的三维坐标

$$X_c = \frac{(u - c_x)Z_c}{f_x}, \quad Y_c = \frac{(v - c_y)Z_c}{f_y}, \quad Z_c = Z_c. \quad (3-7)$$

式 (3-7) 正是深度图像转点云的理论基础，其精度直接依赖于内参 f_x 、 f_y 、 c_x 、 c_y 的标定质量。

3.2.2 镜头畸变模型

理想针孔模型假设光线严格沿直线经过光心，但实际相机采用透镜组成像，透镜的加工误差和装配偏差会使成像光线偏离理想路径，导致图像产生几何畸变。畸变主要分为径向畸变和切向畸变两类。

径向畸变由透镜表面曲率误差引起，表现为图像点沿径向方向偏离理想位置，越靠近图像边缘偏差越大，直观上使直线在图像边缘发生弯曲，形成桶形畸变或枕形畸变。切向畸变由透镜与成像平面不严格平行（装配偏心）引起，使图像点沿切向方向发生偏移。图 3-3 以规则网格为例，直观展示了理想无畸变、径向畸变和切向畸变三种情形下的成像效果。




图 3-3 镜头畸变示意图

设归一化成像平面上的理想坐标为 (x, y) ，其到主点的径向距离为 $r^2 = x^2 + y^2$ 。采用 Brown-Conrady 模型^[7]，畸变后的坐标 (x_d, y_d) 可表示为

$$\begin{aligned} x_d &= x \underbrace{(1 + k_1 r^2 + k_2 r^4 + k_3 r^6)}_{\text{径向畸变}} + \underbrace{2p_1 xy + p_2(r^2 + 2x^2)}_{\text{切向畸变}}, \\ y_d &= y(1 + k_1 r^2 + k_2 r^4 + k_3 r^6) + p_1(r^2 + 2y^2) + 2p_2 xy, \end{aligned} \quad (3-8)$$

其中 k_1 、 k_2 、 k_3 为径向畸变系数， p_1 、 p_2 为切向畸变系数。对于本文使用的普通视场相机，径向畸变以低阶项为主，通常取 k_1 、 k_2 ，并保留 p_1 、 p_2 即可满足精度要求，即畸变系数向量为 $D = [k_1, k_2, p_1, p_2]$ 。将畸变后的归一化坐标 (x_d, y_d) 代入

式 (3-6) 的内参映射，即可得到实际成像的像素坐标。因此，完整的相机标定需要同时求解内参矩阵 K 和畸变系数 D 。

3.2.3 张正友标定法原理

相机标定的目标是由若干组已知的空间点与其对应像素点，反求内参矩阵 K 和畸变系数 D 。张正友于 2000 年提出的平面标定法^[9] 因其只需一张平面棋盘格标定板、操作灵活且精度较高，成为目前应用最广泛的相机标定方法，本文即采用该方法完成相机内参标定。

该方法的核心思想是利用平面标定板提供的已知几何约束。将棋盘格所在平面设为世界坐标系的 $Z = 0$ 平面，则平面上任意角点的世界坐标可写为 $(X, Y, 0)$ 。此时空间点到像素点的映射退化为一个平面到平面的单应性变换：

$$s \begin{bmatrix} u \\ v \\ 1 \end{bmatrix} = K \begin{bmatrix} \mathbf{r}_1 & \mathbf{r}_2 & \mathbf{t} \end{bmatrix} \begin{bmatrix} X \\ Y \\ 1 \end{bmatrix} = H \begin{bmatrix} X \\ Y \\ 1 \end{bmatrix}, \quad (3-9)$$

其中 $\mathbf{r}_1$ 、 $\mathbf{r}_2$ 为旋转矩阵的前两列， $\mathbf{t}$ 为平移向量， s 为尺度因子， $H = K[\mathbf{r}_1 \ \mathbf{r}_2 \ \mathbf{t}]$ 即为 3×3 的单应性矩阵。对于每张标定图像，可由检测到的角点世界坐标与像素坐标估计出对应的单应性矩阵 H 。

利用旋转矩阵列向量的正交归一性质，即 $\mathbf{r}_1^T \mathbf{r}_2 = 0$ 且 $\|\mathbf{r}_1\| = \|\mathbf{r}_2\| = 1$ ，可由 $H = [\mathbf{h}_1 \ \mathbf{h}_2 \ \mathbf{h}_3]$ 导出关于内参的约束方程：

$$\mathbf{h}_1^T \mathbf{B} \mathbf{h}_2 = 0, \quad \mathbf{h}_1^T \mathbf{B} \mathbf{h}_1 = \mathbf{h}_2^T \mathbf{B} \mathbf{h}_2, \quad (3-10)$$

其中 $\mathbf{B} = K^{-T} K^{-1}$ 为对称矩阵，仅含内参信息。每张标定图像提供两个约束方程，当图像数量不少于三张时即可线性求解 $\mathbf{B}$ ，进而通过 Cholesky 分解恢复内参矩阵 K 的闭式初值，并由 K 反解出各图像对应的外参 $[\mathbf{r}_1 \ \mathbf{r}_2 \ \mathbf{t}]$ 。

上述闭式解未考虑镜头畸变，且受角点检测噪声影响。因此，标定的最后一步是以闭式解为初值，将所有内参、畸变系数和各图像外参作为优化变量，通过最小化重投影误差进行非线性优化（Levenberg-Marquardt 算法）：

$$\min_{K, D, \{R_i, \mathbf{t}_i\}} \sum_{i=1}^n \sum_{j=1}^m \|\mathbf{p}_{ij} - \hat{\mathbf{p}}(K, D, R_i, \mathbf{t}_i, \mathbf{P}_j)\|_2^2, \quad (3-11)$$

其中 n 为图像数量， m 为每张图像的角点数量， $\mathbf{p}_{ij}$ 为实际检测到的角点像素坐标， $\hat{\mathbf{p}}(\cdot)$ 为将第 j 个角点世界坐标 $\mathbf{P}_j$ 按当前参数投影得到的预测像素坐标。

式 (3-11) 的目标函数值开方后即为重投影误差 (RMS, 单位为像素), 是衡量标定质量的核心指标: 其值越小, 说明标定参数越准确。

3.2.4 双目深度相机内参标定实现

基于上述原理, 本文对 Gemini335L 双目深度相机的红外相机流进行内参标定。由于深度图像与左红外相机同源、同分辨率, 标定红外相机得到的内参可直接用于深度图像反投影, 故本文以红外相机流 (分辨率 640×480) 作为标定对象。标定采用 calib.io 生成的 9×12 方格棋盘格标定板, 内角点数为 11×8 , 单格边长为 20 mm (打印后经实测校准), 标定算法基于 OpenCV 实现的张正友标定法。

标定图像采集遵循以下原则以保证参数可辨识性: 在近 (约 0.5 m)、中 (约 1 m)、远 (约 1.5 ~ 2 m) 不同距离下拍摄, 使标定板深度跨度大于 0.5 m, 避免焦距欠定; 变换标定板的倾斜角度 (左右倾、上下倾、正对) 以提供充分的姿态约束; 使标定板分别出现在图像的中心、边缘和角落, 以覆盖存在畸变的视场区域。共采集 20 ~ 30 张有效图像, 部分采集样本如图 3-4 所示。




图 3-4 红外相机标定图像采集样本

标定流程为: 对每张图像检测棋盘格内角点并进行亚像素级精化, 剔除角点检测失败或重投影误差异常偏大的图像, 随后按式 (3-10) 求解内参闭式初值, 最后通过式 (3-11) 的非线性优化得到最终的内参矩阵与畸变系数。标定结果如表 3-1 所示。

标定得到的重投影误差 RMS 为 0.28 px, 小于 0.5 px, 属于优秀标定质量, 满足

表 3-1 红外相机内参标定结果

参数类别	符号	标定值
内参	f_x	394.25
	f_y	397.77
	c_x	320.40
	c_y	232.10
畸变系数	k_1	0.1181
	k_2	-0.1832
	p_1	-0.0015
	p_2	0.0006
重投影误差	RMS	0.28 px

深度图像转点云对内参精度的要求。将表 3-1 中的内参 f_x 、 f_y 、 c_x 、 c_y 代入式 (3-7)，即可将深度相机输出的每个有效深度像素反投影为相机坐标系下的三维点，再结合第 3.1 节所述相机到机体、机体到世界坐标系的变换关系，最终得到统一坐标系下的三维点云，为后续障碍物检测与环境建图提供数据基础。

3.3 多传感器外参与静态坐标变换

上一节完成了相机内参标定，解决了单个相机内部的成像参数问题。然而，机器人搭载的激光雷达与深度相机分别安装在本体的不同位置，各自在独立的坐标系下输出数据。要将多源数据融合到统一的机体坐标系，还需确定各传感器坐标系与机体坐标系之间的刚体变换关系，即传感器外参。本节首先概述外参标定问题及常用方法，随后说明本文采用的基于机械安装尺寸的静态坐标变换配置方案，最后介绍 ROS 2 的 TF 坐标变换树及其在本文中的应用。

3.3.1 外参标定问题概述

传感器外参描述的是传感器坐标系相对于参考坐标系（通常为机器人本体坐标系）的位姿，由一个旋转矩阵 $R \in SO(3)$ 和一个平移向量 $\mathbf{t} \in \mathbb{R}^3$ 构成，共六个自由度。设某点在传感器坐标系下的坐标为 $\mathbf{p}_s$ ，则其在机体坐标系下的坐标 $\mathbf{p}_b$ 为

$$\mathbf{p}_b = R \mathbf{p}_s + \mathbf{t}. \quad (3-12)$$

准确的外参是多传感器数据空间对齐的前提，外参误差会直接导致点云错位、地图重影等问题。

确定外参的方法主要有三类：一是基于标定物的离线标定，如利用棋盘格或标定板配合手眼标定（Hand-Eye Calibration）方法，通过求解形如 $\mathbf{AX} = \mathbf{XB}$ 的方程组估计传感器间的相对位姿；二是基于运动或场景的在线自标定，如利用同步定位与建图（SLAM）过程中的点云配准（ICP）或位姿图优化，在线估计并修正外参；三是基于机械安装尺寸的直接测量，即根据传感器在机械结构上的安装位置和朝向，直接计算刚体变换参数。前两类方法精度较高，但依赖专门的标定流程或额外的计算，实现复杂度和调试成本较高。考虑到本文机器人平台的传感器均刚性固定于机械结构上、安装位姿在运行过程中不发生变化，且导航避障任务对外参精度的要求处于中等水平，本文采用第三类方法，即基于机械安装尺寸配置静态坐标变换，兼顾了实现的简洁性与工程的实用性。

3.3.2 本文坐标系配置方案

本文遵循机器人操作系统的坐标系约定（REP-105），以机器人本体坐标系 `base_link` 作为各传感器数据统一的参考坐标系，其原点位于底盘几何中心，+X 轴指向机器人前进方向，+Y 轴指向左侧，+Z 轴垂直向上。激光雷达和深度相机各自的坐标系通过静态变换挂接到该坐标系下。

根据传感器在机械结构上的实测安装位置，各坐标系相对 `base_link` 的外参配置如表 3-2 所示。由于传感器在安装时已保证其坐标轴与机体坐标系机械对齐，故旋转部分近似为单位阵（无相对旋转），外参主要体现为平移偏移。其中，Livox MID-360 激光雷达坐标系 `livox_frame` 相对机体中心前移 0.22 m、右移 0.22 m；Gemini335L 深度相机坐标系 `camera_link` 相对机体中心前移 0.275 m。

表 3-2 传感器外参配置

传感器坐标系	平移 $(x, y, z)/\text{m}$	旋转（欧拉角）
<code>livox_frame</code>	(0.22, -0.22, 0)	(0, 0, 0)
<code>camera_link</code>	(0.275, 0, 0)	(0, 0, 0)

该方案的优点是配置简单、无需专门的标定设备与流程，且传感器刚性固定后外参保持不变，无需在线估计；其局限在于测量精度受限于测量工具（约 $\pm 5\text{ mm}$ ），且未补偿传感器安装时可能存在的微小角度偏差。对于本文面向的半结构化环境移动机器人导航避障任务，该精度已能满足要求；若后续需要更高精度，可引入

前述手眼标定或基于 SLAM 的在线自标定方法进一步优化。

3.3.3 TF 坐标变换树

在机器人系统中，随着传感器数量增加以及机器人自身的运动，各坐标系之间的变换关系既有静态的（如传感器到机体的固定安装关系），也有动态的（如机体相对地图的实时位姿）。为统一管理这些变换，ROS 2 提供了 TF（Transform）坐标变换库，以树状结构维护全部坐标系及其父子变换关系，并支持按时间戳查询任意两个坐标系间的变换。本文机器人系统的 TF 树结构如图 3-5 所示。




图 3-5 机器人 TF 坐标变换树

TF 树以全局地图坐标系 map 为根节点，向下依次为里程计坐标系 odom 和机体坐标系 base_link，其中 $\text{map} \rightarrow \text{odom} \rightarrow \text{base_link}$ 的变换由第 4 章的定位建图模块实时发布，属于动态变换；base_link 向下挂接的 livox_frame 和 camera_link 两个传感器坐标系，其变换即为表 3-2 中配置的外参，通过静态变换发布者一次性发布、运行期间保持不变。数据处理时，各节点只需向 TF 库查询所需的坐标变换（例如将激光雷达点云由 livox_frame 变换到 base_link），即可完成多源数据的空间统一，无需在各节点中硬编码变换参数，提高了系统的模块化程度与可维护性。

3.4 深度图像到三维点云的转换

深度相机直接输出的是二维深度图像，而障碍物检测与环境建图需要三维点云形式的空间信息。本节介绍如何利用第 3.2 节标定得到的相机内参，将深度图像转换为三维点云，并统一到机体坐标系下。整体流程如图 3-6 所示。



图 3-6 深度图像转点云处理流程

3.4.1 深度图像数据格式

本文使用的 Gemini335L 深度相机基于双目立体视觉配合红外结构光主动投影生成深度图像，深度图与左红外相机同源、同分辨率（ 640×480 ），因此可直接使用第 3.2 节标定的红外相机内参进行反投影。深度图像以 ROS 标准图像消息 `sensor_msgs/Image` 发布，编码格式为 16UC1，即每个像素以 16 位无符号整数存储深度值，采用定点数表示（比例因子为 $1/10000$ ），例如像素值 5000 对应实际深度 0.5 m。像素值为 0 表示该点深度测量无效，通常由遮挡、目标反射率过低或超出量程等原因造成。

3.4.2 深度图像反投影算法

深度图像转点云的核心是针孔模型的反投影：对深度图中每个有效像素 (u, v) 及其深度值 d ，按式 (3-7) 计算其在相机坐标系下的三维坐标：

$$X_c = \frac{(u - c_x)d}{f_x}, \quad Y_c = \frac{(v - c_y)d}{f_y}, \quad Z_c = d, \quad (3-13)$$

其中 f_x 、 f_y 、 c_x 、 c_y 取自表 3-1 的标定内参。在反投影之前，需先对深度值进行有效性过滤，仅保留满足 $d > 0$ 且 $d_{\min} < d < d_{\max}$ 的像素，本文取 $d_{\min} = 0.3 \text{ m}$ 、 $d_{\max} = 5.0 \text{ m}$ 。这是因为过近的点位于相机盲区、易产生较大误差，过远的点深度精度显著下降且噪声较大，滤除二者可提升点云质量。

反投影得到的点云位于相机光学坐标系下，其坐标轴定义（+Z 沿光轴向前、+X 向右、+Y 向下）与 ROS 机体坐标系约定不同，需通过固定旋转将其转换到机体坐标系约定的朝向：

$$\mathbf{p}_{\text{body}} = R_{\text{o} \rightarrow \text{b}} \mathbf{p}_{\text{optical}}, \quad R_{\text{o} \rightarrow \text{b}} = \begin{bmatrix} 0 & 0 & 1 \\ -1 & 0 & 0 \\ 0 & -1 & 0 \end{bmatrix}. \quad (3-14)$$

此外， 640×480 的深度图完整转换将产生约 30 万个点，数据量大、计算负担重。为兼顾精度与实时性，本文采用均匀降采样策略，即每隔 N 个像素取一个点进行反投影，实际取 $N = 3$ ，降采样后每帧点数降至约 3 万，处理频率可稳定跟随深度图输入的约 10 Hz。

3.4.3 点云的坐标系变换与发布

经上述处理得到的点云仍位于相机坐标系 `camera_link` 下。为供后续多传感器融合使用，需进一步将其变换到机体坐标系。节点向 TF 库查询 `camera_link` $\rightarrow$ `base_link` 的变换（即第 3.3 节配置的外参），按式 (3-12) 对每个点应用刚体变换，得到机体坐标系下的点云。节点同时对外发布两路点云：一路为相机坐标系下的 `/camera/depth/points`，另一路为机体坐标系下的 `/camera/depth/points_base`，二者均采用 ROS 标准点云消息格式 `sensor_msgs/PointCloud2`。其中，机体坐标系下的点云将与激光雷达点云一同送入下一节的局部体素地图进行融合。深度图转点云节点的关键参数配置如表 3-3 所示。

表 3-3 深度图转点云节点参数配置

参数	取值	说明
深度比例因子	1/10000	16UC1 定点数转米
有效深度范围	0.3 ~ 5.0 m	过滤盲区与远距噪声
降采样间隔 N	3	每隔 3 像素取 1 点
目标坐标系	<code>base_link</code>	点云统一坐标系

3.5 多传感器点云融合与局部体素地图

激光雷达点云与深度相机点云各有优势与盲区：激光雷达测距精度高、视场远，但垂直分辨率有限、近距存在盲区；深度相机在近距范围内点云稠密、可补充低矮障碍信息，但量程短、受光照影响较大。为综合两类传感器的互补优势并抑制各自的噪声，本文将统一到机体坐标系的多源点云融合到一个局部体素地图中，对外提供稳定、去噪的障碍物表示，供后续导航避障使用。

3.5.1 占据体素地图表示

局部体素地图将机器人周围的三维空间离散为边长固定的立方体单元（体素），本文体素边长（分辨率）取 0.05 m，并仅维护机器人周围半径 5 m 范围内的体素以控制内存开销。为存储稀疏分布的占据体素，采用哈希表以体素的整数索

引为键进行索引，避免稠密三维数组的空间浪费。

每个体素的占据状态采用对数几率（log-odds）表示。设体素被占据的概率为 p ，其对数几率定义为

$$l = \log \frac{p}{1-p}. \quad (3-15)$$

采用对数几率的优点在于，多次观测的融合只需对 l 进行简单的加减运算，避免了概率形式下的连乘与归一化。当某传感器点云落入某体素时，对该体素累加一个正的观测增益 Δl （命中）：

$$l \leftarrow \text{clamp}(l + \Delta l, l_{\min}, l_{\max}), \quad (3-16)$$

并将 l 限制在 $[l_{\min}, l_{\max}]$ （本文取 $[-2.0, 2.0]$ ）以防止过度自信。当 l 超过占据阈值（本文取 0，对应概率 50%）时，该体素被判定为占据。

3.5.2 分传感器差异化融合策略

考虑到不同传感器的可信度与特性差异，本文对激光雷达、深度相机采用差异化的融合参数。激光雷达作为基准传感器，赋予较高的命中增益、较长的时间半衰期和较大的信任距离；深度相机作为近距补盲，赋予中等的命中增益与信任距离；同时对各传感器点云设置不同的高度过滤区间，滤除地面点与过高的无关点。主要融合参数如表 3-4 所示。

表 3-4 分传感器融合参数

传感器	命中增益 Δl	半衰期/s	信任距离/m
激光雷达	0.7	5.0	8.0
深度相机	0.5	3.0	4.0

3.5.3 时间衰减与地图更新

为使地图能够反映动态变化的环境（如移动的障碍物离开后原位置应被清空），本文引入基于时间的衰减机制：对于一段时间未被观测更新的体素，按其对应传感器的半衰期对 l 进行指数衰减，并叠加一个负偏移量，使长期未观测的体素的对数几率逐渐减小直至跌破占据阈值，此时将其从哈希表中删除以释放内存。这种以时间衰减代替显式光线投射（raycast）的清除方式，在保证动态障碍及时消除的同时，显著降低了计算开销。地图节点以 10 Hz 的频率周期性执行衰减与更新，并将当前所有占据体素的中心点组织为点云，通过话题 `/local_pointcloud` 发

布，作为后续导航模块的障碍物观测源。至此，多传感器数据完成了从原始观测到统一、去噪的三维障碍物表示的完整处理，为第 5 章的障碍物检测与第 6 章的路径规划提供了数据基础。

第 4 章 基于 FAST_LIO2 的激光里程计定位算法研究

4.1 引言

稳定可靠的自身定位是变电站运维机器人完成自主巡检与搬运任务的前提。机器人只有在统一坐标系下持续获得准确的全局位姿，才能为后续的环境感知、障碍物检测与路径规划提供可信的空间基准。变电站、厂房和室内走廊等场景往往结构重复、纹理单一且 GNSS 信号受限，单纯依靠轮式里程计或二维激光定位难以长期维持精度，容易产生累积漂移并在退化区域失效。因此，需要一种能够融合多源信息、在已知环境中提供稳定绝对定位的方法。

实时定位与地图构建（Simultaneous Localization and Mapping, SLAM）是移动机器人与自动驾驶领域的核心技术。其核心任务可归结为一种耦合估计问题：在未知环境中，移动平台利用传感器数据，同步完成对自身运动状态的描述与对环境空间结构的建模。二者相互依赖，定位精度依赖于地图的准确性，而一致地图的构建又需以精确的位姿轨迹为前提。在众多 SLAM 方案中，紧耦合激光惯性里程计因其高精度、低延迟和对退化环境的鲁棒性，逐渐成为三维定位的主流选择，其中 FAST_LIO2 以直接点到地图配准和迭代卡尔曼滤波取得了良好的精度与实时性平衡。

然而，原始 FAST_LIO2 更侧重在线里程计与建图，其输出轨迹不可避免地存在长距离累积漂移，难以直接满足运维机器人在已知场景中重复巡检对可复现绝对位姿的需求。针对这一问题，本章在 FAST_LIO2 直接激光惯性里程计框架基础上，引入预建点云地图约束与有初值重定位机制，将在线里程计问题转化为地图坐标系下的连续位姿估计问题，并通过仿真实验验证所提方法在定位精度、初始对齐鲁棒性和实时性方面的有效性。

本章的主要内容如下：

（1）系统阐述 SLAM 的基本架构与技术分类，并重点剖析 FAST_LIO2 的核心原理，包括 IMU 状态传播、激光点云运动畸变补偿、直接点到地图残差、流形迭代卡尔曼滤波以及 ikd-Tree 增量地图维护机制。

（2）提出面向预建 PCD 地图的定位与启动重定位方法。通过加载预建地图构建空间索引，采用“近似初值 + ICP 精配准”的两阶段策略完成地图坐标系下的初始对齐，并在滤波器量测更新阶段利用固定全局地图提供几何先验，抑制纯里程计运行中的坐标漂移。

（3）区分纯定位模式与混合建图模式，使所述方法能够在固定地图巡检与地

图扩展两类任务之间灵活切换，为不同运维场景提供统一的状态估计框架。

(4) 在 Gazebo 仿真环境中搭建走廊、迷宫和圆柱体林等多类场景，从定位精度、初始对齐有效性和计算开销三个维度对所提方法进行定量评估与对比分析。

4.2 SLAM 方法架构及技术分类

实时定位与地图构建作为一个复杂的状态估计问题，其解决方案已形成相对统一的系统架构。一个完整的 SLAM 系统通常包含以下几个关键模块：前端里程计、后端优化、建图模块以及回环检测模块。传感器层面可分为激光雷达 SLAM、视觉 SLAM 及多传感器融合 SLAM，后端框架层面可分为基于滤波器的 SLAM 和基于图优化的 SLAM。

前端里程计负责对相邻时刻的传感器数据进行关联与配准，实时估计传感器平台的增量运动，形成局部一致的轨迹与地图，但其误差会随时间累积。后端优化则接收前端输出的位姿估计以及回环检测模块提供的非连续时刻的约束信息，构建一个以位姿为节点、以约束为边的概率图模型，并通过非线性优化方法求解全局一致的最优轨迹。建图模块利用优化后的轨迹，将传感器观测数据融合到统一坐标系下，生成环境地图。根据核心框架与传感器类型的不同，SLAM 技术可进行如下分类：从传感器层面，主要分为激光雷达 SLAM、视觉 SLAM 以及多传感器融合 SLAM；从后端框架层面，则主要分为基于滤波器的 SLAM 与基于图优化的 SLAM 两大类。

4.2.1 基于滤波器的 SLAM

基于滤波器的 SLAM 方法将系统的状态（包括机器人位姿与环境路标点）建模为一个随时间演进的概率分布。其核心思想是采用递归的贝叶斯估计框架，在每一时刻，根据当前的控制输入和传感器观测，对系统状态的置信度（后验概率）进行更新。最具代表性的方法是扩展卡尔曼滤波器（EKF-SLAM）及其改进算法。EKF-SLAM 通过线性化非线性运动与观测模型，在状态向量的高斯分布假设下，进行均值和协方差的递推更新。此类方法的优势在于能够提供状态的在线估计及其不确定性度量，且计算复杂度与路标数量相关。然而，其线性化误差可能导致滤波器发散，且通常假设数据关联是已知或准确的。FastSLAM 算法通过粒子滤波估计路径，结合 EKF 估计路标，部分克服了 EKF-SLAM 的局限性，但粒子退化问题依然存在。在计算资源受限、强调实时性的应用场景中，基于滤波器的轻量化变体（如迭代卡尔曼滤波）仍具有重要价值。

4.2.2 基于图优化的 SLAM

基于图优化的 SLAM 是当前主流的高精度 SLAM 框架。该方法将 SLAM 问题转化为一个大规模非线性最小二乘优化问题。其模型是一个图结构：节点表示机器人不同时刻的位姿（有时也包括环境路标），边则表示位姿节点之间的空间约束。边主要分为两种：一是由前端里程计产生的连续位姿间的约束（里程计边），二是由回环检测产生的非连续位姿间的约束（回环边）。当检测到回环时，相当于在图中添加了新的强约束，从而能够有效校正累积的里程计漂移。优化目标是寻找一组最优的节点状态（位姿），使得图中所有边代表的预测观测与实际观测之间的误差平方和最小。常用的优化工具包括高斯-牛顿法、列文伯格-马夸尔特算法等。与滤波器方法相比，图优化方法能更自然地融合回环约束，进行全局一致性优化，从而获得精度更高的轨迹和地图，但其通常作为后端批量或滑动窗口优化运行，对计算资源要求较高。g2o、GTSAM、Ceres Solver 等开源库为图优化 SLAM 的实现提供了强大支撑。

4.2.3 紧耦合激光-惯性 SLAM

紧耦合激光-惯性 SLAM 是当前实现高鲁棒性、高频率状态估计的主流方案，其核心在于对激光雷达与惯性测量单元（IMU）的数据进行深层次融合。IMU 能够以数百赫兹的频率测量角速度和加速度，在短时间内积分可提供高频但快速发散的位姿预测。激光雷达则提供低频但绝对精度较高的三维几何观测。紧耦合方法并非将二者独立处理后再进行结果融合，而是在一个统一的状态估计框架内，直接使用原始的激光雷达点云和 IMU 测量值，共同约束系统状态（通常包括位置、姿态、速度、传感器偏置等）。具体而言，激光雷达的每一个或多个原始点都可以直接作为观测方程，与 IMU 预测的运动方程一起，构建一个状态估计问题。这种深度融合方式充分利用了 IMU 的高频动态信息来辅助激光雷达点云的运动畸变矫正和数据关联，同时利用激光雷达的精确观测来抑制 IMU 积分漂移。以 FAST-LIO 系列为代表的算法，通过将紧耦合的激光-惯性里程计建模在迭代卡尔曼滤波框架下，实现了在剧烈运动场景中的鲁棒、实时、高精度状态估计，是紧耦合 SLAM 的典型代表^[7]。

4.3 FAST_LIO2 激光惯性里程计原理

FAST_LIO2 是一类面向实时三维建图与定位的紧耦合激光惯性里程计方法，其核心思想是在误差状态迭代卡尔曼滤波框架内融合 IMU 传播模型与激光点云到局部地图的几何约束^[7]。与 LOAM 类方法先提取边缘点、平面点再进行特征匹配

的流程不同^[7]，FAST_LIO2 取消了手工特征提取模块，直接使用降采样后的原始激光点与地图进行配准。这种直接法能够保留更多环境几何信息，降低算法对雷达扫描模式和特征阈值的依赖，因此更适合 Livox MID360 等非重复扫描或小型移动平台常用的三维激光雷达。

FAST_LIO2 的系统流程可概括为：首先，利用 IMU 高频测量对状态进行前向传播，并在传播过程中对一帧激光点云内部的运动畸变进行补偿；其次，将去畸变后的点云变换到世界坐标系，在增量地图中搜索近邻点并拟合局部平面；最后，根据点到局部平面的残差构造量测模型，通过迭代卡尔曼滤波更新位姿、速度、IMU 偏置以及外参等状态。为保证实时性，FAST_LIO2 采用增量式 k 维树（ikd-Tree）维护点云地图，使地图能够在线支持点插入、删除、重平衡和近邻搜索，避免每一帧重新构建静态 KD 树带来的高计算开销^[7]。




图 4-1 FAST-LIO2 激光惯性里程计系统架构

系统由两大模块组成：（1）状态估计模块（橙色虚线框）：基于迭代误差状态卡尔曼滤波（IEKF），通过 IMU 前向传播、点云累积、后向传播、残差计算和状态更新的迭代循环，输出高频位姿估计；（2）建图模块（蓝色虚线框）：基于增量式 kd 树（ikd-Tree）维护局部点云地图，支持逐点插入、树上降采样、区域删除和动态重平衡，为状态估计提供 kNN 近邻搜索服务。输出的里程计位姿（绿色）既作为导航反馈，也驱动地图更新和前向传播的初值。

4.3.1 状态变量与 IMU 传播模型

图4-1展示了 FAST_LIO2 的完整系统架构。其核心是状态估计与建图的紧密协同：IMU 提供连续高频运动预测，激光雷达提供离散低频几何观测，二者在误差状态迭代卡尔曼滤波框架内深度融合。具体而言，系统在每帧同步数据到来时，首先利用 IMU 测量进行前向传播并补偿点云运动畸变；随后将去畸变点云累积并变换到世界坐标系，在 ikd-Tree 维护的增量地图中搜索近邻点，拟合局部平面并计算点到平面残差；最后通过迭代优化更新状态。当残差收敛时，输出当前位姿作为里程计结果并反馈至下一帧的前向传播初值；若未收敛，则继续后向传播进

行下一轮迭代。建图模块根据输出位姿判断是否需要地图移动或区域删除，并将新观测点按体素分辨率插入 ikd-Tree，保持地图的实时性与紧凑性。

设系统状态定义为

$$\mathbf{x} = [{}^G\mathbf{p}_I^T, {}^G\mathbf{R}_I, {}^I\mathbf{R}_L, {}^I\mathbf{p}_L^T, {}^G\mathbf{v}_I^T, \mathbf{b}_g^T, \mathbf{b}_a^T, {}^G\mathbf{g}^T]^T, \quad (4-1)$$

其中 ${}^G\mathbf{p}_I$ 、 ${}^G\mathbf{R}_I$ 分别表示 IMU 坐标系相对于全局坐标系的位置和姿态， ${}^I\mathbf{R}_L$ 、 ${}^I\mathbf{p}_L$ 表示激光雷达相对于 IMU 的外参， ${}^G\mathbf{v}_I$ 为 IMU 速度， $\mathbf{b}_g$ 、 $\mathbf{b}_a$ 分别为陀螺仪和加速度计偏置， ${}^G\mathbf{g}$ 为重力向量。上述状态同时包含运动状态、传感器误差项和外参项，使激光几何约束能够与惯性传播约束在同一估计框架内共同作用。

IMU 测量可表示为

$$\boldsymbol{\omega}_m = \boldsymbol{\omega} + \mathbf{b}_g + \mathbf{n}_g, \quad \mathbf{a}_m = \mathbf{a} + \mathbf{b}_a + \mathbf{n}_a, \quad (4-2)$$

其中 $\boldsymbol{\omega}_m$ 和 $\mathbf{a}_m$ 为 IMU 输出的角速度和加速度， $\mathbf{n}_g$ 、 $\mathbf{n}_a$ 为测量噪声。连续时间状态传播可写为

$$\begin{aligned} {}^G\dot{\mathbf{p}}_I &= {}^G\mathbf{v}_I, \\ {}^G\dot{\mathbf{R}}_I &= {}^G\mathbf{R}_I (\boldsymbol{\omega}_m - \mathbf{b}_g - \mathbf{n}_g)^\wedge, \\ {}^G\dot{\mathbf{v}}_I &= {}^G\mathbf{R}_I (\mathbf{a}_m - \mathbf{b}_a - \mathbf{n}_a) + {}^G\mathbf{g}, \\ \dot{\mathbf{b}}_g &= \mathbf{n}_{bg}, \quad \dot{\mathbf{b}}_a = \mathbf{n}_{ba}. \end{aligned} \quad (4-3)$$

式中 $(\cdot)^\wedge$ 表示李代数向量到反对称矩阵的映射。由于激光雷达在采集一帧点云时平台仍在连续运动，若直接将整帧点云视为同一时刻采集，会在快速转弯或加减速时产生明显运动畸变。FAST_LIO2 利用 IMU 传播得到的连续位姿，对每个点按照其相对时间戳进行反向补偿，将其统一到该帧结束时刻，从而提升后续点云配准的一致性。

4.3.2 直接点到地图量测模型

在量测更新阶段，FAST_LIO2 将去畸变后的激光点 ${}^L\mathbf{p}_j$ 根据当前状态变换到全局坐标系：

$${}^G\mathbf{p}_j = {}^G\mathbf{R}_I ({}^I\mathbf{R}_L {}^L\mathbf{p}_j + {}^I\mathbf{p}_L) + {}^G\mathbf{p}_I. \quad (4-4)$$

随后在 ikd-Tree 维护的地图中搜索该点的若干近邻点，并利用近邻点拟合局部平面

$$\mathbf{u}_j^T \mathbf{p} + d_j = 0, \quad (4-5)$$

其中 $\mathbf{u}_j$ 为平面单位法向量, d_j 为平面参数。对应的点到平面残差为

$$r_j = \mathbf{u}_j^{TG} \mathbf{p}_j + d_j. \quad (4-6)$$

该残差直接反映当前状态估计下激光点与局部地图几何的一致性。实际量测构造过程包括坐标变换、近邻搜索、局部平面估计、残差筛选和量测雅可比计算等步骤。当有效点数量不足或近邻无法稳定拟合平面时, 系统应降低该帧几何约束的可信度, 以避免退化环境对滤波器造成错误修正。

设一帧中所有有效点残差堆叠为 $\mathbf{r}$, 量测模型可近似写为

$$\mathbf{0} = \mathbf{h}(\mathbf{x}) + \mathbf{v}, \quad \mathbf{h}(\mathbf{x}) = [r_1, r_2, \dots, r_m]^T, \quad (4-7)$$

其中 m 为有效量测点数量, $\mathbf{v}$ 为激光量测噪声。由于位姿状态位于 $SO(3)$ 流形上, FAST_LIO2 采用流形上的误差状态迭代卡尔曼滤波进行求解: 先由 IMU 传播得到预测状态, 再在当前线性化点附近反复构建点到平面残差和雅可比, 迭代修正误差状态, 直至收敛或达到最大迭代次数。与传统 ICP 单独输出刚体变换不同, 该过程将点云几何约束直接融入包含 IMU 偏置、速度和外参的统一状态估计中, 因此能够同时获得低延迟和较高鲁棒性。

4.3.3 基于 ikd-Tree 的增量地图维护

激光里程计需要在每帧点云到来时进行地图近邻搜索和地图更新。若每次都对全局点云重新构建 KD 树, 计算复杂度会随着地图规模迅速上升, 难以满足在线定位需求。FAST_LIO2 使用 ikd-Tree 维护局部稠密点云地图, 该结构除支持近邻搜索外, 还支持增量插入、按空间区域删除、树结构重平衡以及树上体素降采样。

如图4-1右侧建图模块所示, ikd-Tree 不仅提供 kNN 近邻搜索服务, 还需动态响应传感器移动和环境变化。当机器人移动导致地图边界发生偏移时(地图移动? 判断为真), 系统触发区域删除操作, 移除视野外的历史点云以控制内存占用。插入新点时, ikd-Tree 首先执行树上降采样(On-Tree Downsampling), 判断新点是否能够补充地图几何信息: 若该体素内已有代表点且新点不提供额外约束, 则跳过插入; 否则将其增量加入树结构。此外, 频繁的插入和删除会导致树的不平衡, 当不平衡度超过阈值时, 系统触发局部或全局重平衡(树重建), 恢复树的查询效率。该动态维护机制使 FAST_LIO2 能够在长时间运行中保持稳定的计算开销。

本文采用的地图维护策略与 FAST_LIO2 一致: 系统首先将当前帧降采样点云变换到世界坐标系, 再依据体素分辨率判断新观测是否能够补充地图几何信息。

若某一体素内已经存在更具代表性的地图点，则当前点不再重复插入；若当前点能够提供新的空间约束，则将其作为增量点加入地图索引。对于预建地图定位任务，地图更新可以被关闭，使所有量测始终约束在固定的全局地图中；对于未知区域探索或地图扩展任务，则可在完成初始定位后开启增量更新，使新观测逐步并入原有地图。该策略使定位模式和建图扩展模式能够在同一状态估计框架下统一描述。

4.4 面向预建地图的 FAST_LIO2 定位与重定位方法

原始 FAST_LIO2 更侧重在线里程计与建图，其输出轨迹不可避免地存在长距离累积漂移。对于运维机器人在变电站、厂房或室内走廊等已知场景中的重复巡检任务，系统更需要在预先构建的全局点云地图中获得稳定、可复现的绝对位姿。因此，本文在 FAST_LIO2 直接激光惯性里程计框架基础上，引入预建点云地图约束和有初值重定位机制，将在线里程计问题转化为地图坐标系下的连续位姿估计问题。该方法并非改变 FAST_LIO2 的紧耦合状态估计本质，而是在滤波器量测更新阶段使用固定全局地图提供几何先验，从而抑制纯里程计运行中的坐标漂移。

本文所提出的定位框架如图4-2所示，系统分为初始化（阶段 A）和在线定位（阶段 B）两个阶段。阶段 A 完成地图加载与 ikd-Tree 索引构建、IMU 静态初始化以及近似初值与 ICP 相结合的两阶段初始对齐，为后续状态估计提供可靠的初始位姿；阶段 B 在每帧数据到来时执行 IMU 传播、点云去畸变、地图坐标变换、ikd-Tree 近邻搜索与 IEKF 状态更新，持续输出地图坐标系下的全局连续位姿，并可根据任务需求在纯定位模式与混合建图模式之间切换。

4.4.1 预建地图定位框架

预建地图定位系统的输入由三部分构成：一是连续到达的激光雷达点云和 IMU 测量，二是离线构建得到的全局点云地图，三是机器人在地图坐标系中的初始位姿近似。激光与惯性数据用于提供高频运动预测和局部几何观测，预建地图用于提供全局坐标基准，初始位姿近似则用于保证启动阶段点云配准能够收敛到正确邻域。

系统输出为地图坐标系下的机器人位姿、连续轨迹以及经位姿变换后的当前帧点云。对于上层路径规划和运动控制模块而言，该输出相当于全局定位反馈；对于感知和地图更新模块而言，该输出提供了将局部观测投影到统一坐标系的时变位姿。为了避免导航任务在定位尚未收敛前启动，系统在初始化完成前应保持任务锁定状态，待地图加载、IMU 初始化和初始配准均满足条件后再向上层模块释




图 4-2 基于预建地图的 FAST-LIO2 定位框架

放定位可用信号。

4.4.2 预建地图加载与初始位姿对齐

定位流程启动后，系统首先读取离线构建的 PCD 点云地图，并通过均匀采样或体素滤波降低冗余点密度。随后，以预建地图初始化增量式空间索引，使后续点云配准能够直接在全局地图中进行近邻搜索。完成该步骤后，地图不再只是里程计运行过程中逐步生成的局部几何集合，而是作为固定的全局几何先验参与后续每帧激光量测更新。

由于点云配准通常是局部优化问题，启动阶段需要较可靠的初始位姿。本文采用“近似初值 + ICP 精配准”的两阶段初始化策略：首先由人工设定、停靠位置或上层先验给出机器人在预建地图中的粗略位姿；然后在 IMU 静态初始化完成后，累积若干帧激光点云形成局部源点云，并将其与预建地图进行 ICP 配准^[2]。ICP 的目标可表示为

$$\mathbf{T}^* = \arg \min_{\mathbf{T} \in SE(3)} \sum_i \left\| \mathbf{T} \mathbf{p}_i - \mathbf{q}_{\pi(i)} \right\|^2, \quad (4-8)$$

其中 $\mathbf{p}_i$ 为启动阶段累积的局部点云， $\mathbf{q}_{\pi(i)}$ 为预建地图中的对应点， $\mathbf{T}^*$ 为源点云到地图坐标系的最优刚体变换。ICP 收敛后，得到的位姿修正被写入滤波器初始状态，使后续激光惯性状态估计直接在预建地图坐标系下展开。若初始配准无法收敛，则说明粗略位姿、当前观测或地图几何之间存在较大不一致，此时不应继续启动导航任务，以避免错误初值引起持续定位发散。

上述两阶段初始对齐过程如图4-3所示。首先由近似初值将启动阶段累积的源点云 $\mathbf{p}_i$ 粗略摆放到预建地图的正确邻域，此时源点云与地图之间仍存在明显的旋转和平移偏差（图4-3(a)）；随后进入 ICP 迭代精配准，在每次迭代中先为源点建立到地图的最近邻对应 $\mathbf{p}_i \leftrightarrow \mathbf{q}_{\pi(i)}$ ，再求解使式(4-8)最小的刚体变换并更新源点云位姿（图4-3(b)），如此反复直至点对残差收敛至阈值 ε ；最终得到的最优变换 $\mathbf{T}^*$ 将源点云精确对齐到地图坐标系（图4-3(c)），并写入滤波器初始状态。其中点对残差是否收敛至阈值 ε 可作为初始化是否成功的判据，若残差无法收敛则放弃本次启动对齐。




图 4-3 两阶段初始对齐过程示意

4.4.3 地图约束下的在线定位更新

完成初始对齐后，系统进入逐帧定位阶段。每当激光点云与 IMU 数据完成时间同步，状态估计器首先根据 IMU 序列进行状态传播，并对当前帧点云进行运动畸变补偿；随后，将去畸变点云变换到地图坐标系，在预建地图中搜索近邻点并拟合局部平面，构造点到平面的残差；最后，通过迭代误差状态卡尔曼滤波更新机器人位姿、速度和 IMU 偏置。由于纯定位模式下地图保持固定，激光量测始终约束在同一全局地图坐标系内，输出位姿也自然具有全局一致性。

从算法结构看，该流程可抽象为以下步骤：

- (1) 加载预建点云地图，对地图点云进行降采样，并构建空间索引。
- (2) 利用启动阶段 IMU 数据估计重力方向、陀螺仪偏置和初始协方差，同时累积若干帧激光点云作为初始配准源点云。
- (3) 若预建地图有效，则以近似初值执行 ICP 配准，将得到的修正变换写入滤波器状态，并将定位状态标记为可用；若预建地图为空或点数不足，则退化为普通 SLAM 模式。
- (4) 在每一帧同步后的激光和 IMU 数据到来时，先进行 IMU 传播和点云去畸变，再将当前帧点云降采样并变换到地图坐标系。

(5) 在地图索引中搜索近邻点并拟合局部平面，构造点到平面残差和量测雅可比，通过迭代卡尔曼滤波更新状态。若系统处于混合建图模式，则将满足条件的新观测增量并入地图。

4.4.4 纯定位模式与混合建图模式

根据地图是否随在线观测更新，本文方法可分为纯定位模式和混合建图模式。纯定位模式仅使用预建地图进行位姿估计，不将当前帧点云写入地图。这种模式适用于已经完成地图采集、巡检路线相对固定的场景，能够避免动态障碍物、临时设备或点云噪声污染全局地图。混合建图模式则在完成初始定位并稳定运行后允许地图增量更新，适用于预建地图不完整或机器人需要探索扩展区域的场景。此时新采集点云会在当前地图坐标系下并入地图，使扩展区域与原始地图保持同一坐标基准。

需要注意的是，本文所述重定位主要指系统启动或任务重启时基于近似初值的地图坐标恢复，而不是完全无先验的全局定位。由于 ICP 属于局部优化方法，初始位姿误差过大、环境几何重复、视场内有效结构过少或预建地图与当前环境差异过大时，配准可能收敛到错误局部最优。因此，在实际部署中应结合机器人停靠点、人工给定初值、二维码/定位桩、轮速里程计或上层任务先验提供合理初始位姿。同时，机器人应在地图加载和初始化期间保持静止，以保证 IMU 初始化和点云累积质量。

4.5 仿真实验与结果分析

为验证本章所述基于 FAST_LIO2 的预建地图定位方法的有效性与实时性，本节在 Gazebo 仿真环境中设计了三类场景的对比实验。实验从定位精度、初始对齐鲁棒性与计算开销三个维度对系统性能进行定量评估，并与纯里程计方法进行对比分析。

4.5.1 仿真平台与实验设置

4.5.1.1 仿真环境与硬件配置

实验采用 Gazebo 11 仿真器与 ROS Noetic 搭建测试平台，仿真 Livox MID360 激光雷达（非重复扫描，10 Hz 帧率，视场角 360°）和 100 Hz IMU 传感器，二者通过仿真插件生成带时间戳的点云与惯性测量数据。移动机器人采用差速驱动模型，通过键盘或轨迹规划节点控制运动。仿真环境提供的机器人真实位姿（来自 Gazebo 的 `model_states` 话题或 P3D 插件）作为评价基准，无需外部动作捕捉系统，为绝对轨迹误差（ATE）与相对位姿误差（RPE）的计算提供可靠真值。

实验在 Intel i7-11800H CPU (8 核 16 线程, 2.3 GHz)、16 GB 内存的笔记本电脑上运行, 操作系统为 Ubuntu 20.04。FAST_LIO2 定位算法运行于单独的 ROS 节点, 与 Gazebo 仿真器并行但独立计算, 不占用仿真器资源。

4.5.1.2 实验场景设计

为覆盖不同几何结构特征与定位退化条件, 设计三个典型仿真场景, 其参数如表4-1所示。


表 4-1 仿真实验场景参数

场景名称	环境特征	轨迹时长 (s)	帧数	里程 (m)
走廊	长直通道, 几何退化敏感	145	~2900	78
迷宫	结构丰富, 多转弯, 特征密集	180	~3600	112
圆柱体林	稀疏重复结构, 对称性干扰	160	~3200	95


走廊场景模拟变电站内部长直通道, 墙面平行且特征单一, 易产生沿走廊方向的定位退化; 迷宫场景包含多个拐角与分支路径, 几何约束充分, 对应厂房或复杂室内环境; 圆柱体林场景由若干圆柱体障碍物随机分布构成, 考察算法在重复结构下的鲁棒性。三个仿真场景的 Gazebo 模型如图4-4所示。每个场景均以匀速或变速方式完成完整轨迹采集, 雷达频率 10 Hz, 单帧点云约 8000-12000 点。



(a) 走廊场景



(b) 迷宫场景



(c) 圆柱体林场景

图 4-4 三类仿真实验场景的 Gazebo 环境模型

4.5.1.3 实验流程与评价指标

实验流程分为两阶段：第一阶段，机器人在各场景以 SLAM 模式（无预建地图）运行，累积点云并构建全局地图，保存为 PCD 格式；第二阶段，加载预建地图，在纯定位模式或混合建图模式下重复相同轨迹，记录估计位姿与真值位姿，离线计算误差指标。

定位精度评价采用如下指标：

- **绝对轨迹误差 (ATE)**：估计轨迹与真值轨迹在相同时间戳下的欧氏距离，统计均方根误差 (RMSE)、均值、最大值与标准差。ATE 反映全局定位精度。
- **相对位姿误差 (RPE)**：相邻时刻位姿变化的估计值与真值之间的差异，分别统计平移误差 (m/m) 与旋转误差 (deg/m)。RPE 反映局部一致性与漂移速率。

误差计算采用开源工具 `evo`^①，自动对齐时间戳并生成统计报告。实时性评价通过 ROS 节点内部计时记录单帧处理耗时，并统计各模块占比。

4.5.2 定位精度评估

本实验对比三种运行模式在三个场景下的定位精度：（1）**纯定位模式**：加载预建地图，地图固定不更新（对应 `update_tree_frame = -1`）；（2）**混合建图模式**：加载预建地图，80 帧后开启增量更新（对应 `update_tree_frame = 80`）；（3）**纯里程计模式**：不加载预建地图，仅依赖 FAST_LIO2 里程计，作为漂移对照基准。

4.5.2.1 轨迹对比

图4-5展示三个场景下估计轨迹与真值轨迹的叠加对比。可以看出，纯定位模式（蓝色虚线）始终紧密跟随真值轨迹（红色实线），在走廊、迷宫和圆柱体林场景中均保持较高一致性。纯里程计模式（橙色点线）在缺乏全局地图约束时，随时间累积产生明显漂移，尤其在走廊场景（长直无明显转弯）漂移最为严重，轨迹终点与真值偏离达数十厘米；迷宫场景由于频繁转弯与丰富几何特征，漂移相对较小但仍不可忽视；圆柱体林场景受重复结构干扰，漂移呈间歇性增长。

4.5.2.2 绝对轨迹误差统计

表4-2列出各场景、各模式的 ATE 统计结果。从 RMSE 指标看，纯定位模式在所有场景均优于混合建图模式与纯里程计。迷宫场景定位精度最高（ATE-RMSE 0.046 m），得益于其丰富的几何约束与频繁的姿态变化；走廊场景精度最低（0.082

^①<https://github.com/MichaelGrupp/evo>




图 4-5 三场景轨迹对比：估计轨迹与真值叠加

m)，符合单一几何结构易产生退化的理论预期；圆柱体林场景居中（0.061 m），表明算法对稀疏重复结构有一定鲁棒性但仍受影响。混合建图模式略优于纯定位（约 5-10%），原因是增量更新能够补充地图中原本未覆盖的局部区域，但差异不显著。纯里程计模式的 ATE-RMSE 比纯定位模式高约 3-5 倍，验证了预建地图约束对抑制长期漂移的关键作用。

表 4-2 绝对轨迹误差（ATE）统计结果

场景	模式	RMSE (m)	Mean (m)	Max (m)
走廊	纯定位	0.082	0.076	0.158
	混合建图	0.071	0.065	0.142
	纯里程计	0.410	0.385	0.782
迷宫	纯定位	0.046	0.042	0.095
	混合建图	0.043	0.039	0.088
	纯里程计	0.190	0.175	0.398
圆柱体林	纯定位	0.061	0.056	0.125
	混合建图	0.058	0.053	0.118
	纯里程计	0.280	0.262	0.545

图4-6左侧展示迷宫场景的 APE（Absolute Pose Error）时间序列曲线，纯定位与混合建图模式的误差始终保持在 0.1 m 以下且波动平缓，而纯里程计误差随时间单调递增，在 180 s 时累积至约 0.4 m。右侧箱线图汇总三个场景的 ATE-RMSE 分布，直观展示预建地图定位方法相对于纯里程计的显著优势。

4.5.2.3 相对位姿误差

表4-3列出 RPE 统计结果。平移 RPE（m/m）反映单位里程的累积漂移速率，纯定位模式在三场景均保持在 0.001 m/m 量级，即每行进 100 m 累积约 10 cm 误差；纯里程计则达到 0.0025-0.0052 m/m，漂移速率高出 2-5 倍。旋转 RPE（deg/m）




图 4-6 定位精度对比：APE 时间序列（左）与 ATE 箱线图（右）

同样显示预建地图约束能够有效抑制姿态漂移。RPE 结果与 ATE 相互印证，共同验证本章方法的定位精度优势。

表 4-3 相对位姿误差（RPE）统计结果

场景	模式	平移 RPE (m/m)	旋转 RPE (deg/m)
走廊	纯定位	0.0012	0.028
	混合建图	0.0010	0.025
	纯里程计	0.0052	0.092
迷宫	纯定位	0.0008	0.019
	混合建图	0.0007	0.017
	纯里程计	0.0025	0.048
圆柱体林	纯定位	0.0010	0.023
	混合建图	0.0009	0.021
	纯里程计	0.0035	0.065

4.5.3 初始对齐（ICP）有效性

本实验验证第4.4.2节所述“近似初值 + ICP 精配准”两阶段初始对齐策略在不同初值扰动下的收敛性能。以迷宫场景为测试环境，对配置文件中的 `approximate_init_pose` 施加平移扰动（0、0.5、1.0、2.0、3.0 m）与旋转扰动（0、10、20、30、45°），共 25 组组合。每组重复运行 10 次，统计 ICP 收敛成功率、平均迭代次数与收敛后配准 RMSE。定义收敛成功的判据为：迭代 100 次内配准残差降至 2 cm 以下且与真值位姿偏差小于 10 cm。

4.5.3.1 收敛成功率

图4-7左侧热力图展示 ICP 成功率随扰动幅度的变化规律。当平移扰动 ≤ 1.0 m 且旋转扰动 $\leq 20^\circ$ 时，成功率接近 100%，表明算法在该范围内具有高鲁棒性；当平移扰动达到 2.0 m 或旋转扰动达到 30° 时，成功率开始下降，部分情况收敛到错误局部最优或超时失败；当扰动进一步增大至 3.0 m / 45° 时，成功率降至 18-85%，不再可靠。该结果验证了第4.4.4节中”ICP 依赖近似初值”的论述，并为实际应用提供定量参考：初始位姿估计误差应控制在 1.5 m、 20° 以内以保证稳定初始化。




图 4-7 ICP 初始对齐分析：成功率热力图（左）与收敛曲线（右）

4.5.3.2 收敛速度与配准精度

图4-7右侧展示不同初值质量下的 ICP 残差收敛曲线。良好初值 (< 1.0 m, $< 20^\circ$) 下，配准残差在 20-30 次迭代内快速收敛至 2 cm 阈值以下，最终稳定在 1.5-2.5 cm；中等初值 (1-2 m, $20-30^\circ$) 需 40-60 次迭代，最终残差 2.5-3.5 cm；较差初值 (> 2 m, $> 30^\circ$) 收敛缓慢且部分情况振荡，最终残差可能停留在 4-5 cm 或更高。表4-4汇总典型扰动等级的统计结果，验证初值质量对 ICP 性能的决定性影响。

表 4-4 ICP 初始对齐性能

扰动等级	成功率 (%)	平均迭代次数	配准 RMSE (cm)
良好 (< 1 m, < 20°)	99.5	25	2.1
中等 (1-2 m, 20-30°)	88.3	52	3.2
较差 (> 2 m, > 30°)	51.7	78	4.6

4.5.4 实时性与计算开销

实时性是移动机器人在线定位的关键指标。本实验记录单帧处理总耗时及各模块占比，并分析 ikd-Tree 地图规模对计算开销的影响。

4.5.4.1 模块耗时分解

图4-8上图展示三场景的模块耗时堆叠柱状图。单帧总耗时在 18.5–24.3 ms 之间，远低于 10 Hz 雷达周期（100 ms），满足实时性要求。近邻匹配模块耗时最高（占比 40–50%），是主要计算瓶颈；IEKF 状态更新次之（约 20–25%）；IMU 传播与降采样、地图增量更新占比较小。迷宫场景耗时最高（24.3 ms），因其点云密度大、近邻搜索复杂度高；走廊场景最低（18.5 ms），点云稀疏且平面拟合简单。




图 4-8 实时性能分析：模块耗时分解（上）、单帧耗时序列（中）、ikd-Tree 规模变化（下）

表4-5列出各模块平均耗时与计算帧率。纯定位模式平均帧率 41–54 Hz，混合建图模式略低（因增量更新带来额外开销）但仍保持在 35 Hz 以上，均显著高于雷达频率，验证算法的实时性。

表 4-5 计算耗时与帧率统计

场景	IMU+ 降采样 (ms)	近邻匹配 (ms)	IEKF 更新 (ms)	地图增量 (ms)	总耗时 (ms)	帧率 (Hz)
走廊	3.2	8.5	4.8	2.0	18.5	54
迷宫	4.1	12.3	5.2	2.7	24.3	41
圆柱体林	3.6	9.8	4.9	1.8	20.1	50

4.5.4.2 单帧耗时波动与地图规模

图4-8中图展示迷宫场景的单帧耗时时间序列，耗时在 15-35 ms 之间波动，均值 24.3 ms（红色虚线）。波动主要来源于点云密度变化与近邻搜索复杂度差异，但整体稳定在实时阈值（100 ms，橙色虚线）以下。

图4-8下图展示 ikd-Tree 地图规模随时间的变化。纯定位模式（蓝线）地图固定在约 18.5 k 点，规模不增长；混合建图模式（绿线）地图从初始 15 k 点逐步增长至约 50 k 点，增量更新使地图覆盖范围扩大但未显著影响单帧耗时，验证 ikd-Tree 增量维护的高效性。该结果与第4.3.3节理论分析一致：ikd-Tree 通过局部重平衡与树上降采样，避免地图规模膨胀导致的性能退化。

4.5.5 实验结果讨论

上述实验结果表明，本章所述基于 FAST_LIO2 的预建地图定位方法在 Gazebo 仿真环境中具有以下特点：

（1）定位精度显著优于纯里程计。预建地图约束使 ATE-RMSE 降低 3-5 倍，有效抑制长期漂移，验证第4.4节方法的核心优势。迷宫场景精度最高，走廊场景受几何退化影响精度最低，符合理论预期。

（2）初始对齐依赖合理初值。ICP 在 1.5 m / 20° 范围内成功率接近 100%，超出该范围显著下降。实际应用中需通过人工设定、停靠位置、二维码或上层先验提供可靠初始位姿，避免错误收敛。

（3）实时性满足在线定位需求。单帧耗时 18.5-24.3 ms，帧率 41-54 Hz，远高于 10 Hz 雷达频率。近邻匹配是主要瓶颈，但 ikd-Tree 增量维护保持高效，地图规模增长未导致性能退化。

（4）纯定位与混合建图模式各有适用场景。纯定位精度略低但稳定，适合固定地图巡检；混合建图精度略高且可扩展地图，适合探索未知区域。实际部署可根据任务需求切换模式。

需要指出的是，本节实验基于仿真环境，Gazebo 提供的传感器噪声模型与真实硬件存在差异，且仿真场景几何结构相对规则。后续实际部署时，需在真实变

电站或厂房环境中进一步验证算法在动态障碍物、光照变化、传感器退化等复杂条件下的鲁棒性。此外，初始对齐成功率对初值的敏感性提示需结合全局重定位方法（如点云描述子匹配）以提升无先验启动能力，该方向将在后续工作中探索。

4.6 本章小结

本章围绕移动机器人定位需求，研究了基于 FAST_LIO2 的激光里程计定位算法。首先介绍了 SLAM 系统的基本架构和技术分类，分析了基于滤波器、基于图优化以及紧耦合激光惯性 SLAM 方法的特点。随后重点阐述 FAST_LIO2 的核心原理，包括 IMU 状态传播、激光点云运动畸变补偿、直接点到地图残差、流形迭代卡尔曼滤波以及 ikd-Tree 增量地图维护机制。

在此基础上，本章说明了面向预建 PCD 地图的定位与启动重定位流程。系统通过加载预建地图构建空间索引，以近似初始位姿和 ICP 完成地图坐标系下的初始对齐，并在后续运行中利用 FAST_LIO2 的点到平面量测更新持续输出全局位姿。通过区分纯定位模式和混合建图模式，所述方法能够在固定地图巡检和地图扩展两类任务之间切换，为后续路径规划、障碍物检测和导航控制模块提供稳定的位姿基础。

从算法特点与适用性来看，相较于仅依赖轮式里程计或 AMCL 粒子滤波的二维定位方法，基于 FAST_LIO2 的三维激光惯性定位具有以下优势。首先，三维点云能够直接利用墙面、设备支架、电缆沟边缘和立体障碍物等空间结构，在平面纹理不明显或二维激光可见特征不足时仍可提供较强约束。其次，IMU 传播为高频状态估计和点云去畸变提供支撑，可提升机器人在转弯、加减速和短时遮挡条件下的定位连续性。再次，直接点到地图配准减少了特征提取阈值对不同雷达型号和扫描模式的依赖，有利于系统在不同传感器平台上的迁移。该方法也存在一定局限：其一，FAST_LIO2 本质上仍是局部里程计框架，若脱离预建地图或回环后端，长距离运行会产生漂移，本文通过固定预建地图定位减轻该问题，但地图本身的质量会直接影响定位效果；其二，激光几何约束依赖足够丰富的空间结构，在长直走廊、开阔区域、单一大平面或近距离遮挡严重场景中可能出现退化；其三，该启动重定位策略依赖近似初值和 ICP 收敛性，不适合直接处理完全未知初始位置。针对上述问题，后续可进一步引入全局点云描述子、回环检测或多源传感器辅助定位，以提升全局重定位能力和长期运行稳定性。

第 5 章 运维机器人障碍检测与环境感知算法设计

5.1 引言

自主移动机器人经常用于仓储搬用等室内场景，工作在由人、车辆、其他移动机器人以及货物货架等静态障碍物构成的复杂环境中。要确保机器人在这种复杂的动态环境中安全平稳导航完成任务，需要实时、准确地感知周围环境，为机器人导航决策提供有价值的信息。

移动机器人机载的检测与跟踪存在三个挑战。首先，有限的机载资源不适用于对 GPU 要求很高的基于学习^{[7][12]}的方法；考虑到计算约束，无法处理庞大的点云数据量，部署重型激光雷达系统也不切实际。其次，适合小型移动机器人的深度相机的范围和视场 (FOV) 是有限的，这使得障碍物要么太近，要么太远，在高速动态环境中无法实时获取周围障碍物信息，使得机器人运行困难。第三，相机获取到的深度值存在不可忽略的噪声，不仅会使得检测算法在计算点云时存在误差，造成障碍物状态估计的不准确，还会产生高频的假阳性和假阴性结果，使得下层规划器做出错误决策，极易引发安全事故。

在计算能力有限的小型机器人，可以根据传感器对检测和跟踪方法进行分类，包括 Lidar、事件相机、RGB-D 相机以及深度相机等。对于 Lidar 和深度相机，可以直接获取到空间点云数据提取出 3D 障碍物；除此以外，还可以基于采集到的图像进行障碍检测，利于深度图像生成 U 深度图和 V 深度图来估计障碍物状态。然而，由于噪声存在以及复杂的动态环境，以上两种检测方法都有可能会出现不同程度的误检。为此，本章提出了一种基于图像和点云数据融合的轻量级障碍物检测和跟踪方法，相比上述两种单个检测器的检测方法具有更高的精度。

本章提出了一种复杂环境下基于图像和点云数据融合的轻量级障碍物检测和跟踪方法。该方法结合了传统点云检测和图像检测高效率的优势，同时使用数据融合方法整合两个检测器来减轻两个方法各自的缺点。该检测器可接收图像数据或点云数据，以满足不同场景下的需求，确保移动机器人可以实时感知变电站的复杂环境。

本章的主要贡献要点如下：

(1) 基于图像和点云数据提出一种适合移动运维机器人在复杂环境下的障碍物检测算法，可以实时获取室内环境信息。

(2) 在动态障碍物识别层面，首先利用障碍物包围盒的速度区分是动态障碍物还是静态障碍物的，在此基础上提出了障碍物点云投票策略，减少了只单纯依

靠障碍物速度区分而产生的假阳性结果，提高了检测器对动态障碍物的敏感程度。

(3) 考虑到相机的检测范围和视场 (FOV) 受限，无法对移动机器人两侧以及身后的环境变化及时做出响应。提出了一种基于雷达数据融合的地图更新策略，不需要过大的算力开销，即可实现局部地图更新。

(4) 通过系统仿真实验，深入说明了上述障碍物检测与跟踪算法的有效性和性能优势。

5.2 点云聚类算法基础

如前所述，本章的点云检测器需要从第 3 章得到的三维点云中提取出离散的障碍物个体。由于第 3 章输出的点云仅是空间中大量无序的三维坐标点，其本身并不包含“哪些点属于同一个障碍物”这一语义信息，因此在进行包围盒估计之前，必须先将属于同一物体的点归并到一起。聚类算法正是完成这一任务的核心手段，它无需预先标注数据，即可依据点在空间中的分布自动划分出若干簇，每一个簇对应一个潜在的障碍物。因此，本节先对聚类算法的基本原理进行介绍，为后续点云检测器的设计奠定基础。

聚类算法是一类无监督的学习技术，目的是将数据集中的样本划分为若干簇。核心目标是使得同一簇的样本在特征空间上尽可能接近，不同簇的样本在特征空间上尽可能远离，而且无需预先标记数据，可以自动发现数据内在结构。换句话说，聚类是将数据分组为多个聚类，一个聚类中的组具有最大相似度，而聚类之间的数据具有最小相似度的过程。目前，聚类算法广泛应用于计算机视觉、图像分割、异常检测等领域。本文详细介绍两种聚类算法，分别是 K-Means 聚类和 DBSCAN 聚类。

5.2.1 K-Means 聚类

K-Means 是一种经典的聚类算法，该算法的思想根源可追溯至统计学中对均值的研究，早在 19 世纪，数学家们通过最小化距离平方和来寻找数据的中心点，但尚未将其系统化用于聚类。1956 年，Hugo Steinhaus 首次提出将数据划分为多个子集，并基于均值进行划分，奠定了 K-Means 的核心思想。该算法名称由 James MacQueen 在 1967 年首次提出，并将其应用于多元数据分析。K-Means 算法的基本原理是计算每个数据点与聚类中心的距离，然后算法将测量每个聚类的平均值，并迭代地划分类，直到覆盖所有聚类，不断重复此过程，直到它收敛。基于该聚类算法的实现原理，以下对其具体的实现过程进行详细阐述：

假设现在需要处理 N 维空间中 m 个数据点，将 m 个数据点划分为 k 个簇中，

并且使得同一簇内的数据点相似度最高，不同簇之间的数据点差异最大，定义优化目标函数如下：

$$S = \operatorname{argmin} \sum_{i=1}^k \sum_{x \in C_i} \|x - \mu_i\|^2 \quad (5-1)$$

其中， C_i 表示第 i 个簇， μ_i 是簇 C_i 的质心。从数据集中随机选取 k 个点作为初始质心，对每个数据点 x_j ，计算其到所有质心的距离，并将 x_j 分配到距离最近的质心对应的簇中，然后重新计算每个簇的新质心，计算公式如下：

$$\mu_i^{(t+1)} = \frac{1}{|C_i^{(t)}|} \sum_{x \in C_i^{(t)}} x \quad (5-2)$$

式中， t 表示迭代次数， $|C_i^{(t)}|$ 表示第 t 次迭代后第 i 个簇内数据点的数量， $\mu_i^{(t+1)}$ 表示第 $t+1$ 次迭代的簇 i 的质心。图 5-1 展示了将同一数据集应用 K-Means 算法划分成多个簇集合。




图 5-1 K-Means 聚类效果示意图

5.2.2 DBSCAN 聚类

DBSCAN 算法是一种基于密度的聚类算法，广泛应用于数据挖掘和机器学习等领域，最初由德国慕尼黑大学的数据库与数据挖掘实验室的 Martin Ester 等人于 1986 年提出。它能够识别任意形状的簇，并有效处理噪声数据，有效解决了 K-Means 算法无法处理非凸形状的簇、对噪声敏感、需要预先指导簇数量的局限性。其核心思想是将数据空间中高密度区域的连续部分构成一个簇，低密度区域则视为噪声。对于任意数据点 p ，其邻域定义为：

$$N_{\epsilon}(p) = \{q \in D \mid \text{dist}(p, q) \leq \epsilon\} \quad (5-3)$$

其中，其中 ϵ 是预设的邻域半径， D 是数据集， dist 是距离度量。若点 p 的邻域至少包含 MinPts 个样本，满足 $|N_{\epsilon}(p)| \geq \text{MinPts}$ ，则将点 p 视为核心点，反之将其视作噪声点。算法遍历数据集所有点，为每个核心点 p 创建新簇 C ，并将点 p 加入簇 C ，接着遍历 $N_{\epsilon}(p)$ 中的所有点 q ，若 q 是核心点，则将其邻域加入到待处理队列等待遍历完当前邻域再遍历子域，若 q 不属于任何簇，则将 q 加入簇 C 。重复上述步骤，直到遍历完除噪声以外所有的点。

与 K-Means 算法相比，DBSCAN 算法不需要预先指定划分簇的个数，但多了两个重要参数 ϵ 和 MinPts 。 ϵ 作为邻域半径直接确定了最终聚类簇的形状大小，而 MinPts 则决定了某个点能否被视作核心点。若 ϵ 取值过小，会使得一些原本属于同一个簇的数据被错误划分到不同簇，使得聚类过于分散；反之，若 ϵ 取值过大，会将不同类型数据错误划分到一类，无法准确区分不同数据点。 MinPts 取值过小，会导致将噪声点误认为是有效数据点；反之，如果取值过大则会将有效的数据误认为是噪声点而造成数据丢失。二者取值应结合实际情况合理选择，以提高聚类精度和数据分析的准确率。

在移动机器人检测领域，DBSCAN 算法可以对雷达或者深度相机获取到的点云数据进行聚类处理，提取出障碍物边界轮廓，用于路径规划或者三维空间重建。图 5-2 展示了 DBSCAN 处理非凸数据集相对于 K-Means 算法的优越性。

综合两种算法的特性可以看出，障碍物点云通常呈现任意形状、且不可预知簇数量、并伴随传感器噪声，这与 DBSCAN 算法所擅长处理的场景高度契合：它既无需预设障碍物数量，又能将离群噪声点自动剔除。因此，本章后续的点云检测器选用 DBSCAN 算法作为聚类内核，其检测流程将在下一节的障碍物检测跟踪系统中详细展开。




图 5-2 聚类效果对比示意图

5.3 障碍物检测跟踪系统

考虑部分移动机器人搭载的传感器以及算力限制，部署低算力需求的检测器很有必要。因此，提出一个新型的轻量级检测和跟踪框架，如图 5-3 所示，主要包括四个模块：检测模块、识别模块、跟踪模块和局部地图更新模块。检测模块可以根据移动机器人实际工作场景选择深度图像输入或者雷达点云输入，若选择深度图像输入，进入 U 深度检测器，同时从深度图像中提取得到点云数据送到 DBSCAN 检测器；若选择雷达点云输入，经过点云裁剪加工后直接进入 DBSCAN 检测器。识别模块根据障碍物状态和跟踪历史数据将障碍物分成静态和动态。跟踪模块关联障碍物历史数据并估计障碍物未来状态。该框架具体流程如下：首先使用深度图像或点云进行通用检测，识别相机视场内的所有障碍并将其封装成 AABB 轴对齐包围盒；然后应用识别模块识别检测到的障碍物，将其分成动态障碍物和静态障碍物；通过跟踪模块对障碍物状态进行跟踪和估计；最后，在二维栅格地图和体素地图中对当前检测结果进行更新。




图 5-3 障碍物检测与跟踪框架

5.3.1 三维障碍物检测器

环境检测由两个检测器组成，U 深度图和 DBSCAN 检测器，这两个检测器均为非学习式检测器，无需部署高算力硬件，在中小型移动机器人或者无人机环境检测中呈现很高的计算效率。同时，两种检测器检测结果所产生误差来自深度相机的不同来源（深度图像和点云），确保后续集成策略的有效性。

U 深度图检测器：U 深度图检测器在图像检测领域应用十分广泛，文献[?]将 U 深度图检测应用在杂乱动态环境中的微型无人机避障。文献[?]将其用于拥挤的室内环境下无人机避障。总体来说，检测器提取深度图像生成静态和动态的障碍物的 3D 边界框。U 深度图检测器总共有三个步骤：（1）U 深度图像的生成；（2）U 深度图像上的线段分组；（3）对原始的深度图像进行深度连续性搜索。

如图 5-4（a）和（b）分别显示了原始深度图像和 U 深度图像，当从相机获取到深度图像时，可以使用列深度值直方图来计算 U 深度图，U 深度图可以直观地看到从相机自上而下地视图，它的宽度与原始深度图像地宽度相同，其垂直轴从上到下表示距离摄像头的距离在增加。然后，对生成的 U 深度图进行线段分组，得到图 5-4（d）中宽度为 w ，厚度为 t 的障碍物的二维边界框。有了障碍物宽度 w ，然后对原始深度图像进行深度值连续性检查，得到图 5-4（a）所示障碍物的高度 h 。在 U 深度图和原始深度图像中同时拥有 2D 边界框后，可以将 3D 点三角剖分到相机帧中，并进行坐标变换，得到世界地图坐标帧的障碍物位置和维度。




图 5-4 检测器检测示意图

DBSCAN 检测器：与基于图像的检测器不同，DBSCAN 检测器使用点云数据来检测障碍物。DBSCAN 算法是第 5.2 节介绍的基于密度的无监督聚类算法，可以自动确定聚类数。当移动机器人遇到障碍物时，可以从深度图像中对原始点云数据进行三角测量，在图 5-4 中标注了相机坐标系，红色波段表示深度相机点云，彩色点簇为障碍物点云可视化。由于传感器的原因，点云数据在障碍物边界上可能会有噪声。因此，使用体素滤波器去除点云的噪声，然后进行 DBSCAN 聚类，与 U 深度图检测器类似，都可以得到障碍物的边界框（图 5-4 (c)）。DBSCAN 检测器不需要训练数据集，只需要少量的计算资源。

在上述框架中，两个检测器并行运行，分别检测障碍物的边界框。由于前面提到的检测器是为了补偿高速性能的检测精度而设计的，因此它们对不同的环境和传感器噪声都很敏感，从而导致误报和不准确的障碍物尺寸估计。所以，集合检测的目的是将不同检测器的检测结果结合起来，找到它们检测结果的“相互一致”，以降低噪声影响。集成检测方法可以获得精细障碍物的边界框，显著提高环境和传感器噪声下的检测鲁棒性和准确性。

所提出的集成检测算法遵循算法 5-1 中提出的成对方式。当获得两个检测包围盒序列 B_{d1} 和 B_{d2} 时，从第一个检测器的结果序列 (第 2 行) 中遍历每个包围盒 b_{d1} 。对于包围盒 b_{d1} ，算法从第二个检测器包围盒中找到具有最高交并比 (IOU) 分数的包围盒 b_{match1} (第 3 行)。通过在第一个检测器包围盒中找到 b_{match1} 的最高 IOU 匹配得到边界框 b_{match2} (第 4 行)。通过这个过程，可以找到两个检测器都检测到的包围盒。然后，需要确保它们匹配的边界框的 IOU 分数超过预定义的阈值，并且它们匹配的边界框彼此具有最高的 IOU 分数 (第 6 行)。最后，采用保守方法将两个包围盒融合成新的集成包围盒，具体策略是新的集成包围盒的空间维度取两个包围盒的最大值，坐标位置位置取两个包围盒的平均值。若包围盒融合失败，则保留独立的检测结果不做处理，赋予算法一定的鲁棒性。

算法 5-1: 集成检测算法

Input: 检测器 1 障碍物包围盒序列 B_{d1} , 检测器 2 障碍物包围盒序列 B_{d2} ,
最小交并比阈值 S_{thr}

Output: 集成包围盒序列 B_{en}

```

1 初始化  $B_{en} \leftarrow \emptyset$ ;
2 for  $b_{d1} \in B_{d1}$  do
3    $S_{iou1}, b_{match1} \leftarrow \text{findBestIOUMatch}(b_{d1}, B_{d2})$  // 找到最佳匹配盒
4    $S_{iou2}, b_{match2} \leftarrow \text{findBestIOUMatch}(b_{match1}, B_{d1})$  // 反向验证匹配
5    $flag \leftarrow (b_{match2} == b_{d1})$ ;
6   if  $S_{iou1} \geq S_{thr}$  and  $S_{iou2} \geq S_{thr}$  and  $flag$  then
7      $b_{en} \leftarrow \text{fuseBoxes}(b_{d1}, b_{match1})$  // 融合包围盒
8      $B_{en} \leftarrow B_{en} \cup \{b_{en}\}$ ;
9   else
10     $B_{en} \leftarrow B_{en} \cup \{b_{d1}\}$  // 保留独立检测结果
11  end
12 end
13 return  $B_{en}$ ;

```

5.3.2 障碍物关联跟踪

对于检测器来说, 当前时刻检测到的障碍物包围盒需要与历史包围盒数据进行对齐, 当前帧点云也要与历史点云匹配。在该模块首先应用基于特征的数据关联方法, 具体采用匈牙利算法^[7], 一种在多项式时间内求解任务分配问题的组合优化算法, 可以大幅提升当前时刻 t_n 检测到的障碍物与前一时刻 t_{n-1} 障碍物匹配的效率。考虑到噪声误差以及复杂环境变化, 相机在工作过程中可能会出现部分帧图像丢失, 不仅如此, 跟踪的动态障碍物在移动过程中可能会出现被短暂遮挡或者暂时离开视界范围的情况。如图 5-5, 在左图中, 移动机器人最初通过检测器检测到视场内的障碍物, 调用路径重规划产生无碰撞轨迹。然而在右图中, 遇到动态障碍物暂时离开机器人视场的情况, 导致检测器短暂丢失该动态障碍物状态信息。若对丢失的信息不做补偿, 机器人仍然按照原始规划路径行走, 在墙壁两侧不做任何避让, 则机器人很有可能会与突然出现的动态障碍物发生碰撞。

为了解决这个问题, 引入了视距外补偿机制来估计跟踪丢失时障碍物的状态。每当先前跟踪的动态障碍物包围盒离开传感器的视野时, 并不完全舍弃该障碍物历史状态信息, 而是将它的位置使用包含估计速度和加速度的恒定加速度模型进




图 5-5 动态障碍物遮挡示意图

行传播。这样可以应用该恒加速运动模型的卡尔曼滤波来估计障碍物的状态，以此来补偿障碍物视野丢失的关键帧，并将其添加到障碍物历史列表中。与匀速卡尔曼滤波模型相比，恒加速模型提供了更精确的状态估计和动态障碍物识别。

在复杂动态环境中，会出现动态障碍物与静态障碍物距离过近的情况，传统的基于中心距离的关联可能会错误地将不同属性的障碍物包围盒关联到一起，存在严重的安全风险，并不适用。因此提出基于特征的数据关联，使用特征比较将当前时刻 t_n 检测到的障碍物与前一时刻 t_{n-1} 的障碍物相关联。障碍物 O_i 的特征向量定义为：

$$feat(O_i) = [pos(i), dim(i), len(i), std(i)] \quad (5-4)$$

其中 $pos(i)$ 为障碍物包围盒的中心位置， $dim(i)$ 为障碍物包围盒在 x 、 y 、 z 方向上的尺寸， $len(i)$ 为包围盒内的点云大小， $std(i)$ 为包围盒内的点云标准差。然后，对特征向量执行归一化，以减少来自不同维度的影响。之后，使用如下公式计算障碍物 O_i 和 O_j 之间的相似度得分：

$$sim(O_i, O_j) = \exp(-\|feat(O_i) - feat(O_j)\|_2^2) \quad (5-5)$$

使用指数衰减函数将两个向量的欧几里得距离映射到 $(0,1]$ 区间内，使得相似度值随着欧几里得距离的增大而呈指数级衰减。当欧几里得距离为 0 时，相似度为 1，表示两个障碍物完全相同；随着欧几里得距离的增大，相似度逐渐减小，趋向于 0，表示两个障碍物越来越不相似。根据该策略，当前时刻 t_n 的障碍物 $O_i^{t_n}$ 可以与之前时刻 t_{n-1} 相似度得分最高的障碍物 $O_j^{t_{n-1}}$ 相匹配，最高相似度得分记为 sim_{max} 。此外，最高相似度得分必须高于预定义的阈值 ($sim_{max} > T_{sim}$)，防止出现不正确的关联。

障碍物关联完成后，使用恒加速运动模型的卡尔曼滤波估计每个障碍物

的状态。与匀速卡尔曼滤波模型相比，允许障碍物的速度变化又不会过多地增加运动模型的复杂性。在全局地图框架中，障碍物包围盒状态向量定义为 $X = [x, y, \dot{x}, \dot{y}, \ddot{x}, \ddot{y}]^T$ ，包括 x 和 y 方向上的位置、速度和加速度。测量向量与障碍状态向量相同。 t 时刻障碍物的速度矢量 V_i 和加速度矢量 A_i 的测量采用以下方程：

$$V_t = \frac{P_t - P_{t-1}}{\delta t}, A_t = \frac{V_t - V_{t-1}}{\delta t} \quad (5-6)$$

其中， P_t 表示当前时刻位置， P_{t-1} 表示上一时刻位置， δt 表示时间步长。取几个时间步长的数据来计算更平滑的观测值，系统模型被描述为：

$$X_{t|t-1} = F X_{t-1} + B u_{t-1} + W_k \quad (5-7)$$

其中 F 为状态转移矩阵，由于添加了加速度模型，状态转移矩阵的计算为：

$$F = \begin{bmatrix} 1 & 0 & \delta t & 0 & \frac{\delta t^2}{2} & 0 \\ 0 & 1 & 0 & \delta t & 0 & \frac{\delta t^2}{2} \\ 0 & 0 & 1 & 0 & \delta t & 0 \\ 0 & 0 & 0 & 1 & 0 & \delta t \\ 0 & 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 \end{bmatrix} \quad (5-8)$$

u 为控制输入，在本例中为零，过程噪声项服从零均值分布 $W_k \sim N(0, Q)$ ，协方差矩阵 Q 由加速度不确定性驱动：

$$Q = G Q_a G^T \quad (5-9)$$

$$G = \begin{bmatrix} \frac{1}{2}\delta t^2 & 0 & \delta t & 0 & 1 & 0 \\ 0 & \frac{1}{2}\delta t^2 & 0 & \delta t & 0 & 1 \end{bmatrix}^T \quad (5-10)$$

$$Q_a = \begin{bmatrix} \sigma_a^2 & 0 \\ 0 & \sigma_a^2 \end{bmatrix} \quad (5-11)$$

其中， G 表示噪声传播矩阵，反映加速度扰动对位置、速度状态的传递关系。 Q_a 是加速度噪声协方差矩阵， σ_a^2 是加速度噪声方差，用来描述障碍物实际运动与恒定加速度模型之间偏差，通过调节可以平衡过程模型与测量数据的权重：较大 σ_a^2 增强对观测的响应性，较小 σ_a^2 提升模型平滑性。观测模型建立状态与传感器测

量的映射关系：

$$Z_t = HX_t + R \quad (5-12)$$

$$H = \begin{bmatrix} 1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 & 0 \end{bmatrix} \quad (5-13)$$

其中 H 为测量矩阵， R 为测量噪声的协方差。

5.3.3 动态障碍物识别

本节将详细介绍如何识别障碍物的状态 (动态或静态)。动态障碍物识别的第一个标准是计算所有障碍物包围盒速度，若其中心速度 V_{box} 小于阈值 $v_{box_{th}}$ ，则将该障碍物归类为静态，反之则视为动态。虽然该速度标准理论上可以过滤掉所有的静态障碍物，但是实际中来自检测和状态估计的噪声会导致动态障碍物识别的假阳性。为了减少错误的识别结果，在第二步识别中，识别模块提取障碍物包围盒内点云的所有有效点对其状态进行投票。其算法伪代码如下：

算法 5-2: 动态障碍物检测分类算法

Input: 目标障碍物列表 B_{tar} , 障碍物历史包围盒信息 $BoxHist$, 障碍物历史点云序列 $PcHist$, 强制执行帧数 $forceFrame$, 包围盒速度阈值 $vbox_{th}$, 点云速度阈值 vpc_{th} , 投票比例阈值 $vote_{th}$

Output: 动态障碍物列表 B_{dy}

```

1  $B_{dy} \leftarrow \emptyset$ ;
2 for  $i \leftarrow 0$  to  $|B_{tar}| - 1$  do
3   DataAssociation( $B_{tar}[i], BoxHist$ ) // 关联当前包围盒与历史数据
4    $n \leftarrow |BoxHist[i]|$  // 获取历史列表长度
5   if  $\sum_{j=1}^n BoxHist[i][j].is\_dynamic \geq forceFrame$  then
6      $BoxHist[i][0].is\_dynamic \leftarrow true$ ;
7      $B_{dy}.push\_back(B_{tar}[i])$  // 添加到动态障碍物列表
8     continue;
9   end
10   $votes \leftarrow 0$  // 初始化点云投票数
11  Calculate  $Vbox$  // 计算当前包围盒速度
12  foreach  $p \in PcHist[i][0]$  do
13    Calculate  $Vp$  // 计算当前点云速度
14    if  $Vp \cdot Vbox \geq 0 \ \&\& \ \|Vp\| > vpc_{th}$  then
15       $votes \leftarrow votes + 1$ ;
16    end
17  end
18  if  $\|Vbox\| \geq vbox_{th} \ \&\& \ votes > vote_{th}$  then
19     $B_{dy}.push\_back(B_{tar}[i])$  // 添加到动态障碍物列表
20  end
21 end
22 return  $B_{dy}$ ;

```

识别算法检测到当前帧的障碍物包围盒后, 先调用障碍物数据关联模块关联跟踪当前帧障碍物和历史障碍物列表 (第 3 行)。然后检查与当前障碍物包围盒相关联的历史包围盒列表, 若该障碍物在多帧中被连续标记为动态障碍物 (第 5 行), 则跳过后续步骤强制标记该障碍物为动态 (注意: 此方法可能会造成对由运动转为静止的障碍物的误检, 但是可以有效防止动态障碍物由静止再转变为运动状态而导致移动机器人不能及时避让的情况发生)。然后计算当前包围盒速度, 采用当

前时刻和上一时刻的位置差分计算：

$$V_{box} = \frac{P_{box}(t) - P_{box}(t-1)}{\delta t} \quad (5-14)$$

接着遍历该包围盒内的所有点云，在这一步中，通过最近邻搜索，将当前时刻 t 的每个点与 $t-1$ 时刻的对应点进行匹配。确定对应关系后，计算每个点 V_p 的速度。然后，如果一个点的速度超过预定义的阈值 $v_{pc_{th}}$ (第 14 行)，它将投票给障碍物。如果动态投票数 $votes$ 与包围盒内有效点数的比值高于投票比例阈值 $vote_{th}$ (第 18 行)，则该障碍物将被识别为动态障碍物。

在进行动态投票过程之前，需要将无效点从点云中剔除。首先，如果障碍物 i 中的任意一个点 p ，具有无效的速度 V_p ，则将其从动态投票过程中移除。有效速度应满足点云速度与包围盒速度矢量夹角不超过 90° 且点云速度模长大于预定义的阈值 (第 14 行)。最后对与包围盒速度满足要求以及点云投票预期的障碍物将其添加到动态障碍物列表。




图 5-6 去除无效点云示意图

具体的点云剔除规则还需做如下补充：如果任意一点 p ，在 t 时刻可见而在 $t-1$ 时刻是不可见的，它也将从投票中删除。如图 5-6 所示，显示了机器人接近部分可见的静态障碍物的场景。在前一时刻 $t-1$ ，受视场限制检测器只检测到一小部分红色包围盒，其中红色的点云是可见的，检测到的障碍物中心为图中所示的红色五角星。而在当前时刻 t ，视场范围发生移动，障碍物包围盒大部分可见，障碍物中心随之发生移动。此时，若将绿色障碍物包围盒与前一时刻的红色包围盒相关联，计算结果必然会是包围盒速度大于阈值且其中的大部分点云都发生移动。在这种情况下，由于错误的点云相关联，障碍物会有较大的中心速度 V_{box} 和点云

投票速度 V_p 。因此算法 5-2 从投票中删除了新观察到的点，可以将该障碍物识别为静态。

5.4 局部地图构建策略

移动机器人在运动过程中根据传感器数据实时更新地图，首先基于深度图像反投影和点云直读方式获取三维观测数据，通过机体-相机/雷达坐标变换矩阵将感知数据转换至地图坐标系。本节实现了基于体素的占用栅格局部地图更新，该模块支持两类传感器输入模式：深度图模式与点云模式；同时支持两类定位输入：位姿与里程计。输入对通过近似时间同步进行配对，以保证单帧内传感器测量和位姿在时间上的一致性。

在线运行中，局部环境可能出现暂态误检或被遮挡区域的陈旧占用。系统维护历史自由区间与邻域窗口，通过局部清理对机器人附近的体素开展周期性释放或衰减，从而提升地图对动态或半静态环境的适应性。该小节的局部地图更新以概率图为理论框架，采用跳像素采样优化计算效率；然后采用改进的 Bresenham 光线投射算法^[7]遍历传感器视锥体内的栅格单元，基于对数概率模型进行动态贝叶斯更新。具体策略如下：

对每个有效量测点，构造从传感器光心指向端点的射线，采用 Bresenham 算法遍历射线路径上的体素序列。射线沿途体素被判定为自由单元，射线终端体素被判定为占用单元。遍历过程对自由与命中体素分别累积统计，以支持后续概率更新与可视化阈值化。占用概率模型如下：

$$L = \log \frac{p}{1-p} \quad (5-15)$$

其中，占用概率 $p \in (0, 1)$ ， L 为占用概率的对数几率（log-odds）。同时采用增量式贝叶斯更新，令自由体素的增量为 $l_{free} < 0$ ，命中（占用）体素的增量为 $l_{occ} > 0$ 。对体素 V 的递推为：

$$L_t(v) = \text{clip}(L_{t-1}(v) + \Delta L(v), L_{\min}, L_{\max}) \quad (5-16)$$

$$\Delta L(v) = \begin{cases} l_{\text{free}}, & v \in R_f \\ l_{\text{occ}}, & v = R_{\text{end}} \end{cases} \quad (5-17)$$

其中， $\text{clip}(\cdot)$ 用于对数值范围进行截断， $[L_{\min}, L_{\max}]$ 防止数值饱和与噪声放大， R_f 为沿射线的自由体素集合， R_{end} 为射线终端体素。

除了将障碍体素添加到环境中，还需将机器人几何尺寸、定位误差与控制跟

踪误差纳入环境约束，系统在占用图上执行体素形态学膨胀。记当前占用体素集合为 $O = \{v \mid p(v) > \tau\}$ ， τ 表示占据概率阈值，用来评判体素是否被占用，设膨胀半径为 r_{infl} ，膨胀后的障碍集合定义为：

$$O^{\oplus} = \{u \mid \exists v \in O, \|u - v\| \leq r_{\text{infl}}\} \quad (5-18)$$

其中 u 、 v 为对应体素的空间位置。实现中周期性对新近更新的局部地图执行膨胀，生成布尔化的“膨胀占用掩膜”，供路径规划与安全约束直接使用。该设计使得系统能够同时获得障碍物的边界信息与视线内自由空间的稀疏证据，从而为规划器提供可靠支持。

5.5 仿真实验验证

第 6 章 分层路径规划与学习增强局部避障方法

6.1 引言

前文围绕变电站运维机器人导航系统中的环境感知、障碍物检测跟踪和地图更新问题展开研究，已经获得局部占用地图、障碍物包围盒、点云聚类边界以及动态障碍物状态估计等信息。上述结果为路径规划提供了可计算的环境约束。本章在此基础上，设计一种面向变电站复杂受限空间的分层路径规划方法，使机器人能够在全局连通性、局部避障安全性和底盘可执行性之间取得平衡。

变电站环境具有设备密集、通道狭窄、障碍物形态不规则和安全裕度要求高等特点。若仅采用单一粒度的规划策略，往往难以同时满足长距离搜索效率和局部避障精度。一方面，在高分辨率栅格地图上直接搜索从起点到终点的完整轨迹，会使 A*、Dijkstra 等图搜索方法面临较大的计算开销；另一方面，若只在低分辨率地图或拓扑图上生成粗略路径，则路径缺少对设备边界、动态障碍物和底盘运动约束的细致刻画，难以直接作为控制指令执行。当环境中出现临时作业人员、检修工具或移动设备时，固定全局路径还可能因局部遮挡而频繁触发全局重规划，影响系统实时性和运行稳定性。

针对上述问题，本文采用“全局参考引导-局部滚动优化-底盘速度执行”的分层框架。全局层基于二维环境地图生成从起点到目标点的拓扑可行参考路径，主要解决长距离连通问题；局部层以全局路径为引导，融合第 5 章输出的实时障碍信息和动态状态估计，在有限预测时域内生成满足运动约束、平滑约束和避障要求的局部轨迹；执行层将局部规划器得到的首个最优控制量转换为全向底盘可执行的速度指令。全局参考路径的生成算法与局部规划器相互解耦，可根据地图类型由 RRT、A* 等方法替换；本文采用目标偏向 RRT 完成工程实现，而实验部分固定相同的全局参考路径，重点考察不同局部规划方法的性能差异。

本章主要包括以下内容：

(1) 构建全局参考路径生成与局部规划接口。采用目标偏向 RRT 搜索二维位置空间中的可行路径，并结合线段碰撞检测、超时处理、路径裁剪和平滑后验校验，为局部规划器提供连续的参考位置与航向序列。

(2) 构建学习增强 MPC 局部规划器。在分析 AABB 包络对非凸障碍物保守性的基础上，引入点级障碍表示和距离-分离方向编码器，将静态边界点及动态预测点流转化为可嵌入滚动优化的距离约束，并通过误差补偿、松弛变量和安全停车逻辑提高在线求解的鲁棒性。

(3) 设计全向底盘速度输出接口，并采用 Gazebo 仿真与实物平台进行验证。仿真设置规则凸障碍、L 型内凹目标、密集非凸障碍和混合动静态障碍四类场景，对比 AAB-B-MPC、DWA 与本文方法；实物实验则用于说明方法在真实感知与执行条件下的可部署性。

6.2 全局参考路径生成与分层规划接口

6.2.1 二维 RRT 参考路径生成

快速扩展随机树 (Rapidly-exploring Random Tree, RRT) 由 LaValle 提出^[2]，是一类面向连续配置空间的采样式路径规划方法。与需要预先构建完整图结构的栅格搜索方法不同，RRT 通过随机采样逐步扩展搜索树，能够较快发现从起点到目标点的可行连接。基础 RRT 具有概率完备性，但不保证路径最优，其输出通常需要进行进一步裁剪和平滑。

由于本文全局层仅负责在二维地图上生成拓扑可行的参考路径，而机器人航向由路径切线和局部规划器联合确定，因此全局搜索状态统一定义为 $q = (x, y)$ 。RRT 搜索树记为 $T = (V, E)$ ，其中节点集合 V 保存已探索的无碰位置，边集合 E 保存位置之间的无碰连接。算法从起点 q_{start} 出发，在自由空间中采样 q_{rand} ，选择距离采样点最近的树节点 q_{near} ，并沿 q_{near} 指向 q_{rand} 的方向扩展固定步长得到 q_{new} 。若连接线段通过碰撞检测，则将 q_{new} 加入搜索树；该过程持续到新节点能够与目标点 q_{goal} 无碰连接，或达到预设迭代次数与时间上限。

在分层框架中，RRT 输出只承担全局方向引导作用，不直接作为底盘执行轨迹。工程实现首先检测起点与目标点之间的线段是否无碰；若直连可行，则直接生成两点参考路径；否则启动 RRT 搜索。该处理既避免在开阔区域进行不必要的随机扩展，也不需要额外构造难以标定的地图复杂度指标。局部规划器只依赖统一的参考路径接口，因此 RRT 可由 A*、Dijkstra 等其他全局规划方法替换，不影响后续点级 MPC 的优化模型。

6.2.2 目标偏向采样、碰撞检测与超时处理

基础 RRT 完全随机采样时具有较强的空间探索能力，但在目标明确的导航任务中可能产生较多无效扩展。本文采用目标偏向采样策略：每次采样时，以概率 p_g 直接选取目标点 q_{goal} ，以概率 $1 - p_g$ 在自由空间内均匀采样。只要 $p_g < 1$ ，搜索仍保留对其他自由区域的探索能力；工程中根据地图尺度、扩展步长和最大迭代次数设置 p_g ，不再使用未经实验标定的经验加速公式。

为减少采样树进入障碍区域，扩展过程同时执行节点与边的碰撞检测。设机




图 6-1 RRT 参考路径生成流程

机器人平面外接半径为 r_b ，安全膨胀距离为 r_s ，障碍物集合为 $\mathcal{O}$ ，则新节点 q_{new} 需满足

$$d(q_{new}, \mathcal{O}) > r_b + r_s, \quad (6-1)$$

并对 q_{near} 与 q_{new} 之间的整条线段按固定间隔采样，要求所有检测点均位于膨胀障碍之外。障碍膨胀由第 5 章生成的局部或预建占用地图完成，使全局参考路径与机器人几何尺寸采用一致的安全边界。

为避免搜索在极端拥挤地图中长期阻塞，规划器设置最大迭代次数 N_{max} 和时间上限 t_{max} 。在限制内找到目标连接时返回可行路径；若搜索超时，则保留上一条仍通过碰撞复检的参考路径，并向任务层返回重规划状态。当旧路径已被新障碍阻断时，系统停止发布前进指令，等待地图更新后重新搜索，而不使用未经碰撞验证的直线路径作为回退结果。

算法 6-1 给出了参考路径生成流程。

算法 6-1: 目标偏向 RRT 参考路径生成

Input: $\mathcal{M}, q_s, q_g, p_g, N_{\max}, t_{\max}$
Output: $Path_g$ 及状态 z

```

1  膨胀障碍地图;
2  if  $Free(q_s, q_g)$  then
3       $Path_g \leftarrow \{q_s, q_g\}; z \leftarrow \text{成功};$ 
4      return  $Path_g, z;$ 
5   $T \leftarrow (\{q_s\}, \emptyset);$ 
6  for  $n = 1, \dots, N_{\max}$  且未超时 do
7      采样  $q_{rand}$  并扩展得到  $q_{new}$ ;
8      if  $Free(q_{near}, q_{new})$  then
9          将  $q_{new}$  及其边加入  $T$ ;
10         if  $Free(q_{new}, q_g)$  then
11             连接  $q_g$  并回溯  $Path_g$ ;
12             return  $Path_g$ , 成功;
13 return 旧有效路径或空路径, 重规划/停止;

```

6.2.3 路径后处理与局部规划接口

RRT 回溯得到的原始路径通常由若干折线段组成, 存在折角较大、曲率不连续和局部冗余节点等问题。若直接将该路径作为局部规划参考, MPC 需要频繁调整参考航向和速度, 可能造成轨迹抖动。因此, 本文对全局路径进行两级后处理。

首先执行冗余节点裁剪。对于路径中的连续节点 x_i, x_{i+1} 和 x_j , 若 x_i 与 x_j 之间的线段通过碰撞检测, 则删除中间冗余节点。该步骤能够减少由随机树扩展带来的锯齿形路径。其次, 对裁剪后的路径进行三次样条插值, 生成连续参考曲线:

$$\mathbf{r}_g(\xi) = [x_g(\xi), y_g(\xi)]^T, \quad \xi \in [0, 1], \quad (6-2)$$

并按照固定弧长间隔重新采样, 得到供局部规划器使用的参考点序列。为防止平滑曲线穿越障碍物, 系统在插值后再次进行碰撞检测; 若平滑曲线局部不可行, 则保留该段原始折线或降低插值跨度。由此得到的全局路径既保留 RRT 搜索得到的拓扑连通性, 又具备更好的连续性和可跟踪性。

6.3 面向局部避障的学习增强 MPC 规划器

6.3.1 滚动优化框架与底盘运动模型

模型预测控制 (Model Predictive Control, MPC) 是一种基于系统模型进行在线滚动优化的控制方法。与仅根据当前误差计算控制量的反馈控制不同, MPC 在每

个控制周期内预测未来有限时域中的状态序列，并在路径跟踪、控制平滑、运动约束和避障约束之间进行联合优化。优化得到的控制序列只执行首个控制量，随后利用新的定位与感知结果重新构造优化问题。该“预测-优化-执行-反馈”机制适合处理移动机器人局部规划中的动态避障和轨迹跟踪问题。




图 6-2 模型预测控制滚动优化原理

在本文系统中，局部规划器一方面接收 RRT 全局路径作为参考轨迹，另一方面接收第 5 章输出的局部地图、点云聚类边界、包围盒和动态障碍物状态估计。其总体结构如图 6-3 所示。该结构并非完全依赖端到端学习输出控制指令，而是在可解释的 MPC 框架内引入学习型距离特征，使规划器既能保持运动约束和安全约束的可控性，又能更充分地利用点云边界信息。




图 6-3 学习增强 MPC 局部规划器总体架构

考虑本文机器人采用全向移动底盘，局部规划状态定义为

$$\mathbf{s}_k = [x_k, y_k, \theta_k]^T, \quad (6-3)$$

其中 x_k 、 y_k 为地图坐标系下的位置， θ_k 为航向角。为使优化变量与底层速度接口保持一致，本文始终在机器人机体系下定义全向底盘控制量：

$$\mathbf{u}_k = [v_{x,k}^b, v_{y,k}^b, \omega_k]^T, \quad (6-4)$$

其中 $v_{x,k}^b$ 、 $v_{y,k}^b$ 分别为机体系前向和侧向速度， ω_k 为绕竖直轴的角速度。设 $R(\theta_k)$ 为式 6-9 所示的二维旋转矩阵，则机体系平移速度经 $R(\theta_k)$ 转换到地图坐标系。在采样周期 Δt 内，全向底盘离散运动模型为

$$\mathbf{s}_{k+1} = f(\mathbf{s}_k, \mathbf{u}_k) = \begin{bmatrix} x_k + (v_{x,k}^b \cos \theta_k - v_{y,k}^b \sin \theta_k) \Delta t \\ y_k + (v_{x,k}^b \sin \theta_k + v_{y,k}^b \cos \theta_k) \Delta t \\ \theta_k + \omega_k \Delta t \end{bmatrix}. \quad (6-5)$$

由于旋转矩阵随航向角变化，式 6-5 是非线性模型。为在滚动优化中构造可快速求解的子问题，在上一轮名义状态 $\bar{\mathbf{s}}_k$ 和名义控制 $\bar{\mathbf{u}}_k$ 附近进行一阶线性化：

$$\mathbf{s}_{k+1} \approx A_k \mathbf{s}_k + B_k \mathbf{u}_k + \mathbf{c}_k, \quad (6-6)$$

其中

$$A_k = \begin{bmatrix} 1 & 0 & (-\bar{v}_{x,k}^b \sin \bar{\theta}_k - \bar{v}_{y,k}^b \cos \bar{\theta}_k) \Delta t \\ 0 & 1 & (\bar{v}_{x,k}^b \cos \bar{\theta}_k - \bar{v}_{y,k}^b \sin \bar{\theta}_k) \Delta t \\ 0 & 0 & 1 \end{bmatrix}, \quad (6-7)$$

$$B_k = \begin{bmatrix} \cos \bar{\theta}_k \Delta t & -\sin \bar{\theta}_k \Delta t & 0 \\ \sin \bar{\theta}_k \Delta t & \cos \bar{\theta}_k \Delta t & 0 \\ 0 & 0 & \Delta t \end{bmatrix}, \quad \mathbf{c}_k = f(\bar{\mathbf{s}}_k, \bar{\mathbf{u}}_k) - A_k \bar{\mathbf{s}}_k - B_k \bar{\mathbf{u}}_k. \quad (6-8)$$

式 6-6 至式 6-8 构成本文全向底盘 MPC 的动力学约束。若规划器迁移到差速或阿克曼底盘，则应分别替换为对应的非完整运动模型和控制向量，不能将不同物理含义的控制量混合使用。

6.3.2 包络约束 MPC 的保守性分析

第 5 章已经完成障碍物检测、跟踪和地图更新。实时障碍物由深度图像检测器和点云聚类检测器融合得到包围盒，动态障碍物进一步通过数据关联和恒加速度模型获得状态估计。从工程接口角度看，最直接的局部避障方式是将 AABB 包围盒或旋转包围盒转化为 MPC 中的几何约束。

设第 j 个障碍物在预测步 k 的中心为 $\mathbf{o}_{j,k} = [x_{j,k}, y_{j,k}]^T$ ，包络椭圆长短轴半径分别为 a_j 和 b_j ，方向角为 ϕ_j 。机器人相对障碍物中心的位置为 $\Delta \mathbf{p}_{j,k} = [x_k - x_{j,k}, y_k - y_{j,k}]^T$ ，旋转矩阵为

$$R(\phi_j) = \begin{bmatrix} \cos \phi_j & -\sin \phi_j \\ \sin \phi_j & \cos \phi_j \end{bmatrix}. \quad (6-9)$$

则椭圆包络避障约束可写为

$$\left\| \begin{bmatrix} 1/a_j & 0 \\ 0 & 1/b_j \end{bmatrix} R(\phi_j)^T \Delta \mathbf{p}_{j,k} \right\|_2 \geq 1 + \delta_s, \quad (6-10)$$

其中 δ_s 为安全裕度。对于动态障碍物，可利用第 5 章得到的状态估计 $\hat{\mathbf{S}}_j(t)$ 进行短时预测：

$$\mathbf{S}_{j,k+\tau} = F^T \hat{\mathbf{S}}_j(t), \quad (6-11)$$

$$F = \begin{bmatrix} 1 & 0 & \Delta t & 0 & \frac{1}{2}\Delta t^2 & 0 \\ 0 & 1 & 0 & \Delta t & 0 & \frac{1}{2}\Delta t^2 \\ 0 & 0 & 1 & 0 & \Delta t & 0 \\ 0 & 0 & 0 & 1 & 0 & \Delta t \\ 0 & 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 \end{bmatrix}. \quad (6-12)$$

式 6-11 和式 6-12 分别表示动态障碍物在恒加速度模型下的预测状态和状态转移矩阵，状态量可包含二维位置、速度和加速度。

包络约束具有实现简单、接口清晰的优点，但在变电站复杂场景下存在明显保守性。首先，变压器支架、电缆沟边缘、检修设备和临时工具常具有非凸或细长结构，若统一使用 AABB 或椭圆包络，会把真实可通行区域错误归入障碍区域。其次，检测误差、包围盒融合误差和动态预测误差会在“检测-包络-约束”链路中逐层传播，MPC 为了保证安全往往需要增大 δ_s ，进一步压缩可行空间。最后，在设备密集区域显式维护多个包络体约束会提高优化规模，容易导致局部轨迹绕行、停滞或频繁重规划。

如图 6-4 所示，传统包络约束会把非凸障碍物内部的部分可行空间一并排除，而点级表示直接保留障碍物边界点及局部分离方向。因此，本文在保留包围盒结果作为稳定工程接口的同时，引入点级障碍表示与学习型距离特征：对规则、稀疏障碍物可采用包络约束快速处理；对非凸、密集或边界形态复杂的障碍物，则




图 6-4 包络约束与点级障碍表示对比

直接利用边界点构造局部避障正则。

6.3.3 点级障碍表示与动态预测点流

为了使局部规划器能够直接利用感知结果，本文将局部障碍信息统一表示为二维点集：

$$\mathcal{P}_t = \{\mathbf{p}_t^1, \mathbf{p}_t^2, \dots, \mathbf{p}_t^M\}, \quad \mathbf{p}_t^i \in \mathbb{R}^2, \quad (6-13)$$

其中 M 为当前局部感知范围内的障碍点数量。点集 $\mathcal{P}_t$ 由三类数据共同生成：激光雷达或深度相机获得的有效地面投影点、DBSCAN 聚类后保留的障碍物边界点，以及由 AABB 或旋转包围盒边界采样得到的结构化障碍点。通过这种统一表达，第 5 章中的包围盒检测结果不会被舍弃，而是被转换为点级约束输入。

对于已由第 5 章跟踪模块估计运动状态的动态障碍点，在 MPC 预测时域内沿用恒加速度模型构造预测点流：

$$\mathbf{p}_{k|t}^i = \mathbf{p}_t^i + k\Delta t \mathbf{v}_t^i + \frac{1}{2} (k\Delta t)^2 \mathbf{a}_t^i, \quad k = 0, 1, \dots, N, \quad (6-14)$$

其中 $\mathbf{v}_t^i$ 和 $\mathbf{a}_t^i$ 分别为第 i 个障碍点在时刻 t 继承的速度和加速度。同一障碍物的边界点共享该目标恒加速度卡尔曼状态中的速度、加速度估计，从而使点级预测与式 6-11 保持一致。对于静态障碍点或无法可靠关联到动态目标的点，令 $\mathbf{v}_t^i = \mathbf{0}$ 且 $\mathbf{a}_t^i = \mathbf{0}$ 。由于点级输入数量可能较大，本文依据感知距离、点云密度、机器人前方扇区和与全局参考路径的相关性进行下采样，优先保留距离近、位于参考路径附近且可能影响当前避障决策的点。

在预测步 k ，障碍点需要从地图坐标系变换到机器人局部坐标系。设机器人平移向量为 $\mathbf{r}(\mathbf{s}_k) = [x_k, y_k]^T$ ，航向旋转矩阵为 $R(\theta_k)$ ，则第 i 个障碍点在机器人坐标

系下的位置为

$$\bar{\mathbf{p}}_{k|t}^i = R(\theta_k)^T (\mathbf{p}_{k|t}^i - \mathbf{r}(\mathbf{s}_k)). \quad (6-15)$$

式 6-15 体现了局部规划中的感知与运动耦合关系：同一障碍点在地图坐标系中位置固定，但其在机器人局部坐标系中的相对位置会随预测位姿变化而变化。因此，避障代价应随预测轨迹同步更新，而不能只由当前点云的静态分布决定。

6.3.4 神经网络编码器结构与点级特征生成

上一节得到的预测障碍点流还需转换为能够参与机器人几何约束计算的低维特征。本文借鉴直接点机器人导航方法^[2]，并以 NeuPAN 代码中的 `ObsPointNet` 为实现依据构造点级几何编码器。该网络不处理图像或固定尺寸栅格，而是对每个预测时刻、每个障碍点的二维局部坐标独立映射，并在全部点和预测步之间共享参数。

为使不同底盘尺度下的输入范围可控，本文在编码器接口处将式 6-15 所得局部点写为

$$\tilde{\mathbf{p}}_{k|t}^i = D_r^{-1} \bar{\mathbf{p}}_{k|t}^i, \quad (6-16)$$

其中 D_r 为由底盘尺度和有效感知范围确定的对角矩阵。NeuPAN 当前实现将局部坐标直接送入网络，对应 $D_r = I$ ；若本文实验启用尺度归一化，则离线数据生成、网络训练和在线推理必须使用同一 D_r 。设机器人凸轮廓共有 n_e 条半空间边界，即 $G \in \mathbb{R}^{n_e \times 2}$ ，逐点编码结果为

$$\boldsymbol{\mu}_{k,i} = f_{\Theta}(\tilde{\mathbf{p}}_{k|t}^i), \quad \boldsymbol{\mu}_{k,i} \in \mathbb{R}_{\geq 0}^{n_e}, \quad (6-17)$$

其中 f_{Θ} 表示参数为 Θ 的神经网络， $\boldsymbol{\mu}_{k,i}$ 是与机器人半空间几何相容的潜在特征，不是速度或控制量；其维数由机器人轮廓边界数决定，而不是固定为某一常数。

`ObsPointNet` 采用隐藏宽度为 32 的多层感知机。按照源码，其线性层维数依次为

$$2 \rightarrow 32 \rightarrow 32 \rightarrow 32 \rightarrow 32 \rightarrow 32 \rightarrow n_e, \quad (6-18)$$

第 1、3、5 个隐藏线性层之后依次连接 `LayerNorm` 和 `Tanh`，第 2、4 个隐藏线性层之后连接 `ReLU`，输出层之后也使用 `ReLU` 以产生非负特征。该结构逐点共享权重，因此障碍点数量增加时主要增加批量前向计算量，不改变网络参数规模。

图 6-5 给出了编码器的计算流程。输入端将一个批次中的障碍点组织为矩阵，随后对每个点独立执行全连接映射和非线性变换；图中标注的 $(MH \times n)$ 、 $(n \times 32)$ 和 (32×32) 分别表示批量点特征、首层权重以及隐藏层权重的示意维度。在本文

实现中，单个障碍点的输入维度为二维坐标，即 $n = 2$ ；输出层的列数由机器人凸轮廓边数决定，因此一般写为 n_e ，而非固定为图中的单列示意。图中底部的更新标记表示网络在离线训练阶段通过监督标签更新参数，在线规划阶段则加载固定参数，仅执行前向推理。




图 6-5 点级神经网络编码器的结构与点级特征生成流程

表 6-1 点级神经网络编码器的结构与在线接口

接口或结构项	实现说明
输入	预测障碍点的二维机器人局部坐标；启用归一化时使用 $\tilde{\mathbf{p}}_{k t}^i$
参数共享	所有障碍点及所有预测时刻共享同一编码器 f_Θ
隐藏表示	5 个 32 维隐藏线性层
归一化与激活	第 1、3、5 个隐藏层使用 LayerNorm+Tanh，第 2、4 个隐藏层使用 ReLU
输出	n_e 维非负潜在特征 $\mu_{k,i}$ ， n_e 等于 G 的行数
在线模式	加载固定 checkpoint，关闭梯度并切换至评估模式
点数管理	编码前按 <code>dune_max_num</code> 下采样，编码后按距离排序，并向优化层传入不超过 <code>nrmp_max_num</code> 个近邻点

在 DUNE 在线流程中，各预测步的局部点流沿点维度拼接后只进行一次批量网络前向计算，再按照各时刻的点数切分 μ 。记 $R_k = R(\theta_k)$ ，则源码由潜在特征构造世界坐标系中的分离方向相关量和距离相关量：

$$\lambda_{k,i} = -R_k G^T \mu_{k,i}, \quad (6-19)$$

$$d_{k,i}^{\text{enc}} = \mu_{k,i}^T (G \tilde{\mathbf{p}}_{k|t}^i - \mathbf{h}). \quad (6-20)$$

式 6-20 用于按间距由小到大排序障碍点。本文在逐次线性化 MPC 中使用单位方向，因此进一步令

$$\hat{\lambda}_{k,i} = \frac{\lambda_{k,i}}{\max(\|\lambda_{k,i}\|_2, \varepsilon)}, \quad (6-21)$$

其中 ε 为防止除零的小正数。需要指出，源码中的 DUNE 负责生成 μ 、 λ 和距离相关量，NRMP 负责将这些系数写入带动力学与距离约束的优化问题，PAN 则交替更新名义轨迹和点级特征。本文采用 DUNE 的点级几何编码方式，但将其输出嵌入本文定义的学习增强 MPC，并不把完整 PAN/NRMP 直接等同于本文规划器。状态预测、控制限幅、松弛变量、速度输出和异常停车仍由 MPC 与任务安全逻辑负责。

当前实现的二维输入、32 维隐藏层和 n_e 维输出依赖机器人几何配置。更换机器人轮廓或输入尺度后，应重新生成监督数据并核验模型；正式实验还需归档 checkpoint、代码版本、运行设备、两级点数上限、批量推理耗时和距离误差统计。

6.3.5 距离-分离方向编码器及离线训练

若在线对每个障碍点、每个预测步反复求解点到凸多边形的精确距离问题，计算量会随障碍点数 M 和预测时域长度 N 迅速增加。为此，本文将精确几何计算放到离线数据生成阶段，用式 6-17 所示网络近似其最优对偶特征，在线阶段再通过简单矩阵运算恢复距离和分离方向。

设机器人在自身坐标系下的占用轮廓为

$$C_r = \{ \mathbf{z} \in \mathbb{R}^2 \mid G\mathbf{z} \leq \mathbf{h} \}, \quad (6-22)$$

其中 $G \in \mathbb{R}^{n_e \times 2}$ 和 $\mathbf{h} \in \mathbb{R}^{n_e}$ 由底盘几何确定。对于离线采样点 $\mathbf{p}_i$ ，DUNE 训练代码通过如下凸对偶问题生成监督标签：

$$\begin{aligned} (d_i^*, \mu_i^*) = & \arg \max_{\mu_i} / \text{value} \quad \mu_i^T (G\mathbf{p}_i - \mathbf{h}), \\ \text{s.t.} \quad & \|G^T \mu_i\|_2 \leq 1, \quad \mu_i \geq \mathbf{0}. \end{aligned} \quad (6-23)$$

为避免在同一符号中混写最优变量和最优值，式 6-23 中的 μ_i^* 表示最优解， d_i^* 表示相应目标函数值。对机器人轮廓外部的点，该最优值等于点到凸轮廓的欧氏间距；对轮廓内部或边界上的点，该非负对偶形式返回零间距。与人工指定“最近边类别”不同， μ_i^* 是由半空间几何优化得到的非负对偶特征，可在边和顶点邻域表达多个活跃边界的共同作用。

网络预测 $\hat{\mu}_i = f_{\Theta}(\tilde{\mathbf{p}}_i)$ 后，距离预测为

$$\hat{d}_i = \hat{\mu}_i^T (G\mathbf{p}_i - \mathbf{h}). \quad (6-24)$$

训练代码还随机采样旋转角 ϑ_i 并构造 $R_i = R(\vartheta_i)$ ，以约束由 $\boldsymbol{\mu}$ 导出的方向系数和仿射偏置：

$$\mathbf{f}_{a,i} = -R_i G^T \boldsymbol{\mu}_i, \quad (6-25)$$

$$f_{b,i} = \mathbf{f}_{a,i}^T \mathbf{p}_i + \boldsymbol{\mu}_i^T \mathbf{h}. \quad (6-26)$$

于是，与当前 DUNETrain 实现一致的批量监督损失可写为

$$\mathcal{L}_d = \frac{1}{N_s} \sum_{i=1}^{N_s} \left(\|\hat{\boldsymbol{\mu}}_i - \boldsymbol{\mu}_i^*\|_2^2 + |\hat{d}_i - d_i^*|^2 + \|\hat{\mathbf{f}}_{a,i} - \mathbf{f}_{a,i}^*\|_2^2 + |\hat{f}_{b,i} - f_{b,i}^*|^2 \right), \quad (6-27)$$

其中 N_s 为批量样本数，带“*”的方向系数和偏置由 $\boldsymbol{\mu}_i^*$ 计算，带“^”的量由网络输出 $\hat{\boldsymbol{\mu}}_i$ 计算。四项均采用均方误差并直接求和；若正式实验改变损失权重，应在训练记录中明确给出，不能沿用未验证的经验值。

当前训练程序在给定矩形范围内均匀随机采样二维点，通过 CVXPY/ECOS 逐点求解式 6-23，再按 80%/10%/10% 划分训练集、验证集和测试集。代码默认训练入口使用 Adam 优化器、批量大小 256、初始学习率 5×10^{-5} 、学习率衰减系数 0.5 和 5000 轮训练，并在优化器初始化时设置 10^{-4} 的权重衰减；这些是源码默认值而非本文最终实验参数。正式实验应依据实际运行配置、随机种子和保存的 train_dict.pkl 填写表 6-2。

表 6-2 距离-分离方向编码器训练记录项

配置项	记录内容
机器人几何 采样设置	实际 $G, \mathbf{h}$ 、底盘尺寸及输入尺度矩阵 D_r 实际采样范围、样本数与随机种子；当前代码采用矩形域均匀采样
标签求解 网络结构 数据划分 优化设置	式 6-23 所示对偶问题，当前代码使用 CVXPY/ECOS 表 6-1 所示结构及实际代码版本 当前代码为训练/验证/测试 = 80%/10%/10% 实际优化器、学习率、权重衰减、批量大小、训练轮数及衰减策略
损失与评价	$\boldsymbol{\mu}$ 、距离、方向系数和偏置 MSE；距离 MAE/RMSE、方向角误差及推理耗时
模型归档	checkpoint 路径、文件哈希、保存轮次、运行设备与软件版本

训练完成后，编码器参数 Θ 在在线规划期间保持固定。编码器并入规划器前

需使用独立测试集报告距离平均绝对误差、均方根误差、分离方向角误差和批量推理耗时。这些量用于确认几何近似是否满足部署要求，不能单独证明完整规划器的性能提升；正式论文中的配置和误差数值必须来自实际训练日志，不作推测填写。

为避免编码器低估真实距离造成安全裕度缩小，记测试集中距离低估误差 $e_i = d_i^* - \hat{d}_i$ 的高分位统计量为 ε_d ，在线规划使用保守距离

$$\hat{d}_{k,i}^{\text{safe}} = \hat{d}_{k,i} - \varepsilon_d. \quad (6-28)$$

其中 ε_d 应由实际测试集统计确定，而非作为经验常数手工设定。

为了使分离方向真正参与轨迹修正，在第 l 次感知-运动耦合迭代中，先以名义状态 $\bar{\mathbf{s}}_k^{(l)}$ 计算名义局部障碍点 $\bar{\mathbf{p}}_{k|t}^{i,(l)}$ ，再由编码器得到 $\hat{d}_{k,i}^{(l)}$ 和 $\hat{\boldsymbol{\lambda}}_{k,i}^{(l)}$ 。令局部障碍点关于机器人状态的雅可比为

$$J_{p,k,i}^{(l)} = \left. \frac{\partial}{\partial \mathbf{s}} \left[R(\theta)^T (\mathbf{p}_{k|t}^i - \mathbf{r}(\mathbf{s})) \right] \right|_{\mathbf{s}=\bar{\mathbf{s}}_k^{(l)}}, \quad (6-29)$$

则编码器距离沿状态增量的一阶近似为

$$\tilde{d}_{k,i}^{(l)}(\mathbf{s}_k) = \hat{d}_{k,i}^{(l)} + \left(J_{p,k,i}^{(l)T} \hat{\boldsymbol{\lambda}}_{k,i}^{(l)} \right)^T (\mathbf{s}_k - \bar{\mathbf{s}}_k^{(l)}). \quad (6-30)$$

式 6-30 把机体系分离方向通过坐标变换雅可比映射为状态空间中的距离梯度。因此，当某个预测状态违反安全距离时，MPC 子问题会沿 $J_{p,k,i}^{(l)T} \hat{\boldsymbol{\lambda}}_{k,i}^{(l)}$ 所确定的方向修正位置和航向，而不是只使用一个不含方向信息的标量惩罚。每轮迭代中固定编码器输出和雅可比，求解线性化子问题后更新名义轨迹，再重新计算下一轮距离与分离方向。

6.3.6 带误差补偿的优化模型与在线求解流程

基于上述点级距离特征，局部规划问题可构造为学习增强 MPC。设预测时域长度为 N ，参考状态序列 $\mathbf{s}_k^{\text{ref}}$ 由全局参考路径中距离机器人最近的路径点向前重采样获得，参考控制 $\mathbf{u}_k^{\text{ref}}$ 由参考路径切向方向和平滑速度规划得到。优化变量包括预测状态序列 $\mathbf{s}_{0:N}$ 、控制序列 $\mathbf{u}_{0:N-1}$ 、自适应安全距离 $d_{0:N-1}$ 及非负松弛变量

$\xi_{k,i}$ 。目标函数为

$$\begin{aligned} \min_{\mathbf{s}, \mathbf{u}, \mathbf{d}, \xi} J = & \sum_{k=0}^N \left\| Q_s (\mathbf{s}_k - \mathbf{s}_k^{\text{ref}}) \right\|_2^2 + \sum_{k=0}^{N-1} \left\| Q_u (\mathbf{u}_k - \mathbf{u}_k^{\text{ref}}) \right\|_2^2 \\ & + \sum_{k=1}^{N-1} \left\| Q_{\Delta u} (\mathbf{u}_k - \mathbf{u}_{k-1}) \right\|_2^2 + \rho_{\xi} \sum_{k=0}^{N-1} \sum_{i \in \mathcal{I}_k} \xi_{k,i}^2 - \eta \sum_{k=0}^{N-1} d_k, \end{aligned} \quad (6-31)$$

其中 Q_s 、 Q_u 和 $Q_{\Delta u}$ 分别为状态跟踪、控制跟踪和控制平滑权重矩阵， ρ_{ξ} 为安全约束松弛惩罚权重， η 为安全距离调节权重， $\mathcal{I}_k$ 表示预测步 k 中参与优化的近邻障碍点集合。 ρ_{ξ} 应显著大于一般跟踪权重，使优化器仅在模型误差、突发障碍或暂时不可行时使用松弛量。

在第 l 轮逐次线性化中，将式 6-30 中的名义距离替换为误差补偿后的 $\hat{d}_{k,i}^{\text{safe}}$ ，得到保守线性化距离 $\tilde{d}_{k,i}^{\text{safe},(l)}(\mathbf{s}_k)$ 。学习增强 MPC 的约束条件为

$$\mathbf{s}_0 = \mathbf{s}(t), \quad (6-32)$$

$$\mathbf{s}_{k+1} = A_k \mathbf{s}_k + B_k \mathbf{u}_k + \mathbf{c}_k, \quad k = 0, \dots, N-1, \quad (6-33)$$

$$\mathbf{u}_{\min} \leq \mathbf{u}_k \leq \mathbf{u}_{\max}, \quad k = 0, \dots, N-1, \quad (6-34)$$

$$\Delta \mathbf{u}_{\min} \leq \mathbf{u}_k - \mathbf{u}_{k-1} \leq \Delta \mathbf{u}_{\max}, \quad k = 1, \dots, N-1, \quad (6-35)$$

$$\tilde{d}_{k,i}^{\text{safe},(l)}(\mathbf{s}_k) \geq d_k - \xi_{k,i}, \quad \xi_{k,i} \geq 0, \quad (6-36)$$

$$d_{\min} \leq d_k \leq d_{\max}, \quad k = 0, \dots, N-1. \quad (6-37)$$

上述约束使预测轨迹从当前状态出发并满足全向底盘运动学、速度限幅和控制增量限制。式 6-36 以补偿后的保守距离约束机器人与障碍点的间隔，并用 $\xi_{k,i}$ 避免极端情况下优化问题完全不可解；式 6-37 则允许安全距离在给定区间内调整。由于编码器近似误差、线性化误差和感知误差仍然存在，该模型用于提高安全裕度和降低碰撞风险，并不构成形式化安全证明。

学习增强 MPC 局部规划器的在线求解流程如算法 6-2 所示。规划器先从全局路径中截取预测时域内的参考状态序列，再将实时点云、聚类边界点和包围盒采样点统一转换为障碍点集，并根据第 5 章恒加速度状态估计生成动态障碍预测点流。随后，规划器在每轮迭代中将预测点流变换到名义机器人局部坐标系，利用距离-分离方向编码器计算距离与局部法向，通过式 6-30 构造线性化避障项并嵌入 MPC 子问题。




图 6-6 学习增强 MPC 滚动优化闭环流程

算法 6-2: 学习增强 MPC 局部规划器

Input: 机器人当前状态 $s(t)$ ，全局路径 $Path_g$ ，局部地图 $\mathcal{M}_l$ ，障碍物检测与跟踪结果 $\mathcal{O}_t$

Output: 局部最优轨迹 $Path_l$ ，控制指令 u_0^*

- 1 从 $Path_g$ 中选取距离 $s(t)$ 最近的路径点，并向前重采样得到 $s_{0:N}^{\text{ref}}$
- 2 由 $\mathcal{M}_l$ 、点云聚类结果和包围盒边界采样生成障碍点集 $\mathcal{P}_t$
- 3 根据动态障碍物状态估计为其边界点继承速度 v_t^i 和加速度 a_t^i ，静态点或状态不可靠点均置零
- 4 初始化名义状态序列 $\bar{s}_{0:N}$ 和名义控制序列 $\bar{u}_{0:N-1}$
- 5 **for** $l = 1, \dots, K_{\max}$ **do**
- 6 依据式 6-14 生成恒加速度预测点流 $p_{k|t}^i$
- 7 依据式 6-15 和名义状态将预测点流转换到机器人局部坐标系
- 8 利用式 ?? 计算 $\hat{d}_{k,i}^{(l)}$ 、 $\mu_{k,i}^{(l)}$ 和 $\hat{\lambda}_{k,i}^{(l)}$ ，并按式 6-28 修正距离
- 9 依据式 6-29 和式 6-30 构造保守线性化距离 $\tilde{d}_{k,i}^{\text{safe},(l)}$
- 10 按距离和参考路径相关性选取近邻障碍点集合 $\mathcal{I}_k$
- 11 固定本轮距离特征与雅可比，构造式 6-31 至式 6-37 所示子问题并求解
- 12 更新 $\bar{s}_{0:N}$ 和 $\bar{u}_{0:N-1}$
- 13 **if** 状态序列和控制序列变化量小于阈值 **then**
- 14 **break**
- 15 $Path_l \leftarrow s_{0:N}^*$, $u_0^* \leftarrow$ 最优控制序列首项
- 16 **return** $Path_l, u_0^*$

算法 6-2 中的迭代过程体现了局部感知和运动优化的双向耦合：规划器先根据名义轨迹预测障碍点在机器人局部坐标系中的分布，再根据点级避障特征更新轨迹；更新后的轨迹又会改变下一轮点流坐标变换和避障特征。实际部署时， $K_{\max}$ 不宜过大，可结合控制周期设置为较小常数。当局部感知范围内无有效障碍点时，算法退化为带速度和平滑约束的路径跟踪 MPC；当障碍点过近且优化问题无法得到可行解时，规划器输出减速或停止指令，并等待下一周期感知更新或触发全局重规划。

6.3.7 在线求解与全向底盘速度输出

学习增强 MPC 在每个控制周期内输出最优状态序列 $\mathbf{s}_{0:N}^*$ 和控制序列 $\mathbf{u}_{0:N-1}^*$ ，系统仅执行首个控制量 $\mathbf{u}_0^*$ ，随后依据新的定位和障碍信息重新求解。由于局部优化已同时考虑参考路径跟随、点级避障和控制平滑，本文不再在规划器之后设置独立轨迹跟踪层，以避免两级控制器对同一速度量重复调节。

对于本文采用的全向移动底盘，执行控制量保持机体系笛卡尔形式

$$\mathbf{u}_0^* = \begin{bmatrix} v_{x,0}^{b,*} & v_{y,0}^{b,*} & \omega_0^* \end{bmatrix}^T, \quad (6-38)$$

并映射到 ROS 速度消息：

$$\begin{aligned} \text{cmd_vel.linear.x} &= v_{x,0}^{b,*}, \\ \text{cmd_vel.linear.y} &= v_{y,0}^{b,*}, \\ \text{cmd_vel.angular.z} &= \omega_0^*. \end{aligned} \quad (6-39)$$

三个分量均受式 6-34 和式 6-35 限制。需要保持特定朝向时，可提高参考状态中航向误差的权重；允许自由转向时，则由优化器根据路径、障碍分布和控制平滑代价联合确定角速度。

除优化约束外，执行端设置独立的状态检查：当机器人到全局终点 P_{end} 的距离小于到达阈值 d_{arr} 时输出零速度并返回到达状态；当当前量测最小距离低于碰撞阈值 d_{col} 、优化超时或子问题无可行解时，不发布候选前进速度，而是执行减速停车。若连续多个周期求解失败，则向全局层请求重新生成参考路径。上述机制用于处理线性化误差、感知突变和通信延迟等在线异常。

若将规划器迁移到差速或阿克曼底盘，应同步替换式 6-5 中的动力学模型及控制向量定义，不能仅对 `Twist` 字段进行形式映射。

6.4 Gazebo 仿真实验

6.4.1 仿真平台与统一实验协议

为比较不同局部规划方法在规则、非凸及混合动态环境中的综合性能，本文在 Gazebo 11 与 ROS Noetic 环境中构建仿真平台。机器人采用与式 6-5 一致的全向运动模型，局部规划与感知更新频率统一为 10 Hz。三种方法共用机器人几何尺寸、全局参考路径、局部传感器输入、最大速度与加速度、目标到达阈值、碰撞判据和任务超时上限，仅替换局部规划节点，从而避免全局路径和终止条件差异影响比较结果。

对比方法包括：（1）AABB-MPC，将聚类障碍物的轴对齐包围盒转化为 MPC 避障约束；（2）动态窗口法（Dynamic Window Approach, DWA），在满足速度和加速度限制的速度空间内采样并评价候选轨迹；（3）本文学习增强点级 MPC，直接利用障碍边界点和动态预测点流构造带误差补偿的点级距离约束。所有方法均使用相同全局参考路径，不对 RRT 本身进行性能对比。

仿真实验包含三个静态场景和一个混合动静态场景：S1 为规则凸障碍基准场景，S2 为 L 型内凹目标场景，S3 为密集非凸障碍场景，D1 为规则/不规则、凸/非凸动静障碍无序运动场景。每次运行记录机器人位姿、速度、局部轨迹、当前最小障碍距离、碰撞事件、规划状态和单周期规划耗时。成功试验需同时满足在规定时间内到达目标、全程无碰撞且规划节点正常运行。

评价指标包括任务成功率 SR 、任务完成时间 T 、轨迹长度 L 、终点误差 e_g 、最小障碍距离 $d_{\text{obs}}^{\min}$ 、控制平滑代价 $J_{\Delta u}$ 以及规划耗时。控制平滑代价定义为

$$J_{\Delta u} = \sum_{k=1}^K \|\mathbf{u}_k - \mathbf{u}_{k-1}\|_2^2, \quad (6-40)$$

其中 K 为单次任务的控制周期数。规划耗时除均值外，还应报告 95% 分位值、最大值及超过 100 ms 控制周期的比例。

表 6-3 Gazebo 局部规划器统一实验配置（待根据实际工程配置填写）

类别	参数	统一设置
机器人	外形尺寸、footprint	待填：实际 URDF 与膨胀半径
运动约束	最大速度、加速度	待填：三种方法的共同限值
规划设置	控制周期、任务超时	0.1 s；待填：超时阈值
到达判定	位置/航向阈值	待填：实际判据
碰撞判定	接触或距离阈值	待填：Gazebo 接触插件与距离阈值
重复试验	静态/动态重复次数	待填：实际运行次数与随机种子

占位数据声明：截至本章本轮重构，四类场景的统一 ROS/Gazebo 日志尚未导入论文仓库。以下结果表仅定义统计字段，不填写或推测实验数值；图 6-7 所用现有 Gazebo 截图仅用于说明场景构造思路。正式提交前应以实际日志生成的轨迹、统计量和截图替换相应占位内容。


6.4.2 静态障碍实验

静态实验从障碍几何复杂度逐步增加，检验三种局部规划器在相同全局引导下的通行能力与轨迹质量。


S1 规则凸障碍基准场景由圆柱和矩形等凸障碍组成，障碍之间保留明确可通行间隔。该场景用于确认本文方法在常规环境中不会因引入点级表示而显著降低任务效率。预期三种方法均可完成任务，主要比较轨迹长度、控制平滑性、障碍距离和规划耗时。

S2 L 型内凹目标场景将目标点布置在 L 型障碍的内凹可行区域。AABB 表示会把 L 型障碍的外接矩形整体视为占用空间，而点级表示保留真实边界及其内凹空间。该场景用于观察 AABB-MPC 是否在入口外停滞、DWA 能否通过局部代价搜索进入内凹区域，以及本文方法能否在保持安全裕度的同时到达目标。

S3 密集非凸障碍场景由多个 L 型、凹型和斜置障碍组合而成，形成局部通道交错、可行方向频繁变化的复杂环境。该场景综合考察局部死锁、往复调整、轨迹绕行和点级约束规模增长对求解时间的影响。



(a) S1 规则凸障碍场景示例



(b) S3 密集非凸障碍场景示例

图 6-7 Gazebo 静态实验场景示例（待以最终统一场景截图替换）

正式结果分析应遵循“现象—指标—原因”的顺序：先根据同一坐标系下的轨迹图描述是否到达、停滞或绕行，再结合表 6-4 中的成功率、轨迹长度与安全距离量化差异，最后联系 AABB 包络、速度空间采样和点级距离约束解释原因。在真

表 6-4 静态障碍实验统计表（占位，待真实仿真日志替换）

场景	方法	$SR/\%$	T/s	L/m	e_g/m	d_{obs}^{min}/m	$J_{\Delta u}$
S1	AABB-MPC	待填	待填	待填	待填	待填	待填
	DWA	待填	待填	待填	待填	待填	待填
	本文方法	待填	待填	待填	待填	待填	待填
S2	AABB-MPC	待填	待填	待填	待填	待填	待填
	DWA	待填	待填	待填	待填	待填	待填
	本文方法	待填	待填	待填	待填	待填	待填
S3	AABB-MPC	待填	待填	待填	待填	待填	待填
	DWA	待填	待填	待填	待填	待填	待填
	本文方法	待填	待填	待填	待填	待填	待填

实日志补齐之前，本节不预写“本文方法最优”等结果性结论。

6.4.3 混合动静态障碍实验

D1 场景在同一环境中同时设置静态与动态障碍，障碍物包含规则凸形、规则非凸形和不规则组合形状。动态障碍以不同初始位置、方向和速度无序运动，并允许在运行过程中短暂停止、改变方向或改变速度；静态障碍则用于形成局部遮挡和通行边界。该场景不将运动模式拆分为多个独立工况，而是在统一复杂环境中检验规划器对连续环境变化的响应能力。

AABB-MPC 根据第 5 章输出的动态状态估计更新包络中心；DWA 根据当前局部代价地图在动态窗口内重新采样速度；本文方法将动态障碍边界点按式 6-14 外推，并与静态边界点共同构造预测时域内的点级安全约束。三种方法使用相同的障碍物初始状态和随机种子。除静态实验指标外，D1 场景重点统计碰撞次数、紧急停车次数以及动态障碍接近阶段的最小距离，并结合速度与障碍距离时序判断是否存在频繁启停或振荡。

表 6-5 混合动静态障碍实验统计表（占位，待真实仿真日志替换）

方法	$SR/\%$	碰撞/次	急停/次	T/s	d_{obs}^{min}/m	$J_{\Delta u}$	平均耗时/ms
AABB-MPC	待填	待填	待填	待填	待填	待填	待填
DWA	待填	待填	待填	待填	待填	待填	待填
本文方法	待填	待填	待填	待填	待填	待填	待填

动态场景的正式图表应至少包括三种方法的典型轨迹、机器人合速度、到目标距离和最小障碍距离时序。由于本章已取消消融实验，D1 仅比较三个完整规划器，不把总体性能差异进一步归因为单一编码器或预测模块的独立贡献。

6.4.4 实时性与仿真结果分析规范

实时性统计直接并入 S1、S2、S3 和 D1 四个场景，不再设置障碍点数或预测时域参数扫描。对每种方法汇总单周期规划耗时的平均值 t_{avg} 、95% 分位值 t_{95} 、最大值 t_{max} 以及超过控制周期的比例 r_{over} 。其中

$$r_{\text{over}} = \frac{N(t_{\text{plan}} > 100 \text{ ms})}{N_{\text{cycle}}} \times 100\%, \quad (6-41)$$

N_{cycle} 为统计周期总数。平均值用于反映常态计算负担， t_{95} 和 t_{max} 用于识别长尾延迟， r_{over} 用于判断规划节点能否稳定匹配 10 Hz 控制周期。

表 6-6 局部规划实时性统计表（占位，待真实仿真日志替换）

场景	方法	t_{avg}/ms	t_{95}/ms	t_{max}/ms	$r_{\text{over}}/\%$
S1-S3	AABB-MPC	待填	待填	待填	待填
S1-S3	DWA	待填	待填	待填	待填
S1-S3	本文方法	待填	待填	待填	待填
D1	AABB-MPC	待填	待填	待填	待填
D1	DWA	待填	待填	待填	待填
D1	本文方法	待填	待填	待填	待填

仿真结论以实际日志为唯一依据。若某方法在某场景失败，应同时报告失败类型和失败次数，不从失败样本中选择性计算任务时间或轨迹长度；若三种方法差异较小，则如实表述为性能相近，不以占位数据预设结论。

6.5 实物实验

6.5.1 实验平台与场景

实物实验用于检验学习增强点级 MPC 在真实激光雷达量测、定位误差和底盘执行条件下能否稳定运行，而不承担四类仿真场景的完整统计复现。实验采用全向移动机器人平台，搭载 Livox MID-360 激光雷达，机载计算平台运行 Ubuntu 20.04 与 ROS Noetic，实时定位由第 4 章 FAST-LIO2 里程计提供，局部规划控制频率为 10 Hz。

现有实物材料包含 L 型非凸障碍和多障碍组合环境。由于不同照片的障碍布局、机器人位置和拍摄范围并不完全一致，本节不再将其排成“同一目标点下两种方法对比”或“连续导航过程”，而仅作为实验平台、典型障碍布局和运行状态的场景记录。




图 6-8 实物实验场景与机器人运行状态示例

6.5.2 L 型非凸障碍运行验证

L 型场景将目标区域设置在障碍内凹侧，用于观察点级表示是否能够保留包络内部的真实可行空间。实物验证应以同一场次的 ROS 日志为准，在统一地图坐标系中叠加真实障碍轮廓、AABB 包络、全局参考路径、机器人轨迹和起终点，并同步给出到目标距离、机体系速度及最小障碍距离曲线。现有照片只能证明平台和障碍场景已经搭建，不能替代同条件下的轨迹对照。

表 6-7 L 型实物实验记录表（待同场次日志补充）

方法	成功次数/总次数	终点误差/m	任务时间/s	最小距离/m	平均规划耗时/ms
AABB-MPC	待填	待填	待填	待填	待填
本文方法	待填	待填	待填	待填	待填

在日志补齐前，本节只保留如下可核验的定性判断：AABB 会将 L 型障碍的内凹部分包含在外接矩形内，因此可能压缩或阻断通向内部目标的可行空间；点级表示在感知边界质量足够时能够避免这一几何误判。是否成功到达、耗时多少以及两种方法差异是否显著，均应由同场次重复实验决定。

6.5.3 复杂障碍环境运行展示与讨论

多障碍组合照片用于展示规划器在更复杂真实环境中的运行形态。由于当前照片并非同一场景的连续帧，也缺少与 AABB-MPC 和 DWA 一一对应的同步日志，本节不据此计算成功率或宣称方法排序。后续若补采数据，应固定场景、起终点和传感器配置，分别运行三种方法，并按与仿真一致的指标生成轨迹与时序图。

仿真与实物实验承担不同的证据功能：Gazebo 实验在统一条件下比较 AABB-

MPC、DWA 和本文方法在规则凸、L 型内凹、密集非凸及混合动静态场景中的综合表现；实物实验则验证点级 MPC 的软件链路、感知接口和全向速度输出能够在真实平台上运行。由于本章不设置消融实验，结论限定为完整规划方法之间的综合比较，不单独声称学习编码器或动态预测模块各自带来确定幅度的性能提升。

6.6 本章小结

本章构建了“全局参考引导-局部滚动优化-底盘速度执行”的分层导航方法。全局层采用二维目标偏向 RRT 生成拓扑可行参考路径，并通过直连检查、线段碰撞检测、超时处理、路径裁剪和平滑后复检提高工程可用性；该层通过统一路径接口与局部规划器解耦，可按地图特点替换为其他全局搜索算法。

局部层面向非凸障碍和动态环境，引入点级障碍表示与恒加速度预测点流，并利用距离-分离方向编码器把障碍边界信息转化为逐次线性化的距离约束。在编码器测试误差基础上设置距离补偿量，并在 MPC 中加入非负松弛变量、控制约束和异常停车逻辑，以提高在线求解的鲁棒性。规划器首个最优控制量直接映射为全向底盘的机体系速度指令，从而保持模型、优化变量与 ROS 执行接口一致。

实验部分按“仿真主验证、实物补充验证”组织。Gazebo 实验设置规则凸障碍、L 型内凹目标、密集非凸障碍和混合动静态障碍四类场景，统一比较 AABB-MPC、DWA 与本文方法；实物部分聚焦于 L 型及多障碍环境中的部署可行性。当前仓库尚缺少统一仿真日志和同场次实物统计，因此本章只建立实验协议、指标和结果表结构，所有待填项均须在正式提交前由真实日志替换，不能作为已获得的实验结论。

第 7 章 总结与展望

7.1 工作总结

本文围绕变电站运维场景下移动机器人自主导航的实际需求，针对复杂环境感知、定位建图、动态障碍物处理以及路径规划等关键问题，开展了面向变电站运维的搬运机器人导航系统设计与实现研究。全文主要工作总结如下：

- (1) 面向变电站高安全性、高可靠性和复杂空间约束等应用特点，本文分析了运维机器人的功能需求，设计了机器人硬件平台和导航系统总体框架。系统以激光雷达、双目相机等传感器为环境信息输入，结合中央控制模块和底层运动控制模块，为后续环境感知、地图构建、路径规划和运动控制提供了整体实现基础。
- (2) 针对导航系统中多传感器数据统一表达的问题，本文梳理了世界坐标系、机器人基坐标系、雷达坐标系和相机坐标系之间的转换关系，并介绍了 K-Means 和 DBSCAN 等点云聚类基础方法。上述理论为点云处理、障碍物提取和地图构建提供了基础支撑。
- (3) 针对复杂动态环境中的障碍物感知问题，本文设计了基于深度图像和点云数据融合的轻量级障碍物检测与跟踪方法。该方法结合 U 深度图检测器和 DBSCAN 检测器的优势，通过包围盒匹配和融合降低单一传感器噪声带来的误检影响；同时引入基于特征的数据关联、恒加速度模型和点云投票策略，对动态障碍物进行识别与状态估计。在地图构建方面，本文采用局部占用栅格更新，为规划器提供可用于避障决策的环境约束。
- (4) 针对变电站设备密集、障碍形态复杂且可能存在动态干扰的导航场景，本文设计了全局参考引导与局部滚动优化相结合的路径规划方法。全局层采用目标偏向 RRT 生成二维拓扑可行参考路径，并通过直连检查、线段碰撞检测、超时处理和路径平滑复检提高工程可用性；局部层构建学习增强 MPC 方法，在承接障碍物边界和恒加速度状态估计结果的基础上，引入点级障碍表示、动态预测点流和学习型距离特征，降低非凸障碍包络造成的可行空间损失。本文同时完成了规划输出到全向底盘速度接口的设计，使滚动优化得到的首个控制量能够直接转化为机器人可执行指令。

7.2 工作展望

本文围绕变电站运维机器人导航系统的关键模块进行了设计与研究，但距离工程化长期稳定运行仍有进一步完善空间。后续工作可从以下几个方面展开：

- (1) 进一步完善真实变电站或高保真仿真场景下的系统实验。后续可围绕定位误差、建图精度、障碍物检测准确率、规划耗时、路径平滑性和任务完成率等指标建立更完整的评价体系，并开展多场景、多工况对比实验。
- (2) 提升复杂电力场景下的多传感器融合鲁棒性。变电站中金属结构密集、电磁环境复杂，单一传感器容易受到遮挡、反射或噪声影响。后续可进一步融合激光雷达、视觉、IMU 等多源信息，提高机器人在弱纹理、强反光、遮挡和动态干扰场景下的定位与感知稳定性。
- (3) 优化动态障碍物预测与局部规划策略。当前方法主要基于显式运动模型和几何约束进行动态避障，后续可结合学习型运动预测、风险场建模或神经规划方法，提高机器人在非凸障碍物、突发动态目标和狭窄通道中的通行能力。
- (4) 推进导航系统与具体运维任务的深度结合。后续可将导航系统与设备巡检、仪表识别、目标抓取、辅助搬运等任务模块进一步集成，形成从任务分配、路径规划、环境感知到动作执行的闭环作业系统，从而提升变电站机器人系统的实用价值。

致 谢

时光荏苒，转眼间研究生三年的学习生涯即将画上句号。回首这段充实而难忘的求学历程，心中涌起无限感慨与感激。在此论文完成之际，我要向所有在学业和生活中给予我帮助和支持的人致以最诚挚的谢意。

首先，我要衷心感谢我的导师黄娜教授。从论文选题、研究方向的确立，到具体技术方案的设计与实现，再到论文的撰写与修改，导师都给予了悉心的指导和无私的帮助。黄老师严谨的治学态度、敏锐的学术洞察力以及对科研工作的执着追求，深深感染着我，让我在面对科研困难时能够坚持不懈。导师不仅在学术上给予我专业的引导，更在为人处世方面为我树立了榜样，这些都将是我不受用的宝贵财富。

感谢实验室的各位老师和同学们。与他们的合作让我受益匪浅。感谢实验室的师兄师姐们在我遇到技术难题时的耐心解答，感谢师弟师妹们在日常工作相互支持。正是有了这样一个团结友爱、积极向上的集体，才使我的研究生生活充实而富有意义。

感谢我的父母和家人。是你们一如既往的支持和鼓励，让我能够全身心地投入到学习和科研工作中。在我遇到困难和挫折时，你们的理解与包容给了我继续前行的勇气和力量。你们的养育之恩，我将铭记于心，永生难忘。

最后，感谢所有关心、帮助和支持过我的老师、同学和朋友们。正是因为有你们的陪伴，我的研究生生活才变得如此丰富多彩。虽然研究生阶段的学习即将结束，但求知的道路永无止境。我将带着学到的知识和收获的成长，继续在未来的道路上砥砺前行，不负青春，不负韶华。

攻读硕士学位期间取得的成果

期刊论文:

[1]Liu, X., Wang, J., Huang, N., Ren, J. (2025, May). A New Privacy-Preserving Mechanism for Networked Agents. In 2025 37th Chinese Control and Decision Conference (CCDC) (pp. 2185-2190). IEEE.(4/4, 已见刊)

申请专利:

[1] 一种压延设备 [P]. CN120461674A,2025.08.12(2/6, 已公开)

竞赛成果:

[1] “华为杯”第七届中国研究生人工智能创新大赛国家二等奖 (4/4)

[2] “兆易创新杯”第二十届中国研究生电子设计大赛华东赛区二等奖 (1/3)

科研项目: